BỘ GIÁO DỤC VÀ ĐÀO TẠO

TRƯỜNG ĐẠI HỌC THƯƠNG MẠI

BÁO CÁO TỔNG KẾT
ĐỀ TÀI NGHIÊN CỨU KHOA HỌC CỦA SINH VIÊN

"SỬ DỤNG HỌC BÁN GIÁM SÁT ĐỂ XÁC ĐỊNH ĐẶC TRƯNG NGƯỜI DÙNG: ÁP DỤNG VÀO CÁ NHÂN HOÁ QUẢNG CÁO TRONG METAVERSE"

Nhóm sinh viên thực hiện:

STT	Họ và tên SV	MSV	Lớp HC
1	Phạm Hương Giang	22D192022	K58SN1
2	Đinh Thị Ngọc Diễm	22D192018	K58SN2
3	Nguyễn Triệu Gia Khánh	22D190077	K58S4

Giảng viên hướng dẫn: TS. Nguyễn Thị Hội

Hà Nội, Tháng 3 năm 2025

LỜI CẢM ƠN

Lời đầu tiên, nhóm nghiên cứu xin gửi lời cảm ơn chân thành nhất đến các thầy cô khoa Hệ thống thông tin kinh tế và Thương mại điện tử đã tạo cơ hội và điều kiện giúp đỡ nhóm trong suốt quá trình nghiên cứu để nhóm tác giả hoàn thành được bài nghiên cứu khoa học này.

Đặc biệt, nhóm tác giả xin gửi lời cảm ơn chân thành về sự chỉ dạy, hướng dẫn tận tình của Tiến Sĩ Nguyễn Thị Hội, Phó Trưởng Khoa Hệ thống thông tin kinh tế và Thương mại điện tử, Trường Đại học Thương mại trong suốt thời gian thực hiện đã hết lòng hướng dẫn, chỉ bảo, giúp đỡ nhóm tác giả hoàn thành đề tài này. Nhóm tác giả xin chân thành gửi lời cảm ơn đến gia đình, người thân và bạn bè và đặc biệt là bạn Hoàng Văn Khang, K58SN1, sinh viên Trường Đại học Thương mại đã quan tâm, khích lệ và giúp đỡ nhóm nghiên cứu hoàn thành bài nghiên cứu.

Nhóm tác giả xin cam đoan bài nghiên cứu khoa học là bài nghiên cứu của nhóm tác giả, được đúc kết quá trình học tập và nghiên trong thời gian qua. Các thông tin và số liệu được sử dụng trong bài nghiên cứu là hoàn toàn trung thực.

Mặc dù trong quá trình làm đề tài nghiên cứu nhóm tác giả đã cố gắng, tuy nhiên cũng không tránh khỏi những thiếu sót không đáng có. Vì vậy nhóm tác giả hy vọng sẽ nhận được những ý kiến nhận xét, góp ý của các thầy cô giảng viên về những vấn đề được triển khai trong bài báo cáo nghiên cứu khoa học của nhóm được hoàn thiện và giúp nhóm tác giả có thêm những kinh nghiệm quý báu.

Cuối cùng, nhóm tác giả xin kính chúc các thầy cô giảng viên trường Đại học Thương mại nói chung, các thầy cô Khoa Hệ thống thông tin kinh tế và Thương mại điện tử nói riêng luôn dồi dào sức khỏe và thành công trong sự nghiệp giảng dạy cao quý.

Nhóm tác giả xin chân thành cảm ơn!

Hà Nội, ngày 6 tháng 3 năm 2025

Nhóm tác giả

MỤC LỤC

LỜI CẢM ƠN ..... **i**
MỤC LỤC ..... **ii**
DANH MỤC TỪ VIẾT TẮT ..... **iv**
DANH MỤC BẢNG BIỂU ..... **vi**
DANH MỤC HÌNH ẢNH ..... **vi**
PHẦN MỞ ĐẦU **1**
1. Tính cấp thiết của đề tài 1
1.1. Xu hướng phát triển của Metaverse 1
1.2. Thách thức trong thu thập và phân tích đặc trưng người dùng trong Metaverse 3
2. Mục tiêu nghiên cứu 4
2.1. Mục tiêu chung 4
2.2. Mục tiêu cụ thể 4
3. Câu hỏi nghiên cứu 4
4. Đối tượng, khách thể và phạm vi nghiên cứu 5
4.1. Đối tượng nghiên cứu 5
4.2. Khách thể nghiên cứu 5
4.3. Phạm vi nghiên cứu 5
5. Phương pháp nghiên cứu 5
6. Những đóng góp của đề tài 6
7. Kết cấu báo cáo 6
CHƯƠNG 1: CƠ SỞ LÝ THUYẾT VỀ ĐỀ TÀI NGHIÊN CỨU **8**
1.1. Cơ sở lý thuyết 8
1.1.1. Các khái niệm liên quan đến đề tài 8
1.1.1.1. Metaverse 8
1.1.1.2. Đặc trưng người dùng 12
1.1.1.3. Cá nhân hóa quảng cáo 13
1.1.2. Các công nghệ, kỹ thuật liên quan đến đề tài 15
1.1.2.1. Khái niệm học bán giám sát 15
1.1.2.2. Các phương pháp học bán giám sát 15
1.1.2.3. Ứng dụng của học bán giám sát 29
1.1.3. Các xu hướng và ứng dụng mới trong kinh tế, xã hội 30
1.2. Các nghiên cứu liên quan 32
1.2.1. Nghiên cứu trong nước 32
1.2.2. Nghiên cứu trên thế giới 33
1.2.3. Các vấn đề đặt ra liên quan đến đề tài 36
CHƯƠNG 2: MÔ HÌNH NGHIÊN CỨU **40**
2.1. Thực trạng các vấn đề liên quan đến đề tài nghiên nghiên cứu 40
2.1.1. Ở Việt Nam 40
2.1.2. Trên thế giới 41
2.1.3. Đánh giá chung 42
2.2. Các mô hình liên quan đến đề tài 43
2.2.1. Các mô hình lý thuyết 43
2.2.1.1. Các mô hình học bán giám sát 44
2.2.1.2. Các mô hình phân tích đặc trưng người dùng trong Metaverse 48
2.2.2. Mô hình đề xuất của nghiên cứu 51
CHƯƠNG 3: PHƯƠNG PHÁP NGHIÊN CỨU **54**

3.1. Phương pháp nghiên cứu 54
3.2. Phương pháp đánh giá 54
3.2.1. Đánh giá độ chính xác và hiệu suất mô hình 54
3.2.2. Đánh giá thời gian huấn luyện 56
CHƯƠNG 4: KẾT QUẢ NGHIÊN CỨU 57
4.1. Thu thập và mô tả dữ liệu 57
4.1.1. Phương pháp và cách thức thu thập dữ liệu 57
4.1.2. Mô tả dữ liệu khảo sát 57
4.2. Các kết quả thực nghiệm 58
4.2.1. Xây dựng bộ dữ liệu thực nghiệm 58
4.2.2. Kịch bản thực nghiệm 59
4.2.2.1. Các bước thực nghiệm 59
4.2.2.2. Sơ bộ thực nghiệm 60
4.2.3. Các kết quả thực nghiệm 62
4.2.3.1. Các bước thực hiện 62
4.2.3.2. Kết quả 62
4.2.4. So sánh với các mô hình đã có 64
4.3. Đánh giá và thảo luận kết quả thực nghiệm 65
CHƯƠNG 5: KẾT LUẬN VÀ CÁC HÀM Ý 67
5.1. Kết luận 67
5.2. Các hàm ý về giải pháp 67
5.3. Hạn chế và hướng nghiên cứu tiếp theo 69
DANH MỤC TÀI LIỆU THAM KHẢO .....
TÀI LIỆU TIẾNG ANH .....
TÀI LIỆU TIẾNG VIỆT .....

DANH MỤC TỪ VIẾT TẮT

AI:	Artificial intelligence (Trí tuệ nhân tạo)
ANN:	Artificial Neural Network (Mạng nơron nhân tạo)
AR:	Augmented Reality (Thực tế tăng cường)
CCPA:	Califonia Consumer Privacy Act (Đạo luật Quyền riêng tư Người tiêu dùng California)
CFA:	Confirmatory Factor Analysis (Phân tích nhân tố khẳng định)
CNN:	Convolutional Neural Network (Mạng nơron tích chập)
CTR:	Click Through Rate (Tỷ lệ nhấp chuột)
DAU:	Daily Active Users (Người dùng hoạt động hàng ngày)
EFA:	Exploratory Factor Analysis (Phân tích nhân tố khám phá)
GDPR:	General Data Protection Regulation (Quy định bảo vệ dữ liệu chung)
GIS:	Geographic Information System (Hệ thống thông tin địa lý)
GSSL:	Graph-based Semi-supervised Learning (Học bán giám sát dựa trên đồ thị)
IoT:	Internet of things (Internet vạn vật)
IR:	Information Retrieval (Hệ thống truy xuất thông tin)
KNN:	K-Nearest Neighbors (Thuật toán K láng giềng gần nhất)
LMS:	Learning Management System (Hệ thống quản lý học tập)
LSTM:	Long Short Term Memory (Mạng bộ nhớ dài - ngắn hạn)
MAU:	Monthly Active Users (Người dùng hoạt động hàng tháng)
ML:	Machine Learning (học máy)
MR:	Mixed Reality (Thực tế hỗn hợp)
MTAM:	Modified Technology Acceptance Model (Mô hình Chấp nhận Công nghệ mở rộng)
MTCNN:	Multi-task Cascaded Convolutional Networks (Mạng nơron tích chập xếp chồng)
NeuIR:	Neural Information Retrieval (Truy hồi thông tin bằng mạng nơron)
NLP:	Natural Language Processing (Xử lý ngôn ngữ tự nhiên)
NPC:	Non-player Character (Nhân vật ảo không phải người chơi)

RL:	Reinforcement Learning (Học tăng cường)
RNN:	Recurrent Neural Networks (Mạng nơron hồi quy)
SME:	Small and Medium Enterprises (Doanh nghiệp vừa và nhỏ)
SSL:	Semi-Supervised Learning (Học bán giám sát)
SVM:	Support Vector Machine (Máy vector hỗ trợ)
TAM:	Technology Acceptance Model (Mô hình Chấp nhận Công nghệ)
UI:	User Interface (Giao diện người dùng)
UX:	User Experience (Trải nghiệm người dùng)
VR:	Virtual Reality (Thực tế ảo)
FP:	False Positive (Dương tính giả)
FN:	False Negative (Âm tính giả)
TP:	True Positive (Dương tính thật)
TN:	True Negative (Âm tính thật)

DANH MỤC BẢNG BIỂU

Bảng 1. Bảng mẫu dữ liệu thực nghiệm 59
Bảng 2. So sánh độ chính xác của các mô hình trên từng tập fold và tập test 64
Bảng 3. So sánh hiệu suất các thuật toán 64

DANH MỤC HÌNH ẢNH

Hình 1. Hồi quy Logistic nhị thức (Sigmoid) 16
Hình 2. Hồi quy Logistic đa thức (Softmax) 17
Hình 3. Hồi quy Logistic thứ tự (Cumulative Logit) 18
Hình 4. Ví dụ về Decision Tree (Cây quyết định) 21
Hình 5. Mô hình Random Forest 24
Hình 6. Ví dụ minh hoạ về thuật toán SVM 26
Hình 7. Thuật toán Self-training 44
Hình 8. Giải thích thuật toán Self-training 45
Hình 9. Kiến trúc Shoestring 46
Hình 10. Machine Learning Project Flowchart 48
Hình 11. Mô hình TAM (Davis, 1989) 49
Hình 12. Engel-Kollat-Blackwell model (1978) 51
Hình 13. Mô hình đề xuất nghiên cứu 53
Hình 14. Confusion Matrix 55
Hình 15. Sơ bộ các bước thực nghiệm 61
Hình 16. Kết quả đánh giá mô hình Logistic Regression 62
Hình 17. Kết quả đánh giá mô hình Decision Tree 63
Hình 18. Kết quả đánh giá mô hình Random Forest 63
Hình 19. Kết quả đánh giá mô hình SVM 63
Hình 20. Kết quả đánh giá mô hình KNN 63

PHẦN MỞ ĐẦU

1. Tính cấp thiết của đề tài

1.1. Xu hướng phát triển của Metaverse

Trong những năm gần đây thuật ngữ Metaverse xuất hiện ngày càng nhiều và càng phát triển, trở thành xu hướng công nghệ mới của thế hệ Internet tương lai. Nó được xem là Internet thế hệ mới sẽ thay đổi cách chúng ta sống và làm việc ở các lĩnh vực. Đại dịch COVID-19 đã cho chúng ta thấy sự hạn chế giao tiếp trong công việc, cuộc sống của mỗi người bởi vậy để đột phá và tăng cường tốc độ làm việc từ xa và xã hội hóa nhằm đổi mới công nghệ và làm tăng sự chấp nhận cuộc sống trực tuyến của người dùng, các ông lớn trong lĩnh vực công nghệ đã đầu tư mạnh mẽ vào Metaverse, vào các công nghệ hỗ trợ Metaverse.

Mở đầu cho làn sóng đi vào thị trường Metaverse là ông Mark Zuckerberg - người sáng lập Facebook đã đổi tên thương hiệu truyền thông khổng lồ từ Facebook sang Meta và đầu tư 10 tỷ đô vào thị trường Metaverse. Ngay khi tuyên bố đổi tên thương hiệu sang Meta, hành động của ông Mark Zuckerberg đã thu hút sự chú ý của truyền thông cũng như thay đổi hướng đi của các thương hiệu lớn trên thế giới như Apple, Microsoft, Disney, … Các công ty, tập đoàn công nghệ lớn trên thế giới đã đầu tư rất nhiều vào Metaverse và kỳ vọng nó sẽ mang lại nhiều lợi nhuận cho họ. Tuy nhiên ở thời điểm hiện tại, tức đầu năm 2025, xu hướng đi vào thị trường Metaverse với mục đích ban đầu là cung cấp thế giới ảo để mọi người làm việc, giao lưu và vui chơi đã nhận lại sự quan tâm mờ nhạt, nguồn tài trợ chậm lại và trở nên không khả thi khi mà có ít người sử dụng nó do vấp phải một vấn đề là thiết bị phần cứng - kính thực tế ảo không được sử dụng phổ biến bởi mức giá của mỗi chiếc kính là không hề rẻ. Theo nhà sáng lập Beautyque NYC Sonia Khemiri chia sẻ với Techopedia: “Sự cường điệu ban đầu vào đầu những năm 2020 đi kèm với những kỳ vọng không thực tế về việc áp dụng nhanh chóng và thay đổi sâu rộng. Những gì chúng ta đang thấy bây giờ là một sự hiệu chỉnh lại. Tầm nhìn về thế giới ảo được kết nối với nhau đã gặp phải một số rào cản, đặc biệt là với phần cứng vẫn còn rườm rà và đắt tiền và phần mềm vẫn chưa mang lại trải nghiệm liền mạch, nhập vai mà chúng tôi hy vọng” (Rosencrance, 2025). Với rào cản về phần cứng cùng với sự bùng nổ của Chat GPT vào cuối năm 2022, thị trường Metaverse nhanh chóng giảm sức hút và gặp phải tổn thất lớn sau khi Meta báo cáo bộ phận Reality Labs

của họ đã tạo ra khoản lỗ 4,3 tỷ đô la vào quý IV của năm với doanh thu 727 triệu đô la, Khoản lỗ cho Reality Labs vẫn tăng lên vào năm 2023 với mức tăng 16,1 tỷ đô la (Tucci, 2024). Sau khoản lỗ được công bố, Disney là công ty mới nhất đã rời khỏi thị trường Metaverse bằng động thái loại bỏ toàn bộ bộ phận Metaverse khoảng 50 nhân viên - đơn vị tạo ra với mục đích hoạt động phát triển một hình thức kể chuyện mới (Robbie Whelan & Joe Flint, 2023; Wang, 2023). Walmart cũng đóng cửa trải nghiệm Metaverse Universe of Play trên Roblox chỉ sau 6 tháng hoạt động, Microsoft đã sa thải nhân viên từ Bộ công cụ thực tế hỗn hợp và HoloLens (Monteros, 2023). Với các động thái này từ các công ty tập đoàn lớn, nhiều cánh truyền thông, báo cáo đã tuyên bố Metaverse đã chết, tin đồn này bị phóng đại nên rất nhiều xong thực tế lại không như vậy. Theo (Statista), dự đoán thị trường Metaverse sẽ đạt 103,6 tỷ đô la Mỹ vào năm 2025 và với tốc độ tăng trưởng hằng năm là 37,43% dự kiến khối lượng thị trường là 507,8 tỷ đô la Mỹ vào năm 2030. Thuật ngữ Metaverse dù không còn sức hấp dẫn nữa nhưng cũng không bị hoàn toàn loại bỏ, nhiều công ty đã thu hẹp ý tưởng của họ về Metaverse lại để tập trung vào dịch vụ của họ, ứng dụng thực tế, hữu hình hơn thay vì tạo ra một thế giới ảo khổng lồ, trừu tượng. Theo nhà tâm lý học tổ chức và chuyên gia AI (Bob Hutchins): “Roblox, Decentraland và Horizon Worlds của Meta, tiếp tục phát triển và tinh chỉnh các dịch vụ của họ, đặc biệt là trong các lĩnh vực thích hợp như trò chơi, sự kiện ảo và tương tác xã hội”. Theo nhà phân tích công nghệ độc lập, diễn giả công nghệ (Waseem Mirza): “Một trong những điều mà tôi lạc quan là lĩnh vực giải trí rộng lớn hơn, sẽ trải qua một sự thay đổi địa chấn khác trong kỷ nguyên Metaverse, tiếp nối sự gián đoạn do phát trực tuyến gây ra”.

Theo báo cáo CI&T (Minkow) cho biết có 81% số người được hỏi chưa mua hàng trong metaverse và 45% nói rằng họ không bao giờ thấy mình mua sắm trong đó. Và theo báo cáo McKinsey & Company (2023) tuyên bố thị trường Metaverse chỉ tính riêng thương mại điện tử “từ nhà và thực phẩm đến thể dục và quần áo" - có thể thúc đẩy "5 nghìn tỷ đô la tạo ra giá trị vào năm 2030". Giá trị được dự đoán mà thương mại điện tử mang lại cho thị trường Metaverse là con số khổng lồ nhưng lại có đến 81% người dùng chưa mua hàng trong Metaverse, nó cho thấy tín hiệu tốt về thuật ngữ này nói chung và ngành thương mại điện tử nói riêng trong Metaverse. Theo khảo sát về người tiêu dùng Metaverse (Mckinsey) cho biết nhiều ý tưởng của Metaverse đang vượt qua ranh giới của công nghệ nhưng lại thường bỏ lỡ mục tiêu với người tiêu dùng. Trong

ngành hàng mua sắm nói chung và dựa trên Metaverse nói riêng để tạo ra giá trị, lợi nhuận thì cần làm thỏa mãn nhu cầu người tiêu dùng để họ có những trải nghiệm tốt về việc mua sắm. Việc quảng cáo sản phẩm đến người dùng hiện nay đang có xu hướng tiếp cận bằng cách quảng cáo sản phẩm đến họ thông qua phân tích từ các thuật toán về những hành động, thói quen, thông tin cá nhân được người dùng chia sẻ xong vẫn chưa có hiệu quả cao với cách làm này. Theo Datareportal (2025), có một lượng người dùng đáng kể tương đương với 25% người dùng hoạt động hàng tháng của Facebook không nhìn thấy quảng cáo trên nền tảng. Việc đưa ra các gợi ý cho người dùng về các sản phẩm mà họ quan tâm là vấn đề thiết thực luôn được các nhà bán hàng quan tâm để tối ưu chi phí quảng cáo, tiết kiệm thời gian của họ đến với người dùng cũng như tiết kiệm tìm kiếm của người tiêu dùng về sản phẩm. Theo Statista được (Barnhart, 2025) tổng hợp, một cuộc khảo sát vào năm 2024 cho biết có đến 86% lượng nhà tiếp thị trên thế giới lựa chọn Facebook để sử dụng cho mục đích tiếp thị và theo Sprout, chi phí trung bình cho mỗi nhấp chuột là 1,88 đô la cho quảng cáo tạo khách hàng tiềm năng. Trong Metaverse, người dùng nhập vai dưới tài khoản được đại diện bởi avatar của họ luôn có mong muốn được thể hiện bản thân dựa ở đây chính là các trang mạng xã hội như Facebook, Instagram,…bằng cách chia sẻ thông tin cá nhân của họ, các hành động đăng bài viết, thể hiện cảm xúc, hoạt động tương tác với người dùng khác,…nên để có thể đưa sản phẩm đến tay người dùng ta cần biết họ là ai, họ muốn gì thông qua những thu thập về thông tin mà họ chia sẻ để phân tích từng cá nhân người dùng điều này được hiểu là cá nhân hóa quảng cáo.

1.2. Thách thức trong thu thập và phân tích đặc trưng người dùng trong Metaverse

Metaverse là một môi trường kỹ thuật phức tạp, đây là nơi người dùng giao tiếp, tương tác, thực hiện các hành vi của mình một cách thoải mái theo ý thích. Việc thu thập dữ liệu người dùng trong Metaverse để hệ thống cá nhân hóa để tối ưu trải nghiệm người dùng là xu hướng tất yếu nhưng quá trình này lại gặp phải nhiều khó khăn liên quan đến tính đa dạng của dữ liệu, quyền riêng tư, bảo mật an ninh và các vấn đề pháp lý khác. Dữ liệu trong Metaverse có tính đa dạng và phi cấu trúc cùng với đa dạng hành vi của người dùng không chỉ bằng văn bản, âm thanh, hình ảnh mà còn có các hoạt động tương tác trong không gian, hành vi giao dịch và cả dữ liệu sinh trắc học. Metaverse là một môi trường số mang tính ẩn danh cao vì thế người dùng thường có xu hướng hạn chế

chia sẻ các thông tin cá nhân của họ. Thêm vào đó, một số quy định pháp lý như Quy định chung về bảo vệ dữ liệu (GDPR) của Liên minh Châu Âu hay Luật bảo vệ quyền riêng tư của người tiêu dùng California (CCPA) tại Hoa Kỳ có yêu cầu chặt chẽ về thu thập và sử dụng dữ liệu cá nhân. Điều này tạo ra rào cản lớn, gây nhiều khó khăn trong quá trình đi thu thập phân tích thông tin người dùng.

Các phương pháp học máy truyền thống thường đòi hỏi một lượng lớn dữ liệu gán nhãn để huấn luyện mô hình nhưng trong môi trường Metaverse, việc thu thập dữ liệu là vấn đề khó khăn và để thu thập được dữ liệu có nhãn thì điều này lại càng khó khăn thêm bởi các dữ liệu có nhãn rất hạn chế do đặc điểm của môi trường này. Việc gán nhãn dữ liệu thủ công đòi hỏi nhiều thời gian và mức chi phí cao dẫn đến tốn kém nhiều. Phương pháp học bán giám sát có thể giúp khắc phục vấn đề này để tối đa dữ liệu thu thập được giúp xác định đặc trưng người dùng nhờ ưu điểm có thể kết hợp giữa dữ liệu có nhãn và chưa có nhãn. Điều này sẽ giúp cho mô hình học máy phân tích xác định đặc trưng người dùng không bị phụ thuộc hoàn toàn vào dữ liệu có nhãn.

2. Mục tiêu nghiên cứu

2.1. Mục tiêu chung

Xác định các đặc trưng của người dùng trong Metaverse, cụ thể trên nền tảng Facebook bằng phương pháp học bán giám sát, từ đó hỗ trợ cá nhân hoá quảng cáo, tối ưu hoá trải nghiệm người dùng.

2.2. Mục tiêu cụ thể

- Nghiên cứu cơ sở lý thuyết của Metaverse, đặc trưng người dùng, cá nhân hoá quảng cáo và học bán giám sát.
- Xây dựng mô hình đề xuất phân tích ảnh của người dùng để hỗ trợ cá nhân hoá quảng cáo.
- Đánh giá hiệu suất của mô hình và các thuật toán để tìm ra mô hình và thuật toán tối ưu nhất áp dụng vào quảng cáo cá nhân hóa cho người dùng.
- Đề xuất các giải pháp cá nhân hoá quảng cáo, tối ưu hoá trải nghiệm người dùng.

3. Câu hỏi nghiên cứu

Câu 1: Học bán giám sát là gì và có vai trò như nào trong việc xác định đặc trưng của người dùng, hỗ trợ cá nhân hoá quảng cáo?

Câu 2: Áp dụng những mô hình, thuật toán học bán giám sát nào để xác định đặc trưng của người dùng hỗ trợ cá nhân hoá quảng cáo?

Câu 3: Sử dụng các phương pháp nghiên cứu và các tiêu chí gì để đánh giá hiệu suất mô hình, thuật toán học bán giám sát trong xác định đặc trưng người dùng hỗ trợ cá nhân hoá quảng cáo?

Câu 4: Đề xuất các giải pháp nào để áp dụng học bán giám sát vào xác định đặc trưng người dùng hỗ trợ cá nhân hoá quảng cáo hiệu quả hơn?

4. Đối tượng, khách thể và phạm vi nghiên cứu

4.1. Đối tượng nghiên cứu

- Đặc trưng người dùng trong Metaverse: các dữ liệu về thông tin cá nhân, nhân khẩu học, các hình ảnh về bài đăng, bình luận, bài đăng lại của người dùng
- Kỹ thuật học bán giám sát
- Các thuật toán phân loại: Logistic Regression, Decision Tree, Random Forest, Support Vector Machine (SVM), K-Nearest Neighbour (KNN)

4.2. Khách thể nghiên cứu

- Người dùng trong Metaverse: Cá nhân tham gia hoạt động ở nền tảng Metaverse cụ thể là nền tảng Facebook dưới tài khoản cá nhân hợp lệ, có hình ảnh đại diện (avatar) và thông tin cá nhân cùng các hoạt động như đăng bài, bình luận hay tương tác với nội dung bài đăng từ người khác trong nền tảng.
- Các dữ liệu phát sinh từ hoạt động của người dùng: Dữ liệu hình ảnh có thể thu được từ các bài đăng của người dùng, bình luận bằng ảnh của người dùng, bài đăng dạng ảnh của cá nhân khác được người dùng tương tác (thả icon bày tỏ cảm xúc, chia sẻ).

4.3. Phạm vi nghiên cứu

- Không gian nghiên cứu: Đề tài giới hạn điều tra, phân tích và khai thác dữ liệu người dùng từ nền tảng mạng xã hội Facebook, là một không gian ảo phổ biến với lượng người dùng lớn.
- Thời gian nghiên cứu: từ 09/2024 đến 03/2025

5. Phương pháp nghiên cứu

- Phương pháp tài liệu:

    - Nghiên cứu các tài liệu trong nước và nước ngoài liên quan đến nội dung nghiên cứu như đặc trưng người dùng trong Metaverse, cá nhân hoá quảng cáo, học bán giám sát và các thuật toán.
    - Tổng hợp các phương pháp học bán giám sát hiện đại, tiên tiến, đặc biệt là các thuật toán phân tích dữ liệu hình ảnh
- Phương pháp thực nghiệm:
    - Xây dựng bộ dữ liệu huấn luyện
    - Triển khai các thuật toán và so sánh, đánh giá hiệu suất giữa các mô hình, thuật toán đề xuất

6. Những đóng góp của đề tài

Đề tài "Sử dụng học bán giám sát để xác định đặc trưng người dùng: Áp dụng vào cá nhân hoá quảng cáo trong Metaverse" đóng góp cả về mặt lý thuyết và về ứng dụng thực tiễn.

Về mặt lý thuyết, bài nghiên cứu xây dựng mô hình học bán giám sát để xác định đặc trưng của người dùng trong Metaverse, góp phần bổ sung nghiên cứu về mô hình hoá người dùng. Đề tài có ý nghĩa quan trọng trong lĩnh vực học máy (Machine Learning – ML), đặc biệt là phương pháp học bán giám sát để phân tích dữ liệu, góp phần mở rộng khả năng ứng dụng học máy cho các bài toán phức tạp. Đồng thời, bài nghiên cứu tập trung trong việc phân tích dữ liệu hình ảnh, đó là nền tảng phát triển các công nghệ hình ảnh trong tương lai.

Bên cạnh đó, đề tài cũng mang lại giá trị thực tiễn trong lĩnh vực cá nhân hoá quảng cáo và trải nghiệm người dùng. Nghiên cứu hỗ trợ hệ thống cá nhân hoá quảng cáo, tối ưu việc phân phối nội dung cho từng người dùng phù hợp, từ đó các doanh nghiệp đưa ra các chiến lược quảng cáo tối ưu, nâng cao hiệu suất tiếp thị. Ngoài ra, bài nghiên cứu mở rộng tiềm năng phát triển của ứng dụng AI trong Metaverse, trong quảng cáo thông minh, hệ thống gợi ý và thương mại điện tử. Đóng góp của đề tài sẽ là cơ sở định hướng của các nghiên cứu tiếp theo về ứng dụng học bán giám sát trong việc tối ưu trải nghiệm người dùng trong môi trường thực tế ảo.

7. Kết cấu báo cáo

Đề tài nghiên cứu là "Sử dụng học bán giám sát để xác định đặc trưng người dùng: Áp dụng vào cá nhân hoá quảng cáo trong Metaverse". Kết quả nghiên cứu của

đề tài là cơ sở khoa học để triển khai và ứng dụng học bán giám sát trong việc cá nhân hoá quảng cáo trong Metaverse. Vì vậy, nhóm xây dựng bài báo cáo với kết cấu các chương như sau:

Chương 1: Cơ sở lý thuyết về đề tài nghiên cứu

Chương này trình bày các cơ sở lý thuyết, khái niệm và các kết quả nghiên cứu tổng quan liên quan đến Metaverse, đặc trưng người dùng, cá nhân hoá, học bán giám sát và các thuật toán ứng dụng vào xác định đặc trưng người dùng. Trên cơ sở nghiên cứu, đánh giá, chỉ các vấn đề còn tồn tại từ đó đề xuất những nội dung nghiên cứu ở các chương tiếp theo.

Chương 2: Mô hình nghiên cứu

Chương này trình bày thực trạng với số liệu thống kê cụ thể và phân tích về hành vi người dùng trên Metaverse nói chung và mạng xã hội Facebook nói riêng từ đó đưa ra đánh giá chung tính cấp thiết của đề tài. Đồng thời, ở chương này cũng đề xuất ra mô hình của bài nghiên cứu dựa trên cơ sở lý thuyết các mô hình tham khảo.

Chương 3: Phương pháp nghiên cứu

Chương này trình bày đầy đủ các phương pháp nghiên cứu bao gồm cách tiếp cận thu thập và xử lý dữ liệu, phương pháp thực nghiệm. Ngoài ra, chương cũng trình bày các phương pháp đánh giá sẽ được sử dụng trong bài nghiên cứu để đo hiệu quả mô hình đề xuất.

Chương 4: Kết quả nghiên cứu

Chương này trình bày kết quả nghiên cứu của mô hình học bán giám sát sử dụng các thuật toán với việc trình bày chi tiết các thu thập dữ liệu, mô tả dữ liệu, các kịch bản thực nghiệm và kết quả thực nghiệm, so sánh với các mô hình đã có. Từ kết quả đưa ra đánh giá chung và những vấn đề, hạn chế gặp phải.

Chương 5: Kết luận và các hàm ý

Chương cuối tổng kết những nội dung đã làm được, những khó khăn hạn chế của bài nghiên cứu từ đó đề xuất giải pháp cho hướng nghiên cứu tiếp theo.

CHƯƠNG 1: CƠ SỞ LÝ THUYẾT VỀ ĐỀ TÀI NGHIÊN CỨU

1.1. Cơ sở lý thuyết

1.1.1. Các khái niệm liên quan đến đề tài

1.1.1.1. Metaverse

Khái niệm

Thuật ngữ Metaverse lần đầu xuất hiện trong tiểu thuyết khoa học viễn tưởng Snow Crash của (Stephenson, 1992), ông mô tả nó như một thế giới kỹ thuật số ba chiều, một thế giới trải nghiệm thực tế ảo của Internet - Metaverse, cho phép người dùng thoát khỏi thế giới vật chất và tham gia vào một không gian ảo. Ý tưởng này đã trở thành nguồn cảm hứng cho sự phát triển của công nghệ thực tế ảo và Internet thế hệ mới ngày nay. Theo nghiên cứu của (Zhao và cộng sự, 2022), trong khoảng 30 năm tiếp theo, khái niệm Metaverse đã xuất hiện trong sách và bộ phim khoa học viễn tưởng chẳng hạn như Ready Player One, Lucy và The Matrix. Theo (Zane L. Berge, 2008), vào thời điểm năm 2003, Second Life (SL) - nền tảng thế giới thực tế ảo 3D được phát triển bởi công ty California (Hoa Kỳ), được thành lập bởi Philip Rosedale, do Linden Lab điều hành. Đó được coi là một trong những nỗ lực đầu tiên trong việc chuyển đổi kỹ thuật của Metaverse. Tuy nhiên, do những hạn chế về kỹ thuật, quy mô đối tượng có thể tiếp cận, vấn đề về cơ sở hạ tầng công nghệ thông tin và công nghệ thực tế ảo (Virtual Reality - VR) chưa phát triển mạnh mẽ nên Second Life không đạt được thành công lớn, không tạo đột phá. Đến nay, theo dữ liệu trên trang web của PlayerAuctions (2025) thu thập thì số người chơi của SL năm 2025 mỗi ngày vẫn đạt hơn chục nghìn người tham gia, vẫn tồn tại và phục vụ một phân khúc nhỏ nhất định trong kỷ nguyên truyền thông mạng xã hội. Thuật ngữ này đã trở thành nền tảng của nhiều ý tưởng công nghệ trong tương lai và ngày càng được phát triển.

Theo (John Herrman & Kellen Browning, 2021) được xuất bản trên tờ New York Times, các trò chơi điện tử như Rolox, Fortnite và Animal Crossing: New Horizons, người chơi có thể xây dựng thế giới của riêng mình, có xu hướng, yếu tố trong trò chơi giống Metaverse.

Theo nghiên cứu của (G.D. Ritterbusch & M.R. Teichmann, 2023), hiện nay khái niệm Metaverse đã được mở rộng và tái định nghĩa nhiều lần bởi các nhà nghiên cứu và các doanh nghiệp. Định nghĩa của nó thay đổi tuỳ theo quan điểm và mục đích. Tuy

nhiên, Metaverse thường được mô tả là một thế giới ảo giống như thế giới thực, là không gian để tương tác với những người dùng khác.

Theo FINRA 10/2024, mặc dù thuật ngữ này không có định nghĩa cụ thể và các cách diễn giải có thể khác nhau, nhưng Metaverse thường được coi là sự phát triển tiếp theo của internet ngày nay.

Theo từ điển Cambridge định nghĩa, Metaverse là một phiên bản internet được xem như là một không gian ảo không giới hạn, nơi con người có thể gặp gỡ và tương tác trong thực tế ảo, một môi trường được tái tạo bằng hình ảnh và âm thanh do máy tính tạo ra, mang lại cảm giác như một địa điểm hoặc tình huống có thật.

Hay theo bài nghiên cứu "Opportunities in the Metaverse" của (J.P. Morgan, 2022), Metaverse là sự kết hợp giữa thế giới vật lý và kỹ thuật số, tạo ra một không gian ảo thống nhất, nơi con người có thể làm việc, giải trí, giao dịch và kết nối xã hội. Đây không phải là một thế giới duy nhất mà bao gồm nhiều không gian ảo khác nhau, được xây dựng để mở rộng và nâng cao trải nghiệm tương tác trực tuyến. Metaverse được phát triển bằng cách bổ sung một lớp không gian ba chiều sống động vào web, giúp mang lại trải nghiệm chân thực và tự nhiên hơn. Tuy Metaverse vẫn đang trong giai đoạn phát triển và chưa có định nghĩa chính thức, nhưng nó được kỳ vọng sẽ thay đổi cách con người tiếp cận công nghệ, phá vỡ rào cản địa lý và mở ra nhiều cơ hội trong các lĩnh vực kinh tế, giải trí và xã hội.

"Metaverse là biên giới tiếp theo giống như mạng xã hội khi chúng ta bắt đầu. Nó có tiềm năng được đầu tư và sẽ trở nên rất rộng lớn", tỷ phú Orlando Bravo, đồng sáng lập và quản lý của Thomas Bravo nói với CNBC vào năm 2021. Ông cho rằng Metaverse là một cơ hội đầu tư với tiềm năng phát triển lớn và sẽ trở thành một phần quan trọng của nền kinh tế kỹ thuật số trong tương lai.

Theo (Dwivedi và cộng sự, 2022), Metaverse được định nghĩa dựa trên bốn khía cạnh chính: môi trường (environment), giao diện (interface), tương tác (interaction) và giá trị xã hội (social value).

Về môi trường, Metaverse có thể được chia thành ba loại: môi trường thực tế, môi trường phi thực tế, và môi trường kết hợp. Môi trường thực tế mô phỏng chính xác các yếu tố địa lý và vật lý, mang đến trải nghiệm chân thực. Trong khi đó, môi trường phi thực tế loại bỏ các rào cản vật lý như trọng lực, cho phép người dùng trải nghiệm những điều không thể thực hiện trong thực tế. Môi trường kết hợp tận dụng ưu điểm của

cả hai bằng cách thêm yếu tố ảo vào thế giới thực hoặc xây dựng một thế giới mới dựa trên quy luật của thế giới thực.

Về giao diện, Metaverse thường sử dụng phương pháp hiển thị 3D, công nghệ nhập vai (immersive), và các yếu tố vật lý. Mặc dù 3D không phải là yếu tố bắt buộc, nhưng hầu hết các môi trường Metaverse đều có định dạng ba chiều để tăng độ chân thực. Công nghệ nhập vai như thực tế ảo (VR) giúp người dùng hòa mình vào thế giới ảo, nhưng cũng có thể gây ra vấn đề tâm lý như tách biệt thực tế. Ngoài ra, một số yếu tố vật lý như trọng lực, va chạm cũng được áp dụng để tăng tính chân thực, nhưng công nghệ hiện nay chưa thể tái tạo đầy đủ xúc giác và cảm giác thực tế.

Về tương tác, Metaverse không chỉ dừng lại ở các cuộc trò chuyện đơn giản mà còn bao gồm các yếu tố như kết nối xã hội, hợp tác và hội thoại với nhân vật ảo (NPCs). Người dùng có thể giao tiếp với nhau như trên mạng xã hội, nhưng trong không gian ba chiều sống động hơn. Ngoài ra, Metaverse cũng cho phép hợp tác giữa nhiều người để tạo ra giá trị mới, vượt qua giới hạn không gian và thời gian. NPC trong Metaverse không chỉ là nhân vật phụ mà còn có thể có tính cách, sở thích riêng, thậm chí người dùng có thể giao tiếp với động vật hoặc đồ vật trong thế giới ảo. Tuy nhiên, vấn đề kiểm soát nội dung giao tiếp cũng cần được chú trọng để đảm bảo môi trường an toàn.

Về giá trị xã hội, Metaverse mang lại những lợi ích mới cho cộng đồng, đặc biệt trong các lĩnh vực như giáo dục, kinh tế, văn hóa và nghiên cứu liên ngành. Nó không chỉ là một công cụ bổ sung cho thế giới thực mà còn có tiềm năng trở thành một thế giới độc lập, nơi con người có thể trao đổi kiến thức, tạo ra của cải và thể hiện bản thân theo nhiều cách khác nhau. Tuy nhiên, để Metaverse phát triển bền vững, cần có sự nhất quán về nền tảng và quy tắc vận hành, cũng như sự nghiên cứu chuyên sâu từ nhiều lĩnh vực như triết học, tâm lý học, xã hội học, kinh tế và chính trị.

Tại sự kiện Connect 2021, thuật ngữ Metaverse đã có sự trở lại lớn tiếp theo, Mark Zuckerberg đã trình bày tầm nhìn của Meta về Metaverse như một bước kế tiếp của internet di động, một tập hợp các không gian kỹ thuật số kết nối, nơi người dùng có thể tương tác, làm việc và giải trí trong môi trường ảo. Meta đã giới thiệu Horizon Home, một không gian ảo cá nhân hóa, mặc dù việc phát triển Metaverse đối mặt với nhiều thách thức nhưng Meta cam kết đầu tư và phát triển để biến tầm nhìn này thành hiện thực.

Ứng dụng

Theo (Xinli Zhang và cộng sự, 2022) thì trong lĩnh vực giáo dục, Metaverse ứng dụng được nhiều, tạo cá cơ hội hỗ trợ, nâng cao trải nghiệm học tập. Các công nghệ như thực tế tăng cường (AR), thực tế ảo (VR), và thực tế hỗn hợp (MR) đã được sử dụng để tạo ra các môi trường học tập nhập vai, nơi người học có thể tương tác thông qua hình đại diện. Metaverse tạo ra các lớp học ảo nơi sinh viên có thể tương tác với nội dung học tập và giảng viên trong không gian ba chiều, giúp tăng cường sự hiểu biết và ghi nhớ. Hay theo nghiên cứu của (Almahasees và cộng sự, 2021) thì trong thời kì đại dịch Covid-19 bùng nổ, việc học tập từ xa qua màn hình trên các nền tảng hội nghị trực tuyến như Zoom, Google Meet hay Microsoft Teams đã trở thành tiêu chuẩn phổ biến.

Theo (R. Chengoden và cộng sự, 2023), ứng dụng của Metaverse còn áp dụng vào lĩnh vực y tế và chăm sóc sức khoẻ. Metaverse cung cấp môi trường mô phỏng 3D, giúp sinh viên và chuyên gia y tế thực hành kỹ năng lâm sàng trong các tình huống giả lập an toàn. Thông qua Metaverse, bác sĩ có thể tư vấn và điều trị từ xa cho các bệnh nhân, cải thiện chất lượng dịch vụ y tế từ xa. Bên cạnh đó còn hỗ trợ theo dõi và quản lý bệnh nhân thông qua các thiết bị đeo và cảm biến, từ đó dữ liệu được cập nhật liên tục để bác sĩ có thể điều trị kịp thời.

Theo nghiên cứu của (Büchel & Spinler, 2024) thì trong lĩnh vực kinh doanh, việc áp dụng Metaverse giúp các doanh nghiệp vừa và nhỏ (SME) nâng cao khả năng tiếp thị bằng cách mở rộng kênh bán hàng, cá nhân hóa chiến lược marketing và tiếp cận nhiều khách hàng hơn. Đồng thời, nó cũng hỗ trợ doanh nghiệp hiểu rõ thị trường hơn, tập trung vào quan hệ khách hàng, nghiên cứu thị trường và tăng cường khả năng quản lý đa lĩnh vực.

Hay theo (V. Ojha, 2023) thì Metaverse còn có tác động tới lĩnh vực truyền thông và giải trí. Với sự kết hợp thực tế ảo, blockchain và trí tuệ nhân tạo, Metaverse đã tạo ra những hình thức kể chuyện nhập vai mới và mang đến trải nghiệm tương tác đa chiều trong trò chơi, các buổi hòa nhạc và sự kiện trực tiếp ảo. Người dùng có thể tham gia vào những thế giới ảo sống động, hòa mình vào các câu chuyện theo cách chưa từng có trước đây. Metaverse không chỉ thay đổi cách chúng ta tiêu thụ nội dung mà còn định hình lại mối quan hệ giữa thương hiệu, người sáng tạo và khán giả trong kỷ nguyên số.

Ngoài ra, theo bài nghiên cứu của (M.Uddin và cộng sự, 2023) thì Metaverse đã mở ra nhiều trải nghiệm xã hội mới, từ giao tiếp, mua sắm, hẹn hò đến du lịch và thậm

chí cả du hành thời gian – không gian. Nó có thể giúp giải quyết các vấn đề xã hội phức tạp, ảnh hưởng đến hành vi doanh nghiệp và thúc đẩy sự chuyển đổi xã hội.

Gần đây, với sự phát triển nhanh chóng các công nghệ tiên tiến như trí tuệ nhân tạo (AI), học máy (ML), blockchain, mạng 5G, và Internet vạn vật (IoT), dữ liệu lớn (big data), điện toán đám mây (cloud computing), điện toán phân tán (distributed computing) và nhiều công nghệ tiên tiến khác đã mở rộng phạm vi ứng dụng của Metaverse.

Bên cạnh những ứng dụng phát triển đầy tiềm năng trên, theo (Z.Allam và cộng sự, 2022), Metaverse còn mang lại tiềm năng lớn trong việc thúc đẩy sự bền vững môi trường. Metaverse góp phần cắt giảm đáng kể lượng khí thải nhà kính, giảm áp lực lên hạ tầng giao thông và hạn chế gây ô nhiễm môi trường bằng việc giảm nhu cầu di chuyển vật lí. Các hoạt động như hội họp, sự kiện, du lịch hay mua sắm có thể diễn ra trong không gian ảo, giúp tối ưu hóa tài nguyên và từ đó giảm thiểu tác động tiêu cực đến hệ sinh thái. Đây được xem là một bước tiến quan trọng trong chiến lược phát triển bền vững của các đô thị thông minh trong tương lai.

1.1.1.2. Đặc trưng người dùng

Theo (Safari và cộng sự, 2019) thì khai thác hành vi người dùng trên mạng xã hội là quá trình đại diện, phân tích và trích xuất các mẫu hoạt động và hành vi từ dữ liệu hành vi của người dùng trên mạng xã hội. Nó có thể là các hành vi như tương tác bằng icon cảm xúc, bình luận, chia sẻ bài viết của người dùng khác hay các hành động đăng tải bài viết của chính cá nhân người dùng. Việc khai thác hành vi người dùng là để tìm ra thói quen, sở thích, sự quan tâm, mong muốn của người dùng dựa trên các hành vi, hành động họ thể hiện và là những thông tin có thể thu thập được nhằm phục vụ người dùng theo đúng nhu cầu của họ.

Trong nghiên cứu này, đặc trưng người dùng được hiểu là các thông tin về thói quen, sở thích, sự quan tâm của người dùng tiềm ẩm dưới dữ liệu mà ở đây là hình ảnh được tìm ra sau khi thu thập và phân tích hành vi, hoạt động của họ trong môi trường Metaverse bằng các phương pháp, kỹ thuật học máy, các thuật toán về gán nhãn để dự đoán chính xác nhu cầu hiện tại của họ nhằm mục đích nâng cao hiệu quả khi tiếp thị, quảng cáo sản phẩm đến người dùng trong môi trường ảo hóa Metaverse.

Dựa trên các tài liệu nghiên cứu được nhóm tác giả tham khảo có thể rút ra được một số nhóm đặc trưng quan trọng về người dùng trong Metaverse như sau:

- Đặc trưng về nhân khẩu học
- Đặc trưng về hành vi người dùng
- Đặc trưng về sở thích người dùng
- Đặc trưng về cảm xúc người dùng
- Đặc trưng theo ngữ cảnh người dùng

1.1.1.3. Cá nhân hóa quảng cáo

Định nghĩa

Theo bài nghiên cứu của (Trang P.Tran, 2017) thì khái niệm cá nhân hoá xuất hiện từ cuối thế kỉ XIX (Ross, 1992) và thường được đề cập trong bối cảnh phân khúc khách hàng, nhắm vào mục tiêu khách hàng và lập hồ sơ khách hàng, trong khi một số nhà nghiên cứu khác sử dụng thuật ngữ này trong chiến lược kết hợp giữa sản xuất hàng loạt và cá nhân hoá sản phẩm và chiến lược tiếp thị từng sản phẩm, dịch vụ cho từng cá nhân (Petrison et al., 1997). Trong thực tế, cá nhân hoá được áp dụng với ý nghĩa rộng hơn, tổng quát hơn (Wind và Rangaswamy, 2001).

Trong bài nghiên cứu của (Jari Vesanen, 2007), tác giả đã tổng hợp và phân tích các định nghĩa về cá nhân hoá quảng cáo theo nhiều tác giả định nghĩa. Tiêu biểu trong số đó là theo (Imhoff, Loftis & Geiger, 2001) thì cá nhân hoá là khả năng của một công ty trong việc nhận diện và đối xử với khách hàng như những cá nhân riêng biệt, thông qua tin nhắn cá nhân, quảng cáo biểu ngữ được nhắm mục tiêu cụ thể, ưu đãi đặc biệt trên hoá đơn hoặc các giao dịch cá nhân khác". Hay theo góc nhìn dựa trên công nghệ, được Personalization Consortium (2005) định nghĩa như sau "Cá nhân hóa là việc sử dụng công nghệ và thông tin khách hàng để điều chỉnh các tương tác thương mại điện tử giữa doanh nghiệp và từng khách hàng. Dựa trên thông tin đã thu thập trước đó hoặc được cung cấp theo thời gian thực, quá trình trao đổi giữa hai bên sẽ được điều chỉnh để phù hợp với nhu cầu mà khách hàng đã nêu ra, cũng như nhu cầu mà doanh nghiệp nhận thấy dựa trên dữ liệu khách hàng hiện có."

Vậy từ việc tìm hiểu nhiều ý kiến về định nghĩa của thuật ngữ cá nhân hoá, ta có thể hiểu thuật ngữ "Cá nhân hóa quảng cáo" là quá trình công cụ dựa trên thông tin thu thập được của khách hàng như hành vi, sở thích, nhu cầu, vị trí địa lý và thông tin về nhân khẩu học mà doanh nghiệp từ đó thực hiện điều chỉnh nội dung quảng cáo, chiến dịch quảng bá cũng như thông điệp nhằm phù hợp với từng cá nhân. Theo đó, quảng

cáo được tối ưu hoá, dự đoán được các nhu cầu tiềm ẩn, cải thiện trải nghiệm người dùng và nâng cao hiệu quả tiếp thị.

Vai trò

Theo (Ostrom và cộng sự, 2015), cá nhân hoá quảng cáo giúp nâng cao trải nghiệm người dùng dựa trên việc các cung các cấp đề xuất, gợi ý phù hợp với sở thích và nhu cầu cá nhân của họ. Cùng với sự phát triển của AI, của thời đại số, việc đề xuất sản phẩm dựa trên lịch sử tìm kiếm, các dấu vết của người dùng trên mạng giúp cá nhân hoá trải nghiệm mua sắm cho từng người dùng. Nhờ đó có tác động tích cực đến thái độ của người dùng đối với chức năng AI trên các sàn giao dịch thương mại điện tử.

Cá nhân hoá quảng cáo mang lại nhiều lợi ích cho doanh nghiệp, công ty. Lợi ích lớn nhất là nó có thể giúp tăng doanh thu và tối ưu hoá tỷ lệ chuyển đổi. Theo tổng hợp của (Trường doanh nhân HBR, 2024) thì theo báo cáo của Criteo Việt Nam năm 2023, doanh nghiệp Việt Nam áp dụng cá nhân hóa trải nghiệm khách hàng có tỷ lệ chuyển đổi cao hơn 75% so với doanh nghiệp không áp dụng và triển khai cá nhân hóa có thể giúp doanh nghiệp Việt Nam tăng doanh thu trung bình 12%. Một nghiên cứu của Epsilon được thực hiện vào năm 2019 với hơn 1.000 người tiêu dùng tại Hoa Kỳ đã cho thấy 80% khách hàng có khả năng mua hàng cao hơn từ thương hiệu cung cấp trải nghiệm cá nhân hóa và 60% khách hàng sẵn sàng chi trả nhiều hơn cho các sản phẩm và dịch vụ được cá nhân hóa.

Vai trò khác của cá nhân hoá là giúp xây dựng mối quan hệ bền chặt với khách hàng, hay nói cách khác là giữ chân khách hàng hiệu quả. Theo kết quả nghiên cứu của SuperOffice mà (Trường doanh nhân HBR, 2024) tìm hiểu, có đến 60% khách hàng sẽ quay lại mua hàng từ một thương hiệu cung cấp trải nghiệm được cá nhân hóa. Hay theo nghiên cứu của Deloitte, cứ 1 trên 5 khách hàng sẵn sàng chi thêm 20% để trải nghiệm một sản phẩm hoặc dịch vụ cá nhân hoá. Có tới 48% khách hàng sẵn sàng chờ lâu hơn cho một sản phẩm hoặc dịch vụ cá nhân hoá được cho ra mắt.

Cá nhân hoá quảng cáo giúp các công ty có thể nổi bật hơn so với đối thủ cạnh tranh. Trong thị trường cạnh tranh căng thẳng, việc cá nhân hoá giúp thương hiệu tạo sự khác biệt, nổi bật so với các đối thủ trên thị trường. Nghiên cứu của Brain & Company chỉ ra rằng có tới 22% người tiêu dùng sẽ mua sắm thường xuyên với thương hiệu cung cấp các sản phẩm cá nhân hoá.

Ngoài ra, cá nhân hóa giúp tiết kiếm chi phí quảng cáo đáng kể. Việc tập trung quảng cáo những sản phẩm nhất định vào các khách hàng tiềm năng mà không quảng cáo phổ biến ngập tràn trên toàn bộ khách hàng, điều đó là giảm lãng phí, tối ưu hoá ngân sách của doanh nghiệp đồng thời tăng hiệu quả chiến dịch quảng cáo. Cuối cùng, từ việc khách hàng có trải nghiệm tích cực với doanh nghiệp, doanh nghiệp nâng cao được nhận thức và giá trị thương hiệu của mình.

1.1.2. Các công nghệ, kỹ thuật liên quan đến đề tài

1.1.2.1. Khái niệm học bán giám sát

Học bán giám sát (Semi-Supervised Learning - SSL) một nhánh của học máy, tập trung vào việc sử dụng cả dữ liệu có nhãn và không có nhãn để thực hiện các nhiệm vụ học tập nhất định. Về mặt khái niệm, học bán giám sát nằm giữa học có giám sát (supervised learning) và học không giám sát (unsupervised learning), cho phép tận dụng một lượng lớn dữ liệu không có nhãn, kết hợp với tập dữ liệu có nhãn thường nhỏ hơn (J.E.Engelen & H.H.Hoos, 2019). Theo của (Xiangli Yang và cộng sự, 2021) thì SSL là một phương pháp học máy kết hợp cả dữ liệu có nhãn và dữ liệu không nhãn để xây dựng mô hình. Mục tiêu của SSL là cải thiện hiệu suất học tập bằng cách sử dụng thêm các mẫu không nhãn so với các thuật toán học có giám sát chỉ sử dụng dữ liệu có nhãn. Phương pháp này giúp khám phá các mẫu tiềm ẩn từ các ví dụ không nhãn, giảm bớt nhu cầu về một lượng lớn nhãn.

1.1.2.2. Các phương pháp học bán giám sát

a. Thuật toán Logistic Regression

Khái niệm

Thuật toán Logistic Regression - Hồi quy logistic là một thuật toán học máy có giám sát được sử dụng cho các nhiệm vụ phân loại trong đó mục tiêu là dự đoán xác suất một cá thể thuộc về một lớp nhất định hay không. Nó một thuật toán thống kê phân tích mối quan hệ giữa hai yếu tố dữ liệu.

Hồi quy logistic được chia thành ba loại:

1. Nhị thức: Dự đoán một đối tượng thuộc một trong hai nhóm đúng hoặc sai, thắng hoặc thua, tích cực hoặc tiêu cực, dương tính hoặc âm tính.
2. Đa thức: Dự đoán một đối tượng có thể có 3 hoặc nhiều loại biến phụ thuộc không theo thứ tự có thể có như “ẩm thực” hoặc “du lịch” hoặc “thời trang”.

3. Thứ tự: Dự đoán một đối tượng có thể có 3 hoặc nhiều loại biến phụ thuộc có trật tự như "không quan tâm" hoặc "ít quan tâm" hoặc "quan tâm nhiều".

Với nhị thức, hồi quy logistic sử dụng hàm Sigmoid

+ Hàm xác suất mô tả theo hàm Sigmoid:

$$P(Y=1|X) = \sigma(z) = \frac{1}{1+e^{-z}}$$

Trong đó:

- $Y \in \{0,1\}$.
- $X = x_1 + x_2 + ... + x_n$ (biến đầu vào đặc trưng cho một mẫu).
- $z = w_0 + w_1X_1 + w_2X_2 + ... + w_nX_n$ (tổ hợp tuyến tính của các đặc trưng).
- $\sigma(z)$ là hàm Sigmoid, đưa đầu ra về khoảng (0,1).

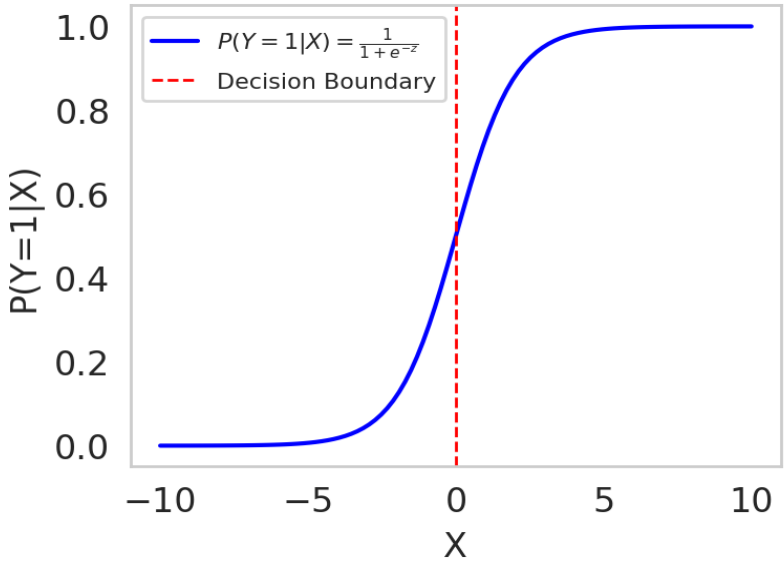

Hình 1. Hồi quy Logistic nhị thức (Sigmoid)

+ Hàm dự đoán nhãn dựa trên ngưỡng 0.5:

$$\hat{Y} = \begin{cases} 1, & \text{nếu } P(Y=1 \mid X) \geq 0.5 \\ 0, & \text{nếu } P(Y=1 \mid X) < 0.5 \end{cases}$$

+ Hàm mất mát Cross - Entropy (Log Loss) đo độ chênh lệch giữa giá trị thực tế và giá trị dự đoán:

$$L = -\frac{1}{m}\sum_{i=1}^{m}\left[y_i \log P(y_i|x_i) + (1-y_i)\log(1-P(y_i|x_i))\right]$$

Trong đó:

- m: số lượng mẫu dữ liệu trong tập huấn luyện.

- y_i: giá trị thực tế của đầu ra thứ i
- $P(y_i \mid x_i)$: xác suất dự đoán thuộc lớp 1 của mô hình cho đầu vào thứ i

Nếu:

- $y_i = 1$ thì $P(y_i \mid x_i)$ càng gần 1 → mất mát lớn.
- $y_i = 0$ thì $P(y_i \mid x_i)$ càng gần 0 → mất mát nhỏ.

Với đa thức, hồi quy logistic sử dụng hàm Softmax

+ Hàm Softmax tính xác suất của lớp k:

$$P(Y = k \mid X) = \frac{e^{z_k}}{\sum_{j=1}^{K} e^{z_j}}, \quad \text{với } z_k = w_k^T X + b_k$$

Trong đó:

- $Y \in \{1, 2, \ldots, k\}$.
- $X = x_1 + x_2 + \ldots + x_n$ (biến đầu vào đặc trưng cho một mẫu).
- $\sum_{j=1}^{K} e^{z_j}$: Tổng tất cả giá trị để e^{z_j} chuẩn hóa xác suất.

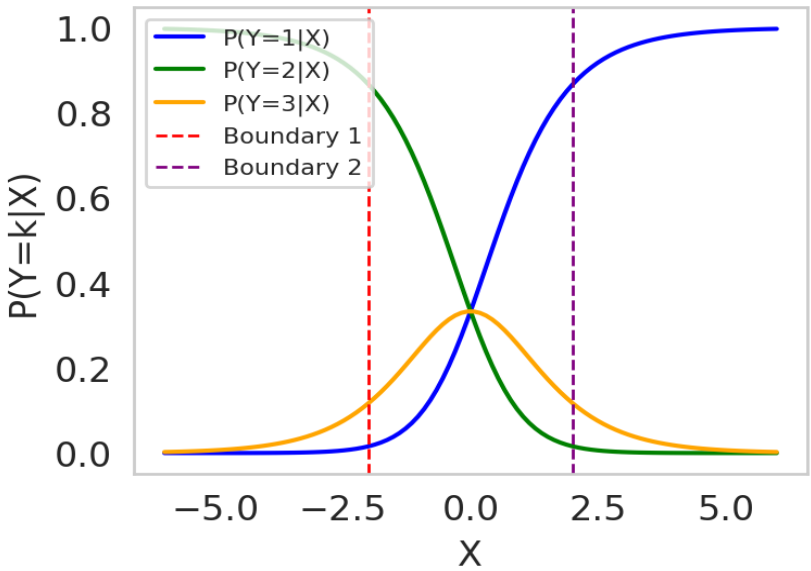

Hình 2. Hồi quy Logistic đa thức (Softmax)

+ Hàm mất mát Cross - Entropy Loss:

$$L = -\frac{1}{m} \sum_{i=1}^{m} \sum_{k=1}^{K} y_{ik} \log P(Y = k \mid x_i)$$

Trong đó:

- m: số lượng mẫu dữ liệu trong tập huấn luyện.
- K: tổng số lớp (nhãn) trong bài toán phân loại.
- y_{ik} :giá trị nhãn thực tế của mẫu x_i đối với lớp k.

Nếu:

- $x_i \in k \rightarrow y_{ik} = 1$.
- $x_i \notin k \rightarrow y_{ik} = 0$.

Với thứ tự, hồi quy logistic sử dụng Cumulative Logit (Logit tích lũy)

+ Xác suất tích lũy:

$$P(Y \leq k \mid X) = \frac{e^{\theta_k - w^T X}}{1 + e^{\theta_k - w^T X}}$$

Trong đó:

- $Y \in \{1, 2, \ldots, K - 1\}$.
- W^T X: tổng trọng số của đầu vào tính bằng:

  $z = w_1X_1 + w_2X_2 + \ldots + w_nX_n$
- $w = (w_1, w_2, \ldots, w_n)$ là vector trọng số.
- $x = (x_1, x_2, \ldots, x_n)$ là vector đầu vào.
- θ_k : Ngưỡng cho lớp thứ k, xác định ranh giới giữa các lớp liên tiếp.

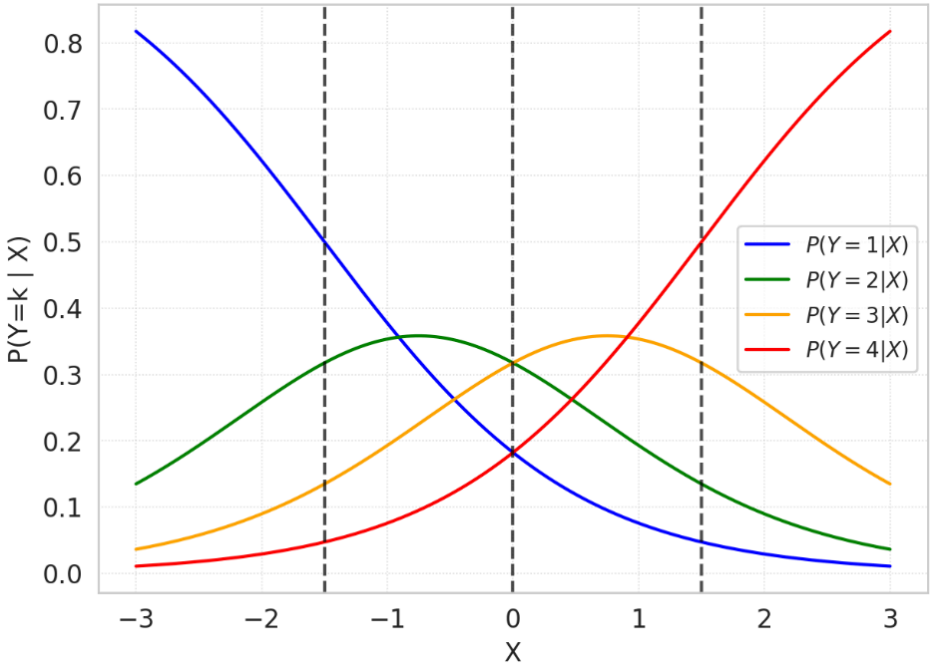

Hình 3. Hồi quy Logistic thứ tự (Cumulative Logit)

+ Logit tích lũy:

$$\log\left(\frac{P(Y \leq k \mid X)}{1 - P(Y \leq k \mid X)}\right) = \theta_k - w^T X$$

+ Xác suất từng lớp:

$$P(Y = k \mid X) = P(Y \leq k \mid X) - P(Y \leq k - 1 \mid X)$$

+ Hàm mất mát log-likelihood:

$$L = -\frac{1}{m}\sum_{i=1}^{m}\sum_{k=1}^{K-1} y_{ik}\log P(Y \le k|x_i) + (1-y_{ik})\log(1-P(Y \le k|x_i))$$

Trong đó:

- m: số lượng mẫu trong tập dữ liệu.
- K: tổng số lớp (nhãn) trong bài toán.
- y_{ik} : nhãn phụ của dữ liệu (biến nhị phân) xác định liệu mẫu i có thuộc lớp k hay không.

Nếu:

- $x_i \in k \rightarrow y_{ik} = 1$.
- $x_i \notin k \rightarrow y_{ik} = 0$.

Ưu, nhược điểm

Logistic Regression là thuật toán học máy đơn giản và dễ thực hiện, mang lại hiệu quả đào tạo cao trong nhiều trường hợp. Vì ưu thế này mà việc đào tạo một mô hình với thuật toán này không đòi hỏi độ tính toán cao. Các tham số dự đoán (trọng số được đào tạo) đưa ra suy luận về tầm quan trọng của từng tính năng. Hướng liên kết là tích cực hoặc tiêu cực cũng được đưa ra vậy nên có thể sử dụng hồi quy logistic để tìm ra mối quan hệ giữa các tính năng. Thuật toán này cho phép các mô hình được cập nhật dễ dàng để phản ánh dữ liệu mới, không giống như cây quyết định hoặc máy vectơ hỗ trợ. Việc cập nhật có thể được thực hiện bằng cách sử dụng độ dốc ngẫu nhiên. Logistic Regression xuất ra xác suất được hiệu chỉnh tốt cùng với kết quả phân loại vượt trội hơn so với các mô hình chỉ đưa ra phân loại cuối cùng là kết quả. Ngoài ra, Logistic Regression còn được sử dụng như một mô hình điểm chuẩn để đo lường hiệu suất bởi sự nhanh chóng và dễ dàng thực hiện của nó. Được chứng minh là rất có hiệu quả khi tập dữ liệu có các tính năng có thể tách tuyến tính, trong số kết quả được tìm thấy sau khi đào tạo mô hình hồi quy logistic cũng được tìm thấy là có khả năng giải thích cao.

Logistic Regression là mô hình phân tích thống kê cố gắng dự đoán kết quả xác suất chính xác dựa trên các đặc điểm độc lập. Ở các bộ dữ liệu chiều cao, nó có thể dẫn đến việc mô hình quá phù hợp trên tập huấn luyện tức là phóng đại độ chính xác của các dự đoán trên tập huấn luyện và do đó mô hình có thể không dự đoán được kết quả chính xác trên tập thử nghiệm. Điều này thường xảy ra trong trường hợp mô hình được đào tạo trên dữ liệu đào tạo nhỏ với nhiều tính năng vậy nên trên các tập dữ liệu chiều cao,

các kỹ thuật chính quy hóa được xem xét để tránh quá khớp nhưng điều này lại làm cho mô hình trở nên phức tạp. Các yếu tố chính quy hóa rất cao có thể dẫn đến mô hình không phù hợp với dữ liệu đào tạo. Các vấn đề phi tuyến tính không thể được giải quyết bằng hồi quy logistic vì nó có bề mặt quyết định tuyến tính. Dữ liệu có thể tách rời hiếm khi được tìm thấy trong các tình huống trong thế giới thực. Hạn chế chính của Logistic Regression là giả định về tuyến tính giữa biến phụ thuộc và biến độc lập, ngoài ra còn yêu cầu một bộ dữ liệu lớn và cũng có đủ ví dụ đào tạo cho tất cả các danh mục mà nó cần xác định đồng thời cũng gặp khó khăn trong việc nắm bắt các mối quan hệ phức tạp khi sử dụng Logistic Regression.

Ứng dụng

Là một thuật toán về phân loại, Logistic Regression được áp dụng rộng rãi vào các bài toán ở nhiều lĩnh vực khác nhau. Trong lĩnh vực marketing và thương mại, nó giúp dự đoán sự rời bỏ của khách hàng, phân loại email bị spam hay không. Trong lĩnh vực truyền thông xã hội, nó giúp phân tích các cảm xúc của người dùng như tiêu cực, trung lập hay tích cực, giúp phân loại ra các chủ đề dựa trên đặc điểm người dùng và có thể nhận diện đối tượng tỏng ảnh, nó cũng được dùng để phát hiện ra các tài khoản giả mạo người dùng hay không. Đặc biệt, trong lĩnh vực ngân hàng và y tế nó được áp dụng vào bài toán chấm điểm tín dụng, phát hiện nợ xấu của khách hàng, phát hiện giao dịch không an toàn hay được dùng để chuẩn đoán ung thư giúp phát sớm các nguy cơ gây bệnh để có cách khắc phục và điều trị.

b. Thuật toán Decision Tree

Khái niệm

Theo Sách Business intelligence and data mining (Maheshwari, 2015) định nghĩa theo mô tả bản chất và cách thức hoạt động, Decision Tree hay cây quyết định là một cấu trúc phân nhánh theo hệ thống thứ bậc, giúp đưa ra các quyết định bằng cách đặt ra một loạt câu hỏi theo trình tự nhất định. Là một công cụ hỗ trợ ra quyết định và là một trong những kỹ thuật phổ biến trong phân loại dữ liệu.

Theo trang IBM, cây quyết định là một thuật toán có giám sát phi tham số, được sử dụng cho cả nhiệm vụ phân loại và hồi quy. Nó có cấu trúc phân cấp dạng cây, bao gồm một nút gốc (root node), các nhánh (branches), nút bên trong (internal nodes) và nút lá (leaf nodes).

Outlook	Temp.	Humidity	Windy	Play Golf
Rainy	Hot	High	False	No
Rainy	Hot	High	True	No
Overcast	Hot	High	False	Yes
Sunny	Mild	High	False	Yes
Sunny	Cool	Normal	False	Yes
Sunny	Cool	Normal	True	No
Overcast	Cool	Normal	True	Yes
Rainy	Mild	High	False	No
Rainy	Cool	Normal	False	Yes
Sunny	Mild	Normal	False	Yes
Rainy	Mild	Normal	True	Yes
Overcast	Mild	High	True	Yes
Overcast	Hot	Normal	False	Yes
Sunny	Mild	High	True	No

Hình 4. Ví dụ về Decision Tree (Cây quyết định)

Nguồn: Saedsayad.com

Decision Tree có ba tiêu chí đánh giá phổ biến để xác định cách thức chia nhánh tại mỗi nút trong cây quyết định. Đó là least error, Gini coefficient (Gini index) và Information gain.

Với tiêu chí đánh giá least error, root node và các leaf nodes (nút lá) được quyết định là những thuộc tính có số lỗi thấp nhất hay nói cách khác là có độ chính xác cao nhất.

Xây dựng cây quyết định dựa trên Gini coefficient, ta chọn thuộc tính mà tại đó giá trị Gini thấp nhất. Vì giá trị Gini càng thấp, dữ liệu sau khi chia sẽ càng thuần khiết, tăng độ chính xác của cây quyết định.

$$Gini(S) = 1 - \sum p_i^2$$

Trong đó: p_i là xác suất của lớp i trong tập dữ liệu S

Information gain dựa trên sự giảm của hàm Entropy khi tập dữ liệu được phân chia trên một thuộc tính. Để xây dựng cây quyết định, phải tìm tất cả thuộc tính mà trả về Information gain cao nhất làm nodes. Cách tính Information Gain như sau, trước tiên ta tính Entropy trước:

$$Entropy(Nv) = \sum_{i=1}^{M} -p_i \log_2 p_i$$

Trong đó:

- Entropy (Nv): Độ hỗn loạn Entropy của tập dữ liệu S

- $\sum$: Ký hiệu tổng, biểu thị sự cộng dồn của tất cả các lớp hoặc danh mục i có trong tập dữ liệu S
- p_i : Xác suất của một điểm dữ liệu thuộc về một lớp hoặc danh mục i cụ thể

$$Gain(Nv,A) = Entropy(Nv) - \sum_{v \epsilon Values(A)} \frac{|Nv_v|}{|Nv|} Entropy(Nv_v)$$

Trong đó:

- Gain (Nv, A): lượng thông tin thu được khi chia nút Nv theo thuộc tính A
- Entropy(Nv): Độ hỗn loạn (Entropy) của toàn bộ tập dữ liệu.
- $\sum$: Tổng của tất cả các giá trị có thể có của thuộc tính A.
- Nv_v: Các tập con được tạo ra khi tập dữ liệu Nv được chia dựa trên thuộc tính A.
- $|Nv_v|$ và |Nv|: Số lượng mẫu trong tập con Nvv và số lượng mẫu trong tập dữ liệu gốc Nv.
- Entropy(Nv_v): Độ hỗn loạn (Entropy) của từng tập con Nv_v

Ưu, nhược điểm

Cây quyết định là một mô hình đơn giản, dễ hiểu vì có cấu trúc trực quan, dễ hình dung như một sơ đồ luồng, giúp người dùng dễ dàng theo dõi cách đưa ra quyết định. Có tính linh hoạt, có thể áp dụng cho nhiều loại bài toán khác nhau, bao gồm cả phân loại (classification) và hồi quy (regression). Không giống các mô hình học máy khác, cây quyết định không yêu cầu chuẩn hoá dữ liệu trước khi đưa vào huấn luyện mô hình, không cần đưa về cùng một thang đo, giúp tiết kiệm thời gian tiền xử lý. Bên cạnh đó, cây quyết định có thể xử lý tốt các mối quan hệ phi tuyến tính, có khả năng phát hiện và khai thác các mối quan hệ phi tuyến tính giữa các biến đặc trưng và biến mục tiêu.

Tuy nhiên, cây quyết định cũng tồn tại một số nhược điểm. Cây quyết định dễ bị overfitting, nó học chi tiết, bao gồm cả những điểm nhiễu không quan trọng từ dữ liệu huấn luyện, vì vậy có thể hoạt động kém trên dữ liệu mới. Trong dữ liệu đầu vào chỉ có một thay đổi nhỏ cũng có thể dẫn đến sự khác biệt lớn trong cấu trúc của cây quyết định, làm cho mô hình thiếu sự ổn định. Ngoài ra, khi một thuộc tính có quá nhiều danh mục, mô hình có thể tập trung quá mức vào thuộc tính đó, có xu hướng thiên vị các thuộc tính có nhiều mức giá trị, trong khi bỏ qua các yếu tố quan trọng khác, dẫn đến giảm độ chính xác trong dự đoán.

Ứng dụng

Cây quyết định có nhiều ứng dụng thực tế trong nhiều lĩnh vực khác nhau. Trong lĩnh vực y tế, cây quyết định giúp chuẩn đoán y khoa, bệnh lý của bệnh nhân. Các nhà cung cấp dịch vụ y tế sử dụng cây quyết định để dự đoán bệnh tiểu đường dựa trên kết quả xét nghiệm lâm sàng dựa vào các đặc trưng đầu vào gồm mức đường huyết, chỉ số IBM và huyết áp. Cây quyết định phân loại bệnh nhân thành các nhóm có hoặc không bị mắc bệnh tiểu đường, từ đó hỗ trợ bác sĩ trong việc chuẩn đoán chính xác bệnh lý. Bên cạnh lĩnh vực y tế, cây quyết định còn ứng dụng vào giáo dục. Nó có thể dự đoán kết quả thi, học sinh có đậu hay không dựa trên thói quen học tập với các dữ liệu đầu vào cần thiết là tỷ lệ chuyên cần, thời gian học bài và điểm số trước đó. Cây quyết định giúp xác định học sinh có nguy cơ trượt, giúp giáo viên hay gia đình có thể hỗ trợ kịp thời. Hơn thế nữa, các tổ chức tài chính cũng ứng dụng cây quyết định để đánh giá xem có phê duyệt một khoản vay dựa trên hồ sơ khách hàng hay không. Với các dữ liệu đầu vào là thu nhập, điểm tín dụng, tình trạng việc làm và lịch sử vay vốn để xây dựng mô hình cây quyết định, từ đó giúp ngân hàng đưa ra sự lựa chọn nhanh chóng, đáng tin cậy. Ngoài ra, cây quyết định cũng được ứng dụng vào xây dựng mô hình dự đoán tự động, nhiều ứng dụng trong machine learning, khai phá dữ liệu và thống kê.

c. Thuật toán Random Forest

Khái niệm

Random Forest (Breiman, 2001) là một phương pháp thống kê phi tham số xử lý các vấn đề phân loại và hồi quy. RF là một trong những phương pháp chính được sử dụng trong học máy để giải quyết vấn đề dự đoán. Hiệu suất dự đoán tuyệt vời cũng như tính linh hoạt của chúng, áp đặt những hạn chế nhẹ về bản chất của dữ liệu, dẫn đến việc sử dụng chuyên sâu trong các lĩnh vực ứng dụng khác nhau.

Theo IBM, Random Forest là một phần mở rộng của phương pháp đóng bao bởi nó sử dụng cả tính bao và tính năng ngẫu nhiên để tạo ra một khu rừng cây quyết định không tương quan. Tính ngẫu nhiên của tính năng, còn được gọi là đóng bao tính năng hoặc phương pháp không gian con ngẫu nhiên. Các thuật toán rừng ngẫu nhiên có ba siêu tham số chính, cần được thiết lập trước khi đào tạo. Nó bao gồm kích thước nút, số lượng cây và số lượng tính năng được lấy mẫu. Từ đó, bộ phân loại rừng ngẫu nhiên có thể được sử dụng để giải quyết các vấn đề hồi quy hoặc phân loại.

Thuật toán được tạo thành từ một tập hợp các cây quyết định và mỗi cây trong tập hợp bao gồm một mẫu dữ liệu được rút ra từ một tập huấn luyện với sự thay thế, được gọi là mẫu bootstrap. Trong số mẫu đào tạo đó, một phần ba trong số đó được đặt làm dữ liệu thử nghiệm, được gọi là mẫu out-of-bag (oob), mà chúng ta sẽ quay lại sau. Một trường hợp ngẫu nhiên khác sau đó được đưa vào thông qua tính năng, thêm sự đa dạng cho tập dữ liệu và giảm mối tương quan giữa các cây quyết định. Tùy thuộc vào loại vấn đề, việc xác định dự đoán sẽ khác nhau. Đối với nhiệm vụ hồi quy, các cây quyết định riêng lẻ sẽ được tính trung bình và đối với nhiệm vụ phân loại, phiếu bầu đa số — tức là biến phân loại thường xuyên nhất — sẽ mang lại lớp dự đoán. Cuối cùng, mẫu oob sau đó được sử dụng để xác nhận chéo, hoàn thiện dự đoán đó.

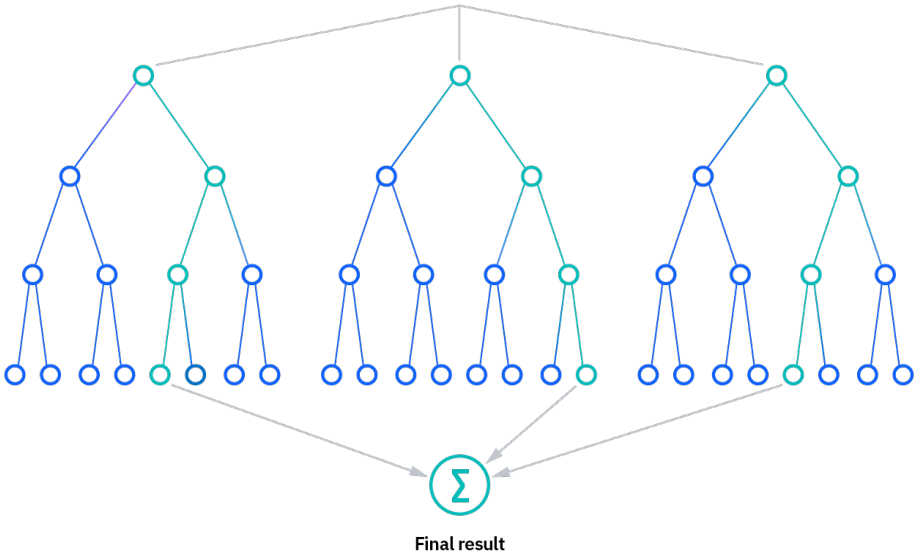

Hình 5. Mô hình Random Forest

Nguồn: IBM

Ưu, nhược điểm

Khi Random Forest sử dụng nhiều cây quyết định, bộ phân loại sẽ không phù hợp quá mức với mô hình vì tính trung bình của các cây không tương quan sẽ làm giảm sai số dự đoán và phương sai tổng thể từ đó sẽ làm giảm nguy cơ quá khớp, phù hợp với mô hình. Random Forest mang tính linh hoạt cao vừa có thể cung cấp dự đoán chính xác cao với bộ dữ liệu lớn vừa có thể xử lý tốt dữ liệu bị thiếu mà không ảnh hưởng đến độ chính xác ngoài ra thuật toán cũng không yêu cầu chuẩn hóa hoặc tiêu chuẩn hóa trên tập dữ liệu và nó còn giúp dễ dàng đánh giá tầm quan trọng của biến hoặc đóng góp cho mô hình.

Random Forest có thể xử lý các tập dữ liệu lớn, cung cấp các dự đoán chính xác hơn bởi vậy nên xử lý dữ liệu chậm sẽ bị chậm do đang tính toán dữ liệu cho từng cây quyết định riêng lẻ, điều này dẫn đến việc gây tốn thời gian cho quy trình. Thuật toán xử lý các tập dữ liệu lớn hơn, sẽ cần nhiều tài nguyên hơn để lưu trữ dữ liệu đó dẫn đến đòi hỏi về mặt tài nguyên. Gặp khó khăn khi giải thích mô hình so với các mô hình khác đơn giản như cây quyết định bởi dự đoán của nó là có từ các cây quyết định kết hợp lại với nhau phức tạp hơn nhiều so với sự riêng lẻ dễ diễn giải của một cây quyết định.

Ứng dụng

Random Forest là một thuật toán được ưa chuộng hơn những thuật toán khác vì nó giúp giảm thời gian dành cho các tác vụ quản lý dữ liệu và tiền xử lý. Trong lĩnh vực ngân hàng, nó có thể được sử dụng để đánh giá những khách hàng có rủi ro tín dụng cao, xác định các giao dịch gian lận có khả năng và các vấn đề về giá quyền chọn. Trong y học, các mô hình rừng ngẫu nhiên được xây dựng để xác định và phân loại bệnh dựa trên một loạt các triệu chứng. Ngoài ra, nó còn được sử dụng để lấy dự đoán từ hồ sơ sức khỏe điện tử của bệnh nhân, thường là một tệp chứa một loạt các điểm dữ liệu về bệnh nhân đó. Một mô hình rừng ngẫu nhiên có thể được đào tạo về các triệu chứng của bệnh nhân trong quá khứ và sức khỏe hoặc sự tiến triển của bệnh sau này và khái quát hóa cho bệnh nhân mới. Trong thương mại điện tử, nó có thể được sử dụng cho các công cụ đề xuất cho mục đích bán chéo.

d. Thuật toán Support Vector Machine (SVM)

Khái niệm

Thuật toán Support Vector Machines (SVM) được phát triển bởi (Cortes & Vapnik, 1995) để giải quyết bài toán phân loại nhị phân. SVM là một thuật toán nhận dạng mẫu đã được sử dụng để phân tích nhiều tập dữ liệu sinh học phức tạp, bao gồm các hồ sơ biểu hiện microarray, chuỗi DNA và protein, mạng tương tác protein-protein, phổ khối liên tiếp, v.v. (William S Noble, 2006). Theo (Sharma và cộng sự, 2023), SVM là một mô hình học máy phi tham số, có thể dự đoán và kiểm soát, thường được sử dụng để giải quyết các bài toán hồi quy và phân loại.

Theo nghiên cứu của (L.V.Nghị & N.M. Ngọc, 2023), thuật toán SVM là giải pháp tìm một bề mặt để phân chia các lớp dữ liệu trong không gian n chiều (gọi là “siêu phẳng” tối ưu H), trong đó dữ liệu được tách làm 2 lớp dữ liệu có ký hiệu là (+1) hoặc (-1). Có 2 lớp dữ liệu và một “siêu phẳng” tối ưu (H) để phân cách 2 lớp (+1 và -1) dựa

trên "lề" (w) và giá trị (b) để thoả mãn phương trình điều kiện: y = w.x - b = 0. Mỗi lớp dữ liệu có một vecto tựa gọi là siêu phẳng hỗ trợ H1 và H2)

+ "Siêu phẳng" hỗ trợ H1 của lớp (+1) thỏa mãn: w.xp - b ≥ +1 với y = + 1

+ "Siêu phẳng" hỗ trợ H2 của lớp (-1) thỏa mãn: w.xp -b ≥ -1 với y = - 1

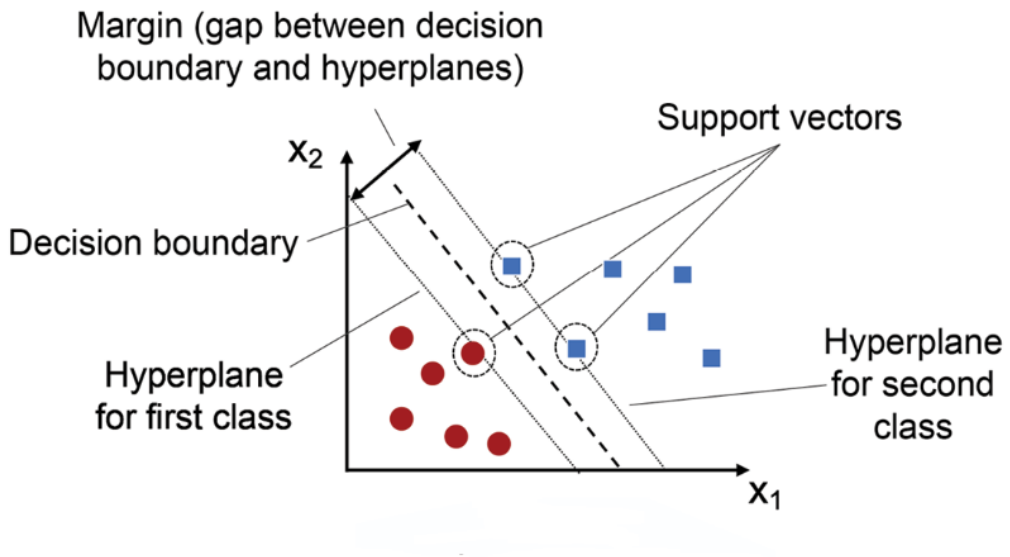

Hình 6. Ví dụ minh hoạ về thuật toán SVM

Nguồn: Analytics Yogi

Ưu, nhược điểm

Theo bài nghiên cứu của (Shih-Lin Lin, 2021), thuật toán SVM có nhiều ưu điểm. Đó là SVM sử dụng hàm kernel để ánh xạ dữ liệu từ không gian có số chiều thấp sang không gian có số chiều cao, giúp phân tách dữ liệu phi tuyến. Hoạt động tốt với dữ liệu có số chiều lớn, không bị ảnh hưởng bởi số lượng đặc trưng lớn, giúp phân loại hiệu quả mà không giảm chiều dữ liệu. Bên cạnh đó, thuật toán SVM có khả năng tổng hoá tốt, tránh overfitting ngay cả khi số lượng dữ liệu huấn luyện ít. Không yêu càu dữ liệu lớn để huấn luyện, tiết kiệm bộ nhớ.

Cũng theo nghiên cứu đó, tác giả cũng chỉ ra những nhược điểm của thuật toán SVM. Nếu số chiều của đặc trưng lớn hơn nhiều so với số lượng mẫu dữ liệu, hiệu suất của SVM chỉ ở mức trung bình. Thuật toán SVM không phù hợp khi kích thước tập mẫu quá lớn và hàm kernel ánh xạ dữ liệu vào không gian có số chiều rất cao, vì khi đó khối lượng tính toán trở nên quá lớn. Ngoài ra, không có một tiêu chuẩn chung nào để lựa chọn hàm kernel cho các bài toán phi tuyến, khiến việc tìm một hàm kernel phù hợp trở

nên khó khăn. Cuối cùng, thuật toán SVM nhạy cảm với dữ liệu bị thiếu, có thể ảnh hưởng đến độ chính xác của mô hình.

Ứng dụng

Với nghiên cứu tổng hợp IBM, thuật toán SVM ứng dụng vào nhiều nhiệm vụ, lĩnh vực khác nhau. Trước tiên, thuật toán thường được sử dụng trong xử lý ngôn ngữ tự nhiên (NLP) để phân tích thái độ, cảm xúc, phát hiện thư rác (spam) và mo hình hoá chủ đề. Nhờ khả năng xử lý tốt dữ liệu số có chiều cao, thuật toán trở thành công cụ mạnh trong phân loại văn bản. SVM còn ứng dụng trong các bài toán phân loại hình ảnh, bao gồm phát hiện đối tượng như nhận diện khuôn mặt, phân loại động vật,… và truy xuất hình ảnh. Ngoài ra, trong lĩnh vực bảo mật, SVM có thể giúp xác định xem một hình ảnh có bị chỉnh sửa hoặc giả mạo hay không. Trong lĩnh vực tin sinh học (Bioinformatics), thuật toán được sử dụng trong phân loại protein, phân tích biểu hiện gen và chẩn đoán bệnh. Đặc biệt, trong nghiên cứu ung thư, SVM giúp phát hiện các xu hướng tinh vi trong các tập dữ liệu phức tạp, hỗ trợ việc chẩn đoán và nghiên cứu các loại bệnh lý. Hơn thế nữa, trong hệ thống thông tin địa lý (GIS), thuật toán SVM có thể phân tích cấu trúc địa chất nhiều lớp dưới lòng đất, giúp loại bỏ nhiễu khỏi dữ liệu điện từ. Bên cạnh đó, SVM còn hỗ trợ dự đoán khả năng hóa lỏng địa chấn của đất, một yếu tố quan trọng trong lĩnh vực kỹ thuật xây dựng.

e. Thuật toán Nearest Neighbors (k-NN)

Khái niệm

Thuật toán K-Nearest Neighbor (KNN) là một thuật toán phân loại có giám sát. Mặc dù có cấu trúc đơn giản nhưng KNN vẫn được đánh giá là một trong 10 thuật toán khai phá dữ liệu hàng đầu (Xindong Wu và cộng sự, 2007). Theo (T.M Cover and P.E.Hart, 1967), KNN là một thuật toán máy học có giám sát, hoạt động dựa trên nguyên tắc rằng một điểm dữ liệu mới sẽ được phân loại dựa trên nhãn của k điểm lân cận gần nhất trong tập dữ liệu huấn luyện, được sử dụng cả trong bài toán phân loại và hồi quy. Ngoài ra, theo (Beckmann và cộng sự, 2015), KNN còn được gọi là một thuật toán học lười vì giai đoạn huấn huyện trong KNN diễn ra nhanh.

Thuật toán KNN được thực hiện theo các bước sau:

- Tính khoảng cách giữa một điểm dữ liệu xi với tất cả các điểm trong tập huấn luyện T. Thường sử dụng khoảng cách Euclid, nhưng có thể thay bằng các độ đo khác.

+ Công thức tính khoảng cách Euclidean

$$d(x,y) = \sqrt{\sum_{i=1}^{n} (y_i - x_i)^2}$$

+ Công thức tính khoảng cách Manhattan

$$\text{Manhattan Distance} = d(x,y) = \left(\sum_{i=1}^{m} |x_i - y_i|\right)$$

+ Công thức tính khoảng cách Minkowski

$$\text{Minkowski Distance} = \left(\sum_{i=1}^{n} |x_i - y_i|\right)^{1/p}$$

- Chọn k điểm lân cận gần nhất dựa trên khoảng cách đã tính
- Xác định nhãn cho xi dựa trên nhãn phổ biến nhất trong k điểm gần nhất. Ngoài ra, có thể áp dụng trọng số theo khoảng cách để cải thiện độ chính xác.

Nếu giá trị của k nhỏ, có nghĩa là nhạy cảm với nhiễu, dẫn đến phân loại không chính xác. Giá trị k lớn, sẽ giảm ảnh hưởng của nhiễu nhưng làm tăng chi phí tính toán. Giá trị k tối ưu thường được lấy số lẻ, như k = 3, 5, 7 để tránh trường hợp cân bằng phiếu. Theo nghiên cứu của (B.V. Dasarathy. 1991) cho thấy, k = 3 có thể đạt hiệu suất gần bằng phân loại Bayes trong tập dữ liệu.

Ưu, nhược điểm

Thuật toán KNN là thuật toán đơn giản, dễ triển khai vì có độ phức tạp thuật toán thấp, không cần huấn luyện mô hình phức tạp mà chỉ cần lưu dữ liệu huấn luyện và sử dụng khi có điểm dữ liệu mới. Vì KNN lưu trữ toàn bộ dữ liệu huấn huyện nên nó có thể tự điều chỉnh dữ liệu, giúp mô hình trở nên linh hoạt, tự cập nhật khi có dữ liệu mới. Thuật toán có thể sử dụng cho cả bài toán phân loại và hồi quy, trở thành công cụ đa năng trong các ứng dụng học máy. Bên cạnh đó, thuật toán yêu cầu ít tham số, chỉ cần chọn giá trị k và thước đo khoảng cách. KNN cũng không yêu cầu giả định về phân phối dữ liệu, có thể hoạt động tốt trên nhiều loại dữ liệu như dữ liệu phi tuyến tính, không đồng nhất hay dữ liệu không tuân theo bất kì mô hình thống kê cụ thể nào.

Mặc dù có những ưu điểm nổi trội nhưng thuật toán KNN cũng có những nhược điểm. Thuật toán cần tính toán khoảng cách của điểm mới với tất cả các điểm huấn

luyện, khi mà số lượng mẫu tăng thì việc tính toán đó tốn nhiều thời gian và tài nguyên. Nếu dữ liệu chứa nhiều nhiễu hoặc số lượng mẫu giữa các lớp không đồng đều, kết quả có thể bị sai lệch, làm cho thuật toán trở nên nhạy cảm với nhiễu và dữ liệu mất cân bằng. Việc chọn giá trị k cũng quan trọng trong thuật toán KNN, bởi nếu chọn giá trị k không phù hợp sẽ ảnh hưởng trực tiếp đến độ chính xác của mô hình.

Ứng dụng

Thuật toán KNN là một kỹ thuật được sử dụng rộng rãi trong nhiều lĩnh vực. Trong hệ thống gợi ý (Recommendation Engines), KNN có thể phân tích dữ liệu hành vi người dùng trên website để đưa ra các gợi ý nội dung phù hợp. Bằng cách phân nhóm người dùng dựa trên hành vi tương tự, thuật toán có thể đề xuất nội dung mà những người trong cùng nhóm quan tâm. Tuy nhiên do KNN gặp khó khăn về hiệu suất khi làm việc với tập dữ liệu lớn nên không phải lúc nào cũng tối ưu trong hệ thống gợi ý. Trong việc xử lý dữ liệu, KNN có thể được sử dụng để ước lượng dữ liệu bị thiếu thông qua phương pháp bù khuyết dữ liệu, giúp cải thiện độ đầy đủ và chất lượng của dữ liệu đầu vào vì trong thực tế nhiều tập dữ liệu có thể bị thiếu giá trị. Trong lĩnh vực tài chính, KNN được ứng dụng để đánh giá mức độ rủi ro tín dụng khi ngân hàng xem xét cấp khoản vay cho cá nhân hoặc doanh nghiệp. Ngoài ra, KNN cũng được sử dụng trong dự báo thị trường chứng khoán, tỷ giá hối đoái, giao dịch hợp đồng tương lai và thậm chí là phát hiện rửa tiền. Trong lĩnh vực y tế, KNN được áp dụng để dự đoán nguy cơ mắc bệnh, chẳng hạn như nhồi máu cơ tim hoặc ung thư tuyến tiền liệt. Thuật toán hoạt động bằng cách phân tích các biểu hiện gen và xác định nguy cơ dựa trên dữ liệu của các bệnh nhân có triệu chứng tương tự. Một lĩnh vực khác mà KNN được sử dụng rộng rãi là nhận dạng mẫu (Pattern Recognition). Thuật toán này giúp phân loại văn bản và chữ số viết tay, đặc biệt hữu ích trong việc nhận diện số viết tay trên biểu mẫu hoặc phong bì thư, giúp tự động hóa quá trình xử lý dữ liệu trong các hệ thống bưu chính và hành chính.

1.1.2.3. Ứng dụng của học bán giám sát

Học bán giám sát có nhiều ứng dụng vào các nhiệm vụ và lĩnh vực khác nhau. Trong nghiên cứu của (Xiangli Yang và cộng sự, 2021), nhóm tác giả đã tổng hợp một số bộ dữ liệu phổ biến nhất, tài liệu tham khảo tiêu biểu theo từng lĩnh vực ứng dụng. Theo đó, SSL được ứng dụng trong thị giác máy tính để phân loại hình ảnh để nhận dạng, phân loại đối tượng trong ảnh, phát hiện đối tượng 3D và phân đoạn ngữ nghĩa với các bộ dữ liệu tiêu biểu đó là MNIST, CIFAR-10,.. Trong lĩnh vực xử lý ngôn ngữ

tự nhiên (NLP), SSL đóng vai trò quan trọng trong phân loại văn bản, học chuỗi, sinh hội thoại và trả lời câu hỏi. Ngoài ra có các ứng dụng thực tế như phân tích cảm xúc, phân loại chủ đề, nhận diện thực thể có tên (NER) và phát triển chatbot thông minh.

Bên cạnh đó, học bán giám sát còn có ứng dụng vào việc phân tích giọng nói. Việc gán nhãn cho tệp âm thanh tốn nhiều công sức và SSL là phương pháp phù hợp để giải quyết vấn đề. Trong sinh học, do các chuỗi DNA thường có kích thước lớn, với sự phát triển của SSL còn có thể phân loại chuỗi DNA. Nhờ khả năng khai thác dữ liệu chưa gán nhãn hiệu quả, học bán giám sát ngày càng được áp dụng rộng rãi trong các lĩnh vực yêu cầu phân tích dữ liệu lớn, mở ra nhiều tiềm năng ứng dụng mới trong tương lai.

1.1.3. Các xu hướng và ứng dụng mới trong kinh tế, xã hội

Metaverse đang trở thành một trong những xu hướng công nghệ lớn nhất của thế kỷ 21. Theo (Tạp chí Lao động và Xã hội, 2025) thì sự bùng nổ của Metaverse không phải là một hiện tượng ngẫu nhiên mà là kết quả của một quá trình phát triển liên tục. Theo báo cáo của FINRA năm 2024, cơ hội doanh thu toàn cầu của Metaverse có thể đạt 800 tỷ đô la vào năm 2024, với dự đoán rằng một số yếu tố sẽ đóng góp hơn 3 nghìn tỷ đô la vào Tổng sản phẩm quốc nội (GDP) toàn cầu vào năm 2031. Với việc các công ty lớn như Meta, Microsoft, Apple đang đầu tư mạnh vào phát triển nền tảng Metaverse, tạo ra không gian ảo nơi con người có thể làm việc, giải trí và tương tác với nhau, nhu cầu phân tích hành vi người dùng và cá nhân hóa trải nghiệm trong không gian Metaverse cũng ngày càng trở nên cấp thiết (Allam và cộng sự, 2022).

Xu hướng cá nhân hoá quảng cáo đang ngày càng khẳng định vai trò quan trọng trong thời đại ngày nay. Theo (McKinsey & Company, 2021), khoảng 71% người tiêu dùng mong đợi thương hiệu cung cấp trải nghiệm cá nhân hoá; 76% người tham gia khảo sát thất vọng vì không thấy trải nghiệm cá nhân hoá khi tương tác với thương hiệu. Theo (Phiên bản thứ bảy của báo cáo State of Marketing của Salesforce, 2021) tiết lộ rằng 90% các nhà tiếp thị đã phát triển các chiến lược tiếp thị kỹ thuật số của họ để đáp ứng tốt hơn kỳ vọng của người mua trong năm 2021 và 80% người tiêu dùng ưu tiên mua sắm từ các thương hiệu cung cấp trải nghiệm được cá nhân hóa. Điều này cũng chỉ ra rằng xu hướng marketing ngày càng phải chuyển từ những chiến lược tiếp thị đại trà sang những chiến lược được thiết kế phù hợp với nhu cầu và sở thích cá nhân của từng khách hàng.

Với việc áp dụng các mô hình học máy vào phân tích dữ liệu người dùng từ nhiều nguồn khác nhau trong không gian ảo, đề tài sẽ có tiềm năng trong việc giải quyết thách thức dữ liệu trong Metaverse. Học bán giám sát là một phương pháp có tiềm năng lớn khi dữ liệu trong Metaverse có khối lượng lớn nhưng phần lớn không được gán nhãn. Các thuật toán học bán giám sát có thể tự động khám phá các mẫu hành vi chưa được xác định trước, từ đó nâng cao khả năng dự đoán sở thích, thói quen và hành vi của người dùng trong Metaverse, cải thiện độ chính xác trong nhận diện đặc trưng người dùng. Khi các doanh nghiệp xác định chính xác đặc trưng người dùng trong Metaverse, họ có thể cung cấp quảng cáo phù hợp hơn, tối ưu hóa hiệu suất chiến dịch marketing, tiếp thị.

Áp dụng học bán giám sát để xác định đặc trưng người dùng trong Metaverse hỗ trợ cá nhân hoá quảng cáo mang lại nhiều lợi ích quan trọng, không chỉ đối với cá nhân người dùng mà còn đối với doanh nghiệp và ngành nghiên cứu. Đối với người dùng Metaverse, cá nhân hoá quảng cáo tạo trải nghiệm tốt hơn, tránh bị làm phiền bởi những quảng cáo không liên quan mà thay vào đó là nhận được những nội dung quảng cáo phù hợp với nhu cầu, sở thích và hành vi của mình. Từ đó, người dùng tiết kiệm thời gian tìm kiếm, khám phá những sản phẩm, dịch vụ mà họ thực sự quan tâm, thậm chí có thể khám phá những sản phẩm, dịch vụ mới mà họ chưa biết, mở rộng phạm vi khám phá từ những hành vi trên Metaverse.

Đối với doanh nghiệp, nhờ khả năng xác định chính xác đặc trưng người dùng, quảng cáo trong Metaverse có thể được cá nhân hóa để tiếp cận đúng đối tượng khách hàng tiềm năng, giúp tăng tỷ lệ chuyển đổi và doanh thu. Nhờ đó tối ưu hóa chi phí quảng cáo bằng cách tập trung vào những người dùng có mức độ tương tác cao nhất, thay vì phân phối quảng cáo một cách đại trà và kém hiệu quả. Kết quả là doanh nghiệp vừa có thể tiết kiệm ngân sách quảng cáo mà đảm bảo các chiến dịch quảng cáo đạt được kết quả tốt nhất. Thông qua sự tương tác với thương hiệu trong không gian ảo, thử nghiệm sản phẩm hay tham gia vào các sự kiện, doanh nghiệp xây dựng được nhận diện thương hiệu, hiểu rõ sở thích, xu hướng của khách hàng để cải thiện, tối ưu hoá sản phẩm và dịch vụ phù hợp.

Đối với ngành nghiên cứu, đề tài mang lại đóng góp vào sự phát triển của công nghệ học máy (ML). Học bán giám sát là một trong những phương pháp tiềm năng nhất để phân tích dữ liệu người dùng trong Metaverse, nơi mà lượng dữ liệu chưa được gán

nhãn chiếm phần lớn. Việc áp dụng phương pháp này giúp nâng cao khả năng áp dụng vào các hệ thống thực tế, cải thiện độ chính xác của các mô hình dự đoán hành vi người dùng, và mở rộng ứng dụng của học máy trong nhiều lĩnh vực khác như thương mại điện tử, giáo dục và giải trí số. Đồng thời, việc nghiên cứu và phát triển các thuật toán học bán giám sát để phân tích dữ liệu trên Metaverse sẽ mở ra nhiều cơ hội mới trong lĩnh vực khoa học dữ liệu và hành vi người dùng.

1.2. Các nghiên cứu liên quan

1.2.1. Nghiên cứu trong nước

Ở nghiên cứu "Mô hình mạng nơron tích chập đa nhiệm nhận dạng khuôn mặt và biểu cảm cho ứng dụng hỗ trợ giám sát học trực tuyến" (D.T.Long và cộng sự, 2021). Bài viết chỉ ra việc phát triển mạnh mẽ của hệ thống quản lý học tập trực tuyến (LMS) nhưng việc theo dõi, quản lý học tập chưa đạt được hiệu quả. Nhóm tác giả đề xuất mô hình MTCNN để nhận dạng khuôn mặt và nhận dạng biểu cảm khuôn mặt từ việc ứng dụng công nghệ mạng nơron tích chập đa nhiệm (MTCNN). Mô hình được thử nghiệm trên các tập dữ liệu công khai gồm CK+, OuluCASIA và dữ liệu người học được thu thập thực tế. Từ đó, nhóm tác giả thu thập được kết quả và so sánh, đối chiếu với một số kiến trúc hiện đại mặc dù kích thước mô hình đơn giản hơn. Khi so sánh, đối chiếu nhận thấy kết quả khả quan hơn. Từ đó, nhóm tác giả đề xuất tích hợp mô hình mà nhóm đề ra với hệ thống quản lý học tập trực tuyến (LMS) theo hướng kết nối mở gia tăng thêm tính năng giám sát và theo dõi quá trình học tập, chủ động cảnh báo cho giáo viên, người học biết để điều chỉnh hoạt động dạy và học nhằm nâng cao chất lượng đào tạo.

Trong nghiên cứu "Một phương pháp học bán giám sát cho lọc kết hợp" (D.T.Liên và cộng sự, 2016) nghiên cứu về hệ tư vấn - hệ thống tự động cung cấp thông tin phù hợp và gỡ bỏ thông tin không phù hợp cho mỗi người dùng. Hệ thống tự động trong nghiên cứu được xây dựng dựa trên hai kỹ thuật lọc thông tin là lọc cộng tác (collaborative filtering) và lọc nội dung (content-based filtering). Mô hình mà nghiên cứu đề xuất là sự kết hợp giữa 2 kỹ thuật lọc và phương pháp học bán giám sát với hai thủ tục là bán giám sát tập đánh giá người dùng cùng tập đặc trưng sản phẩm và bán giám sát tập đánh giá sản phẩm cùng tập đặc trưng người dùng. Nhóm tác giả sử dụng tập dữ liệu MovieLens 1M thuộc bộ dữ liệu MovieLens của nhóm nghiên cứu GroupLens thuộc trường đại học Minnesota, gồm đánh giá của 6040 người dùng cho 3952 phim trong đó mỗi người dùng có đánh giá ít nhất của 20 phim và phim được chia

thành 19 thể loại khác nhau dùng để làm thực nghiệm. Với ý tưởng hợp nhất biểu diễn giá trị các đặc trưng sản phẩm vào lọc cộng tác để thống nhất các phương pháp dự đoán dựa vào người dùng Sau đó, xây dựng phương pháp hợp nhất biểu diễn giá trị các đặc trưng người dùng vào lọc cộng tác để thống nhất các phương pháp dự đoán dựa vào sản phẩm và chuyển giao kết quả dự đoán giữa hai phương pháp dự đoán theo người dùng và dự đoán theo sản phẩm. Kết quả nghiên cứu cho thấy phương pháp đề xuất cho lại kết quả dự đoán khá tốt trong trường hợp dữ liệu thưa đồng thời cũng đã hạn chế được quá trình tính toán mức độ tương tự giữa các cặp người dùng, tập láng giềng của của người dùng và sản phẩm để xác định các kết quả dự đoán một cách chắc chắn.

Nghiên cứu "Đánh giá tác động của quảng cáo cá nhân hóa đến ý định mua sắm của giới trẻ trên địa bàn Thành phố Hồ Chí Minh" (N.V.Nên và cộng sự, 2022) được thực hiện dựa trên điều tra bảng hỏi với 617 người tiêu dùng trẻ trên địa bàn Thành phố Hồ Chí Minh qua phương pháp phân tích, so sánh và tổng hợp kết hợp với phương pháp nghiên cứu định lượng (kiểm định Cronbach's Alpha, phân tích nhân tố khám phá EFA, phân tích nhân tố khẳng định CFA, phân tích mô hình hồi quy tuyến tính bội). Kết quả quả nhóm tác giả thu được cho thấy giá trị ảnh hưởng của quảng cáo cá nhân hóa đến ý định mua sắm của giới trẻ trên địa bàn Thành phố Hồ Chí Minh. Các biến như "tạo ra giá trị tin cậy", "tác động của nhận thức kiểm soát hành vi" đều là những lợi ích của quảng cáo cá nhân hóa dẫn đến ý định mua sắm tức nó tạo ra giá trị đáng tin cậy bằng cách cung cấp thông tin liên quan và có ý nghĩa dựa trên sở thích và hành vi của người tiêu dùng và khi tiếp cận quảng cáo cá nhân hóa, người tiêu dùng sẽ cảm thấy mình có quyền kiểm soát và lựa chọn thông tin mà họ nhận được, từ đó tạo ra sự dễ chịu và yên tâm hơn khi quyết định mua sắm.

1.2.2. Nghiên cứu trên thế giới

"What your Facebook Profile Picture Reveals about your Personality" (Cristina Segalin và cộng sự, 2017). Bài viết nghiên cứu về nhận dạng tính cách tự động từ các bức ảnh trên hồ sơ người dùng Facebook. Với tập dữ liệu 11736 ảnh đại diện trong bộ dữ liệu myPersonality, nhóm nghiên cứu phân tích bốn đặc trưng như đặc trưng thẩm mỹ tính toán (CA), đặc trưng dựa trên công cụ phân tích hình ảnh (IATO), đặc trưng mô tả bằng biểu đồ trực quan (PHOW) và sử dụng đặc trưng trích xuất từ mạng nơron tích chập (CNN). Kết quả nghiên cứu chỉ ra rằng những đặc điểm hình ảnh cụ thể có thể dự đoán các đặc trưng tính cách theo mô hình Big Five, đặc biệt là hướng ngoại

(extraversion) và dễ xúc động (neuroticism). Sau đó, nghiên cứu đề xuất mô hình phân loại tính cách từ việc tự động nhận dạng các đặc điểm trực quan qua hình ảnh và so sánh hiệu suất với phương pháp đánh giá của con người. Kết quả cho thấy thuật toán máy tính có độ chính xác cao hơn so với con người dự đoán. Từ đó, bài nghiên cứu mở ra tiềm năng ứng dụng vào lĩnh vực tiếp thị, cá nhân hoá quảng cáo, phân tích mạng xã hội, tuyển dụng nhân sự và dự đoán hành vi người dùng dựa trên dữ liệu hình ảnh trên mạng xã hội.

"Modeling User - Machine Interactions During The Information Retrieval Process", Sorbonne Université (Agnès Mustar, 2023). Bài viết đã trình bày lý thuyết và tổng quan các phương pháp trong lĩnh vực truy xuất thông tin (IR - Information Retrieval). Đầu tiên là *(1) Biểu diễn văn bản*, phương pháp biểu diễn văn bản gồm mô hình truyền thống như Bag-of-words (BOW) và các phương pháp hiện đại như Word Embeddings (Co-occurrence et matrix factorization, Word2vec), mạng nơ-ron hồi quy (RNN - Recurrent Neural Networks), kiến trúc Transformer và các mô hình Transformer như BERT, BART, T5. Đồng thời, ở phần này cũng trình bày các phương pháp huấn luyện: học có giám sát, học tăng cường (RL). Tiếp theo *(2) Mô hình Transformers* trong IR, đặc biệt là trong lĩnh vực NeuIR. Để truy xuất tài liệu ban đầu, sử dụng mô hình Sparse retrieval cải thiện quá trình tìm kiếm bằng cách tính trọng số từ vựng, mở rộng tài liệu và học biểu diễn sparse để giảm vấn đề khác biệt từ vựng; mô hình Dense Retrieval sử dụng vector biểu diễn có độ phân giải thấp để tính toán độ tương đồng giữa truy vấn và tài liệu, trong đó RepBert tạo vector trung bình từ các token, còn ColBert áp dụng mã hóa độc lập giữa truy vấn và tài liệu nhằm tăng tốc độ xử lý. Sau đó, tới giai đoạn xếp tài liệu sử dụng các mô hình phân loại Discriminative Models (điển hình là MonoBERT) và Generative Models như T5-based ranking đánh giá độ liên quan bằng cách sinh token, Multi-task learning kết hợp nhiều nhiệm vụ. *(3) Mô hình hoá người dùng* chia thành hai nhóm chính là mô phỏng người dùng và mô hình hoá từng phần. Mô phỏng người dùng xây dựng mô hình giả lập hành vi của người dùng trong môi trường tìm kiếm hoặc thương mại điện tử. Còn mô hình hóa từng phần tập trung vào các khía cạnh cụ thể như dự đoán ý định tìm kiếm (Intent Prediction), đề xuất truy vấn (Query Suggestion), và mô hình nhấp chuột (Click Model). *(4) Hệ thống hoá cá nhân* trong truy xuất thông tin (IR) có thể dựa trên phản hồi rõ ràng (explicit feedback) yêu cầu người dùng cung cấp thông tin trực tiếp hoặc phản hồi ngầm định (implicit

feedback) khai thác các tín hiệu như sửa đổi truy vấn, số lần nhấp chuột, thời gian đọc tài liệu để suy luận nhu cầu tìm kiếm của người dùng.

"Modeling Users for Adaptive Information Retrieval by Capturing User Intent" (E.Santosvà cộng sự, 2009). Trong bài viết, nhóm tác giả nghiên cứu trình bày kết quả về việc áp dụng mô hình người dùng nhận thức trong truy xuất thông tin (IR), nhằm xác định và tận dụng ý định của người dùng để nâng cao hiệu quả tìm kiếm. Ý định này được suy lận bằng cách phân tích điểm chung giữa các tài liệu liên quan được truy xuất, từ đó hệ thống tối ưu hoá kết quả tìm kiếm phù hợp với nhu cầu của từng người dùng. Nhóm tác giả sử dụng phương pháp đo lường hiệu suất truy xuất, cho phép so sánh với các phương pháp truyền thống trong lĩnh vực này, đồng thời kiểm chứng những cải tiến mà mô hình mang lại. Cụ thể nhóm tác giả đối chiếu phương pháp đề xuất với Ide dec-hi, một trong những kỹ thuật phản hồi liên quan hàng đầu dựa trên trọng số TF-IDF. Thực nghiệm được tiến hành trên ba bộ dữ liệu tiêu chuẩn CRANFIELD, CACM và MEDLINE. Kết quả cho thấy phương pháp của nhóm tác giả đề ra hoạt động tốt hơn trong các lần truy xuất ban đầu và có hiệu suất cạnh tranh với Ide dec-hi trong các lần phản hồi sau. Ngoài ra, nhóm nghiên cứu còn đánh giá tác động của mô hình người dùng đối với các nhà phân tích thông tin và kết quả cho thấy phương pháp nhóm đề ra giúp truy xuất nhiều tài liệu liên quan hơn đối với từng chuyên gia phân tích, so với ứng dụng truy xuất thông tin dựa trên từ khóa Verity Query Language.

"User Modeling for Web Information Retrieval" (Peter Brusilovsky và cộng sự, 2004). Trong bài nghiên cứu, nhóm tác giả đã nghiên cứu và trình bày mô hình hoá người dùng trong truy xuất thông tin trên Web nhằm cải thiện độ chính xác và mức độ phù hợp của kết quả tìm kiếm. Mô hình tập trung vào cá nhân hoá quá trình truy xuất thông tin bằng cách xây dựng hồ sơ người dùng và điều chỉnh kết quả tìm kiếm theo sở thích, nhu cầu của từng cá nhân. Bên cạnh đó, nhóm tác giả cũng phân tích những hạn chế của các công cụ tìm kiếm truyền thống, như việc chỉ dựa vào từ khoá mà không xem xét ý định thực sự của người dùng. Nhóm đề xuất tích hợp mô hình hoá người dùng vào hệ thống IR với các phương pháp lọc thông tin thích ứng, truy xuất thông tin thích ứng, duyệt siêu văn bản thích ứng và trực quan hoá thông tin thích ứng. Thực nghiệm được tiến hành bằng nhiều phương pháp trên để đánh giá hiệu suất mô hình. Kết quả là việc tích hợp mô hình người dùng giúp tăng đáng kể độ chính xác của truy xuất thông tin và giảm tình trạng quá tải dữ liệu. Bài nghiên cứu cũng chỉ ra các hệ thống tìm kiếm có thể

nâng cao trải nghiệm người dùng bằng cách cá nhân hoá nội dung và sắp xếp kết quả tìm kiếm dựa trên lịch sử tương tác.

"Learning-based models for building user profiles for personalized information access" (Sassi Hidri M., 2024). Bài viết nghiên cứu việc xây dựng hồ sơ người dùng dựa trên các mô hình học sâu (Deep learning) nhằm cá nhân hoá truy xuất thông tin. Mục đích là tận dụng mạng nơron để nắm bắt, hiểu rõ hơn về hành vi, sở thích và tương tác của người dùng, từ đó cải thiện chất lượng gợi ý và tìm kiếm thông tin. Bài nghiên cứu tập trung vào giải quyết vấn đề khác biệt từ vựng giữa truy vấn người dùng và nội dung tài liệu, đó vốn là một thách thức lớn trong truy xuất thông tin (IR). Tác giả đề xuất sử dụng mạng nơron nhân tạo (ANN), mạng nơron tích chập (CNN) và mạng nơron hồi quy (RNN, LSTM) để học biểu diễn tài liệu và dự đoán các mối quan tâm trọng tâm của người dùng. Thực nghiệm được tiến hành trên hai tập dữ liệu. Thứ nhất là bộ dữ liệu BBC gồm 2225 bài báo thuộc năm lĩnh vực (Kinh doanh, Giải trí, Chính trị, Thể thao, Công nghệ) được sử dụng để suy luận mối quan tâm của người dùng. Thứ hai là bộ dữ liệu hồ sơ người dùng gồm 10000 bản ghi chứa thông tin về quốc gia, tuổi, giới tính, thu nhập, ngành và trung tâm của mối quan tâm được dùng để dự đoán sở thích cá nhân. Kết quả cho thấy mô hình CNN đạt độ chính xác cao nhất (97.5%) trong việc phân loại tài liệu theo lĩnh vực, trong khi đó thì mô hình ANN mở rộng cho hồ sơ người dùng đạt 96.5% trong việc dự đoán sở thích cá nhân. Bên cạnh đó, bài nghiên cứu cũng chỉ ra do tính black-box của mô hình học sâu có thể cản trở sự hiểu biết và niềm tin, nghiên cứu tương lai sẽ tập trung vào tăng cường tính minh bạch, khả năng diễn giải và tiêu chuẩn đánh giá.

1.2.3. Các vấn đề đặt ra liên quan đến đề tài

Khoảng trống các nghiên cứu

Các nghiên cứu trước đó dù đã lấy loại dữ liệu là hình ảnh để nghiên cứu về nhận diện khuôn mặt, biểu cảm hay tính cách người dùng (D.T.Long và cộng sự, 2021; Cristina Segalin và cộng sự, 2017) xong chúng lại tập trung vào ứng dụng giám sát học tập hay phân loại người dùng nên chưa nghiên cứu sâu về đặc trưng người dùng với khía cạnh quảng cáo cá nhân hóa. Bên cạnh đó, nghiên cứu về học bán giám sát trong hệ thống gợi ý (D.T.Liên và cộng sự, 2016) đã đề xuất phương pháp kết hợp giữa lọc cộng tác và lọc nội dung, nghiên cứu về truy xuất thông tin cá nhân hóa và mô hình hóa người dùng (Agnès Mustar, 2023; E.Santos và cộng sự, 2009; Peter Brusilovsky và công sự,

2004) lại chủ yếu tập trung vào văn bản và chưa mở rộng sang việc phân tích hình ảnh để trích xuất đặc trưng người dùng mà chỉ nghiên cứu ở dạng text - dạng văn bản.

Nghiên cứu của (Sassi Hidri M., 2024) đã ứng dụng các mô hình học sâu (Deep Learning) để xây dựng hồ sơ người dùng nhằm cá nhân hóa truy xuất thông tin, nhưng không nghiên cứu trong môi trường Metaverse và chưa kết hợp phương pháp học bán giám sát để xử lý dữ liệu.

Ý nghĩa của nghiên cứu ở thời điểm hiện tại

Ở hiện tại, nhiều nghiên cứu về đặc điểm người dùng, cá nhân hóa người dùng đã được thực hiện xong những nghiên cứu để áp dụng vào quảng cáo cá nhân hóa thì lại còn hạn chế và chỉ tập trung vào dữ liệu là dạng văn bản trong khi kho dữ liệu phong phú là dữ liệu hình ảnh chưa được khai thác hiệu quả. Việc tiếp cận người dùng bằng quảng cáo cá nhân hóa dựa trên hành vi và sở thích của họ luôn là một yếu tố quan trọng đối với các doanh nghiệp. Các thương hiệu không chỉ mong muốn đưa sản phẩm của mình đến nhiều khách hàng hơn mà còn cần đảm bảo rằng nội dung quảng cáo tiếp cận đúng nhóm đối tượng tiềm năng, từ đó tối ưu chi phí marketing và tăng cường hiệu quả kinh doanh. Trong bối cảnh đó, thương mai điện tử trong Metaverse đang là một ngách, một lĩnh vực có tiềm năng phát triển mạnh mẽ. Vậy nên nghiên cứu "Sử dụng học bán giám sát để xác định đặc trưng người dùng: Áp dụng vào quảng cáo cá nhân hóa trong Metaverse" tại thời điểm năm 2025 có ý nghĩa quan trọng bởi nó đề xuất một phương pháp mới là ứng dụng học bán giám sát để phân tích đặc trưng người dùng từ dữ liệu hình ảnh, giúp cải thiện độ chính xác của quảng cáo cá nhân hóa trong môi trường mới - môi trường ảo hóa Metaverse.

Ý nghĩa của nghiên cứu trong tương lai gần

Nhu cầu của con người luôn thay đổi và có xu hướng ngày càng cao theo thời gian. Để duy trì sự thu hút đối với người dùng, các hệ thống và dịch vụ công nghệ cần không ngừng cải tiến chất lượng, đổi mới phương pháp nhằm mang lại những trải nghiệm tốt hơn. Một trong những xu hướng quan trọng hiện nay là cá nhân hóa trải nghiệm người dùng, đặc biệt trong các hệ thống gợi ý nội dung và quảng cáo số. Chính vì thế, nghiên cứu "Sử dụng học bán giám sát để xác định đặc trưng người: Áp dụng vào quảng cáo cá nhân hóa trong Metaverse" có ý nghĩa quan trọng khi hướng đến việc tối ưu hóa quá trình nhận diện và phân tích đặc điểm người dùng trong môi trường ảo hóa. Ứng dụng của nghiên cứu này không chỉ giới hạn trong lĩnh vực quảng

cáo mà còn có thể mở rộng sang nhiều lĩnh vực khác như hệ thống đề xuất nội dung số, trò chơi trực tuyến, thương mại điện tử và giáo dục thông minh.

Trong bối cảnh Metaverse ngày càng phát triển, các doanh nghiệp và nền tảng công nghệ có thể tận dụng kết quả nghiên cứu này để cải thiện hiệu quả quảng cáo, giúp cá nhân hóa nội dung hiển thị nhằm tối ưu trải nghiệm người dùng. Khi đặc trưng của từng cá nhân được xác định chính xác thông qua học bán giám sát, hệ thống quảng cáo trong Metaverse có thể hiển thị nội dung phù hợp với sở thích, thói quen và hành vi của từng người, từ đó tăng khả năng tương tác và cải thiện tỷ lệ chuyển đổi. Bên cạnh đó, công nghệ này còn có thể ứng dụng vào các hệ thống gợi ý nội dung số như mạng xã hội, nền tảng phát nhạc, phim trực tuyến và thương mại điện tử, giúp người dùng dễ dàng tiếp cận với những nội dung phù hợp mà không mất quá nhiều thời gian tìm kiếm. Ngoài ra, trong lĩnh vực trò chơi trực tuyến, việc xác định đặc trưng người dùng có thể hỗ trợ xây dựng nhân vật, vật phẩm và nhiệm vụ tùy chỉnh theo sở thích, góp phần nâng cao trải nghiệm của người chơi. Không chỉ vậy, công nghệ này còn có thể hỗ trợ cá nhân hóa quá trình học tập bằng cách phân tích hành vi và mức độ tiếp thu của từng học viên, từ đó đề xuất nội dung giáo dục phù hợp với khả năng và nhu cầu cá nhân.

Bên cạnh những ứng dụng tiềm năng, nghiên cứu này còn mang lại nhiều lợi ích quan trọng. Trước hết, việc cá nhân hóa dựa trên học bán giám sát giúp nâng cao trải nghiệm người dùng khi nội dung hiển thị phù hợp với sở thích cá nhân, làm tăng mức độ hài lòng và sự gắn kết với nền tảng. Đồng thời, hiệu quả quảng cáo cũng được cải thiện khi các doanh nghiệp có thể tiếp cận đúng khách hàng tiềm năng với nội dung phù hợp, từ đó giảm chi phí quảng cáo và tăng tỷ lệ chuyển đổi. Ngoài ra, học bán giám sát còn giúp tối ưu hóa việc khai thác dữ liệu, giảm thiểu chi phí gán nhãn thủ công mà vẫn đảm bảo mô hình đạt độ chính xác cao. Không chỉ dừng lại ở đó, nghiên cứu này còn đóng góp quan trọng vào sự phát triển của AI trong không gian số, tạo tiền đề cho các nghiên cứu chuyên sâu hơn về hành vi người dùng trong Metaverse và các nền tảng số khác.

Tuy nhiên, để triển khai nghiên cứu vào thực tế, vẫn còn nhiều thách thức cần được giải quyết. Một trong những khó khăn lớn nhất là quá trình thu thập và xử lý dữ liệu người dùng trong môi trường Metaverse, bởi đây là một không gian phức tạp với nhiều loại dữ liệu khác nhau như hình ảnh, hành vi tương tác, văn bản và âm thanh.

Ngoài ra, độ chính xác của mô hình cũng là một vấn đề cần cân nhắc, vì việc sử dụng học bán giám sát có thể gặp khó khăn trong việc đảm bảo dữ liệu không bị sai lệch hoặc thiếu tính đa dạng. Hơn nữa, yếu tố quyền riêng tư và đạo đức AI cũng đặt ra nhiều thách thức, đặc biệt khi dữ liệu cá nhân ngày càng trở thành một vấn đề nhạy cảm, đòi hỏi các giải pháp bảo mật và tuân thủ các quy định pháp lý chặt chẽ. Ngoài ra, để nghiên cứu có thể ứng dụng rộng rãi, mô hình cần có khả năng mở rộng và hoạt động hiệu quả trên quy mô lớn, đồng thời tích hợp linh hoạt với các nền tảng Metaverse hiện có.

CHƯƠNG 2: MÔ HÌNH NGHIÊN CỨU

2.1. Thực trạng các vấn đề liên quan đến đề tài nghiên nghiên cứu

2.1.1. Ở Việt Nam

Facebook là nền tảng mạng xã hội hàng đầu tại Việt Nam, với số liệu thống kê cho thấy mức độ sử dụng rộng rãi và sự tăng trưởng đáng kể trong những năm qua. Theo báo cáo của DataReportal, từ tháng 1/2023 đến tháng 1/2024, số người dùng Facebook tại Việt Nam đã tăng thêm 6,5 triệu, tương đương mức tăng 9,8%. Tính đến tháng 4/2023, theo số liệu từ NapoleonCat, Facebook tại Việt Nam có khoảng 85,1 triệu người dùng, chiếm hơn 84,1% dân số. Trong đó, tỷ lệ người dùng nữ chiếm 51%, nam chiếm 49%. Nhóm tuổi từ 25 đến 34 là đối tượng sử dụng nhiều nhất, với khoảng 24,6 triệu người. Những số liệu này cung cấp thêm thông tin quan trọng về hành vi khách hàng trên Facebook cũng như trong không gian Metaverse tại Việt Nam, giúp làm rõ các xu hướng tương tác và mức độ phổ biến của nền tảng này. Về hành vi của người dùng trên nền tảng mạng xã hội Facebook, có tới 81,8% người dùng Facebook tại Việt Nam truy cập nền tảng này qua điện thoại di động, trong khi chỉ 1,5% sử dụng máy tính xách tay hoặc máy tính để bàn. Điều này cho thấy phần lớn người dùng ưu tiên thiết bị di động để lướt Facebook. Bên cạnh đó, hơn một tỷ người dùng Facebook trên toàn cầu kết nối với các doanh nghiệp thông qua công cụ nhắn tin mỗi tuần, khẳng định tầm quan trọng của nền tảng này trong việc tương tác giữa doanh nghiệp và khách hàng. Về hiệu quả quảng cáo, tỷ lệ nhấp chuột (CTR) trung bình trên Facebook đạt khoảng 1,4%. Ngành may mặc và giày dép có CTR cao nhất với 2,06%, trong khi lĩnh vực chăm sóc sức khỏe chỉ đạt 0,73%. Đây là dữ liệu quan trọng giúp doanh nghiệp tối ưu hóa chiến lược quảng cáo trên Facebook.

Đối với Metaverse, thị trường này tại Việt Nam dự kiến đạt giá trị 180,4 triệu USD vào năm 2023 và tăng trưởng với tốc độ trung bình hàng năm 40,37% trong giai đoạn 2023-2030, ước tính đạt 1.937 triệu USD vào năm 2030. Ngành game được xem là lĩnh vực có tiềm năng phát triển mạnh mẽ, khi Việt Nam có số lượng game phát hành và nhà phát triển game hàng đầu khu vực. Trong nửa đầu năm 2022, có 170 triệu lượt tải ứng dụng Metaverse trên toàn cầu, trong đó game chiếm 67,3%.

Xét về hành vi sử dụng Facebook, người Việt Nam chủ yếu dùng nền tảng này để kết nối với bạn bè, gia đình, cập nhật tin tức và tham gia các nhóm cộng đồng. Trung bình, họ dành khoảng 2 giờ 32 phút mỗi ngày trên mạng xã hội, trong đó Facebook

chiếm phần lớn thời gian sử dụng. Những số liệu này cho thấy vai trò quan trọng của Facebook và Metaverse trong đời sống số của người Việt, đồng thời giúp doanh nghiệp nắm bắt xu hướng để xây dựng chiến lược kinh doanh phù hợp.

Metaverse, được coi là bước tiến tiếp theo của internet, kết hợp giữa thế giới vật lý và kỹ thuật số, đang thu hút sự quan tâm tại Việt Nam. Theo dự báo của Statista, thị trường Metaverse tại Việt Nam đang trải qua sự tăng trưởng đáng kể, được thúc đẩy bởi sự ưa chuộng của người tiêu dùng đối với các trải nghiệm kỹ thuật số và tương tác ảo.

Việc thấu hiểu hành vi khách hàng trên Facebook và Metaverse đóng vai trò quan trọng trong việc giúp doanh nghiệp xây dựng chiến lược tiếp thị và tương tác hiệu quả. Sự phát triển mạnh mẽ của Metaverse mang đến nhiều cơ hội mới, cho phép doanh nghiệp tạo ra trải nghiệm khách hàng độc đáo, tăng cường sự gắn kết và mở rộng thị trường theo hướng số hóa. Nhiều báo cáo khảo sát uy tín đã cung cấp thông tin quan trọng về xu hướng này. Báo cáo Digital 2024 của DataReportal cung cấp cái nhìn toàn diện về tình hình sử dụng mạng xã hội và internet tại Việt Nam, bao gồm số liệu chi tiết về người dùng Facebook và các xu hướng kỹ thuật số. Trong khi đó, báo cáo của Statista về Metaverse tại Việt Nam đưa ra dự báo và phân tích về sự phát triển của thị trường này, đồng thời đánh giá các yếu tố thúc đẩy và xu hướng tiêu dùng trong lĩnh vực Metaverse.

Những số liệu và phân tích trên càng khẳng định tầm quan trọng của việc nghiên cứu hành vi khách hàng trên Facebook và Metaverse. Chúng không chỉ giúp doanh nghiệp hiểu rõ hơn về cách người dùng tương tác trên các nền tảng này mà còn hỗ trợ trong việc tối ưu hóa chiến lược kinh doanh, từ đó tận dụng tốt nhất cơ hội trong kỷ nguyên kỹ thuật số đang phát triển mạnh mẽ.

2.1.2. Trên thế giới

Người dùng hoạt động hàng tháng (MAU) trên Facebook được định nghĩa là những người đã đăng ký và đăng nhập vào nền tảng này, truy cập thông qua ứng dụng di động hoặc trình duyệt web trong vòng 30 ngày gần nhất tính đến ngày đo lường. Theo báo cáo đầu tư mới nhất của Meta, tính đến ngày 30/1/2025, Facebook có 3,065 tỷ người dùng hoạt động hàng tháng.

Số liệu thống kê cho thấy mức độ phổ biến của Facebook trên toàn cầu ngày càng tăng. MAU đã tăng 3,44% so với cùng kỳ năm trước, với 68,85% người dùng hàng tháng

đăng nhập hàng ngày. Điều này có nghĩa là hơn một nửa số người dùng internet trên thế giới (56,76%) truy cập Facebook mỗi tháng, chiếm 38,22% dân số toàn cầu. Nếu so sánh với quy mô dân số, số người sử dụng Facebook còn nhiều hơn tổng dân số của châu Phi, châu Âu và Bắc Mỹ cộng lại. Đáng chú ý, 98,5% người dùng Facebook truy cập nền tảng này qua điện thoại di động.

Tương tự, người dùng hoạt động hàng ngày (DAU) là những người đăng ký và đăng nhập vào Facebook ít nhất một lần trong ngày, thông qua ứng dụng di động hoặc trình duyệt web. Hiện tại, Facebook có trung bình 2,11 tỷ người dùng hoạt động hàng ngày, tăng 5,5% so với cùng kỳ năm trước. Trong số những người dùng hàng tháng, 68,85% đăng nhập hàng ngày, chiếm 39,07% tổng số người dùng internet và 26,31% dân số thế giới.

Những con số này cho thấy Facebook vẫn là nền tảng mạng xã hội hàng đầu thế giới, với tỷ lệ sử dụng cao và sự gắn kết chặt chẽ của người dùng. Đặc biệt, với 98,5% tài khoản truy cập qua điện thoại di động, rõ ràng thiết bị di động đóng vai trò quan trọng trong trải nghiệm Facebook của người dùng.

2.1.3. Đánh giá chung

Trong những năm gần đây, Metaverse đã trở thành một chủ đề thu hút sự quan tâm lớn từ cộng đồng công nghệ, doanh nghiệp và các nhà nghiên cứu nhờ vào tiềm năng to lớn trong việc tạo ra một không gian kỹ thuật số tương tác, nơi con người có thể giao tiếp, làm việc, mua sắm và giải trí trong môi trường thực tế ảo. Các tập đoàn công nghệ hàng đầu thế giới như Meta (Facebook), Google, Microsoft đã đầu tư mạnh mẽ vào lĩnh vực này, không chỉ để phát triển hạ tầng nền tảng Metaverse, mà còn để tận dụng các cơ hội kinh doanh tiềm năng trong quảng cáo thông minh, thương mại điện tử ảo, giáo dục trực tuyến và các dịch vụ giải trí kỹ thuật số. Trong đó, nền tảng mạng xã hội Facebook là nền tảng phổ biến nhiều người dùng ở nhiều quốc gia trên thế giới, trong đó có Việt Nam. Sử dụng dữ liệu người dùng để cá nhân hóa quảng cáo ngày càng trở nên phổ biến, giúp doanh nghiệp tiếp cận khách hàng mục tiêu chính xác hơn.

Việc xác định đặc trưng người dùng trong Metaverse đóng vai trò quan trọng trong tối ưu hóa quảng cáo số, nâng cao trải nghiệm người dùng và cải thiện độ chính xác trong phân tích dữ liệu. Khi doanh nghiệp có thể hiểu rõ hành vi và sở thích của

từng cá nhân, họ có thể cung cấp quảng cáo cá nhân hóa, giúp tăng mức độ tương tác, cải thiện trải nghiệm khách hàng, đồng thời tối ưu hóa tỷ lệ chuyển đổi.

Trong bối cảnh số hóa mạnh mẽ, Facebook vẫn là nền tảng quan trọng để doanh nghiệp tiếp cận khách hàng, với dữ liệu thu thập ở trên, có hơn 81,8% người dùng tại Việt Nam truy cập qua thiết bị di động và hơn 1 tỷ người dùng trên toàn cầu kết nối với doanh nghiệp thông qua Facebook Messenger mỗi tuần. Điều này cho thấy Facebook không chỉ đơn thuần là một nền tảng mạng xã hội, mà còn là một kênh tiếp thị quan trọng giúp doanh nghiệp tiếp cận khách hàng mục tiêu và tối ưu hóa chiến lược quảng cáo. Metaverse đang mở ra những cơ hội quảng cáo và tiếp thị số đột phá. Các thương hiệu có thể tận dụng không gian ảo để tạo ra các chiến dịch tiếp thị nhập vai, giúp người dùng có trải nghiệm tương tác sống động, từ đó cải thiện tỷ lệ chuyển đổi và nâng cao mức độ nhận diện thương hiệu.

Hơn thế nữa, bằng cách áp dụng học bán giám sát, doanh nghiệp có thể tận dụng một lượng nhỏ dữ liệu có nhãn để hướng dẫn mô hình học từ dữ liệu chưa có nhãn, từ đó giúp tối ưu hóa quá trình huấn luyện mô hình mà không cần tốn quá nhiều tài nguyên để gán nhãn toàn bộ dữ liệu. Metaverse, nơi mà dữ liệu thu thập được có khối lượng lớn, đa dạng và liên tục thay đổi, nhưng phần lớn chưa được gán nhãn do chi phí và thời gian xử lý thủ công quá cao thì việc phân tích người dùng áp dụng học bán giám sát có thể khai thác dữ liệu hành vi một cách hiệu quả hơn. Các quảng cáo được điều chỉnh dựa trên sở thích, hành vi mua sắm, thời gian hoạt động, tần suất tương tác và mức độ quan tâm của từng người dùng. Từ đó, nâng cao trải nghiệm người dùng trong Metaverse đồng thời cho phép doanh nghiệp dự đoán xu hướng tiêu dùng, gợi ý sản phẩm, dịch vụ hoặc nội dung phù hợp với từng nhóm khách hàng, tận dụng tối đa tiềm năng tiếp thị trong không gian kỹ thuật số thế hệ mới.

2.2. Các mô hình liên quan đến đề tài

2.2.1. Các mô hình lý thuyết

Việc xác định đặc trưng người dùng trong Metaverse đòi hỏi sự kết hợp của nhiều mô hình lý thuyết nhằm khai thác hiệu quả dữ liệu và tối ưu hóa chiến lược cá nhân hóa quảng cáo. Trong môi trường ảo Metaverse này, người dùng tương tác thông qua các thiết bị công nghệ, để lại các dấu vết dữ liệu phong phú, đa dạng nhưng không phải lúc nào cũng được gán nhãn đầy đủ. Do đó, học bán giám sát (Semi-Supervised Learning - SSL) trở thành một phương pháp quan trọng, kết hợp dữ liệu có nhãn và chưa có nhãn

để nâng cao hiệu suất mô hình. Bên cạnh đó, các mô hình phân tích hành vi người dùng giúp hiểu rõ hơn về sở thích, xu hướng và động cơ của họ trong không gian Metaverse, từ đó cung cấp nền tảng cho các hệ thống đề xuất và cá nhân hóa quảng cáo.

2.2.1.1. Các mô hình học bán giám sát

Mô hình Self-training

Theo nghiên cứu của (Amini và cộng sự, 2025), mô hình self-training là một trong những phương pháp sớm nhất trong học bán giám sát và đã trở nên phổ biến trong những năm gần đây, với mục tiêu tận dụng dữ liệu chưa gán nhãn để cải thiện mô hình học máy. Mô hình sẽ gán nhãn giả (pseudo-labels) cho các mẫu chưa có nhãn, sau đó đưa vào tập dữ liệu huấn luyện để tiếp tục tối ưu hoá mô hình.

Nguyên lí hoạt động của mô hình này là ban đầu với tập dữ liệu nhỏ gán nhãn để huấn luyện mô hình ban đầu. Sau đó, mô hình được sử dụng để dự đoán nhãn, gán nhãn cho các dữ liệu chưa gán nhãn. Các dữ liệu được gán nhãn có độ tin cậy cao (confidence scores trên một ngưỡng nhất định) sẽ được gán nhãn giả. Tập dữ liệu đó với thêm nhãn tương ứng được đưa vào huấn luyện. Quá trình này được lặp lại, mỗi vòng lặp thì bộ lọc sẽ chuyển một vài các mẫu có độ tin cậy cao nhất sang tập dữ liệu huấn luyện cùng với các dự đoán phân lớp của chúng.

Algorithm 1. Self-Training

Input : $S = (\mathbf{x}_i, y_i)_{1 \leqslant i \leqslant m}$, $X_{\mathcal{U}} = (\mathbf{x}_i)_{m+1 \leqslant i \leqslant m+u}$.
$k \leftarrow 0$, $X_{\tilde{\mathcal{U}}} \leftarrow \emptyset$.
repeat
  Train $f^{(k)}$ on $S \cup X_{\tilde{\mathcal{U}}}$
  $\Pi_k \leftarrow \{\Phi_\ell(\mathbf{x}, f^{(k)}), \mathbf{x} \in X_{\mathcal{U}}\}$ ▷ Pseudo-labeling
  $X_{\tilde{\mathcal{U}}} \leftarrow X_{\tilde{\mathcal{U}}} \cup \Pi_k$
  $X_{\mathcal{U}} \leftarrow X_{\mathcal{U}} \setminus \{\mathbf{x} \mid (\mathbf{x}, \tilde{y}) \in \Pi_k\}$
  $k \leftarrow k + 1$
until $X_{\mathcal{U}} = \emptyset \vee \Pi_k = \emptyset$
Output : $f^{(k)}, X_{\mathcal{U}}, X_{\tilde{\mathcal{U}}}$

Hình 7. Thuật toán Self-training

Nguồn: Bài nghiên cứu của (Amini và cộng sự, 2025)

Với thuật toán trên, biến đầu vào (input) là tập dữ liệu có nhãn, tập dữ liệu chưa có nhãn, biến đếm số vòng lặp và tập rỗng ban đầu. Biến trong vòng lặp là mô hình được huấn luyện ở vòng lặp thứ k, tập nhãn giả và tập dữ liệu chưa gán nhãn giảm dần. Vòng lặp sẽ dừng lại khi tập dữ liệu chưa gán nhãn là tập rỗng. Cuối cùng thu được biến đầu ra (output) là mô hình sau khi được huấn luyện, tập dữ liệu sau khi được gán nhãn giả.

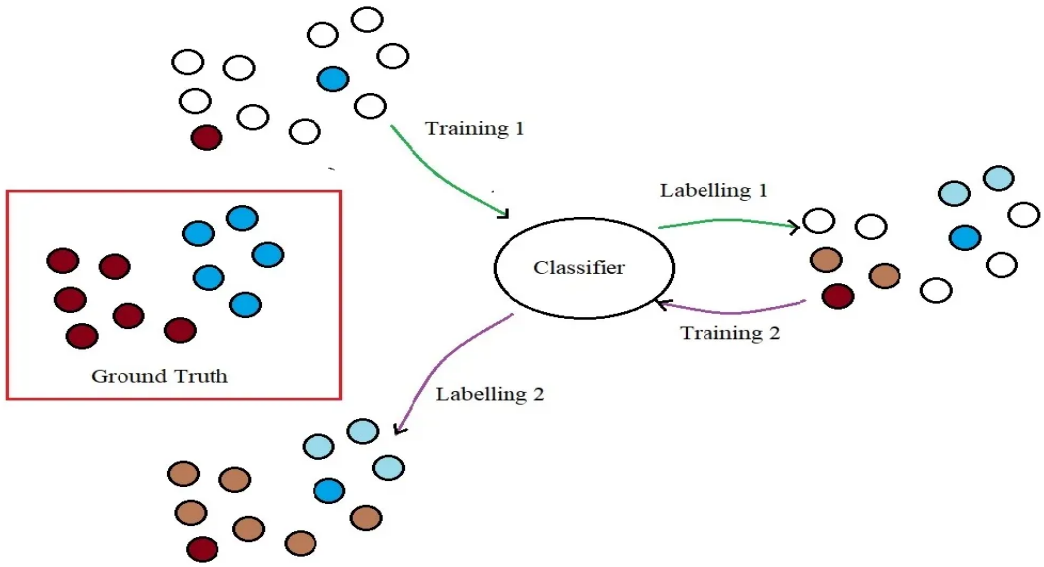

Hình 8. Giải thích thuật toán Self-training

Nguồn: Medium

Ứng dụng của self-training được mở rộng và áp dụng cho nhiều lĩnh vực, nhiều nhiệm vụ học máy. Trong bài "Learning Subjective Nouns using Extraction Pattern Bootstrapping" của (Ellen Rilof và cộng sự, 2003), self-training được ứng dụng trong xử lý ngôn ngữ tự nhiên (NLP). Theo (Amini và cộng sự, 2025), các phương pháp self-training hiện đại trong NLP chủ yếu dựa trên co-training, pseudo-labeling sử dụng hai bộ phân loại để học từ dự đoán của nhau. Trong thị giác máy tính (computer vision), self-training hỗ trợ phân loại hình ảnh, phát hiện đối tượng và phân đoạn ảnh. Ngoài ra, trong lĩnh vực nhận dạng giọng nói, self-training giúp cải thiện độ chính xác bằng cách lọc nhiễu trong quá trình tạo nhãn giả dựa trên các ràng buộc ngữ âm và mô hình ngôn ngữ miền đặc thù. Trong phát hiện bất thường, self-training hỗ trợ nhận diện các mẫu bất thường bằng cách kết hợp các kỹ thuật học không giám sát với mô hình có giám sát, giúp nâng cao độ tin cậy của các dự đoán.

Mô hình Graph-Based Semi-Supervised Learning

Theo bài nghiên cứu của (Zixing Song và cộng sự, 2023), Graph-based Semi-supervised Learning (GSSL) là một nhánh của học bán giám sát (SSL), trong đó dữ liệu được biểu diễn dưới dạng đồ thị và thông tin của các mẫu chưa được gán nhãn có thể được suy luận từ cấu trúc đồ thị. Cụ thể GSSL dựa trên giả thuyết manifold (manifold assumption), cho rằng: (1) Các điểm dữ liệu gần nhau trên một đa tạp (manifold) có xu hướng có cùng nhãn, (2) Một đồ thị được xây dựng để biểu diễn mối quan hệ giữa các điểm dữ liệu, trong đó các nút (nodes) đại diện cho dữ liệu và các cạnh (edges) thể hiện

sự tương đồng của chúng, (3) Các mẫu dữ liệu có kết nối mạnh mẽ (cạnh có trọng số lớn) có xu hướng thuộc cùng một lớp. Do đó, mô hình bao gồm hai bước chính. Đầu tiên là xây dựng đồ thị (Graph Construction), tạo đồ thị sao cho các mẫu dữ liệu gần nhau có kết nối mạnh hơn. Sau đó là suy luận nhãn (Label Inference), truyền nhãn từ các mẫu dữ liệu có nhãn sang các mẫu chưa có nhãn dựa trên cấu trúc đồ thị.

Theo bài nghiên cứu của (Wanyu Lin và cộng sự, 2020), Đại học Toronto, nhóm tác giả đề xuất kiến trúc Shoestring nhằm cải thiện hiệu suất của học bán giám sát dựa trên GSSL trong điều kiện số lượng dữ liệu gán nhãn ít.

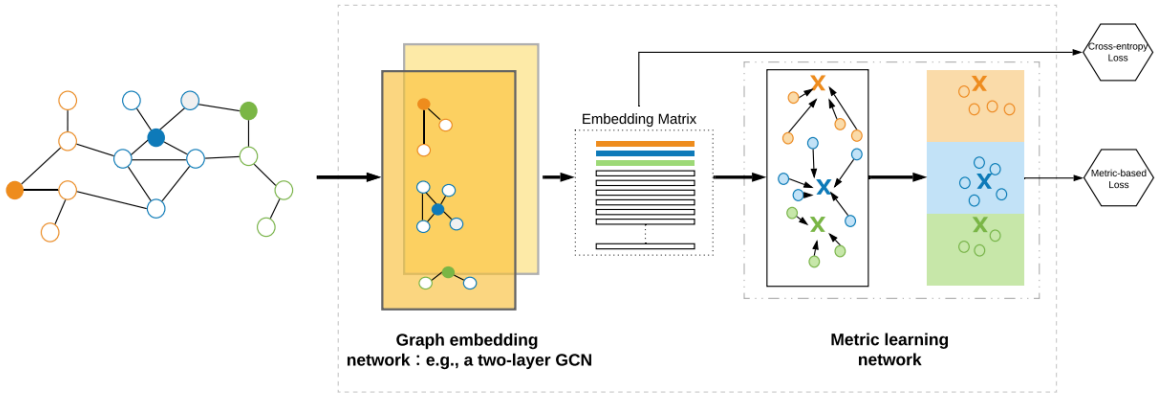

Hình 9. Kiến trúc Shoestring

Nguồn: Bài nghiên cứu của (Wanyu Lin và cộng sự, 2020)

GSSL cũng được ứng dụng cho nhiều lĩnh vực khác nhau. Theo (Zixing Song và cộng sự, 2023), trong thị giác máy tính (Computer Vision), GSSL được sử dụng để phân loại ảnh quang phổ cao (Hyperspectral Image Classification - HSI), nơi dữ liệu có nhãn rất ít và đắt đỏ, cũng như cải thiện truy xuất hình ảnh bằng cách tối ưu hóa phương pháp xây dựng đồ thị dựa trên KNN. Ngoài ra, GSSL còn hỗ trợ chuyển đổi giữa hình ảnh và âm thanh bằng cách sử dụng biểu diễn manifold dựa trên đồ thị. Trong xử lý ngôn ngữ tự nhiên (NLP), GSSL giúp gán nhãn từ loại (POS Tagging) bằng cách xây dựng đồ thị tương đồng giữa các n-gram, tối ưu hóa mô hình ngôn ngữ bằng cách làm mịn đồ thị ngữ nghĩa, và hỗ trợ phân loại văn bản ngắn khi dữ liệu có nhãn bị hạn chế bằng cách kết hợp với mô hình GAT (Graph Attention Networks). Đối với mạng xã hội (Social Networks), GSSL được sử dụng để phân loại tweet trong tình huống khủng hoảng, phát hiện người dùng giả mạo trên Twitter, và cải thiện hệ thống gợi ý địa điểm, bạn bè thông qua đồ thị song phương. Trong khoa học y sinh (Biomedical Science), GSSL hỗ trợ phân loại kiểu hình dựa trên dữ liệu gen, dự đoán mối quan hệ giữa thuốc và bệnh thông qua

tương tác miRNA-disease và tăng cường độ chính xác trong chẩn đoán bệnh cũng như phân đoạn ảnh y tế. Nhìn chung, GSSL đóng vai trò quan trọng trong cả dữ liệu có cấu trúc đồ thị tự nhiên (như mạng xã hội và y sinh) lẫn dữ liệu phi đồ thị (như thị giác máy tính và xử lý ngôn ngữ) bằng cách xây dựng và khai thác các mô hình đồ thị phù hợp.

Machine Learning Project Life Cycle

Với bài viết của (Ihsanul Haque Asif, 2023), tác giả đã trình bày chi tiết về lưu đồ vòng đời dự án học máy để xây dựng, huấn luyện và triển khai mô hình học máy. Quy trình này gồm các bước chi tiết như sau: *Xác định vấn đề (Problem Formulation)*, xác định rõ các mục tiêu và phạm vi của dự án học máy. *(1) Thu thập dữ liệu (Data Acquisition)*, thu thập dữ liệu cần thiết từ các nguồn phù hợp để giải quyết vấn đề đã xác định. (*2) Làm sạch và gán nhãn dữ liệu (Data Cleaning & Labeling)*, chuẩn hóa và biến đổi dữ liệu để chuẩn bị cho việc huấn luyện mô hình. *(3) Phân tích dữ liệu khám phá (Exploratory Data Analysis - EDA)*, phân tích dữ liệu để hiểu rõ hơn về cấu trúc và đặc điểm của nó. (*4) Tiền xử lý dữ liệu (Data Preprocessing)*, chuẩn hóa và biến đổi dữ liệu để chuẩn bị cho việc huấn luyện mô hình. *(5) Chia tập dữ liệu (Dataset Splitting)*, chia dữ liệu thành các tập huấn luyện, kiểm định và kiểm tra để đánh giá mô hình. *(6) Huấn luyện mô hình (Model Training)*, sử dụng dữ liệu huấn luyện để xây dựng mô hình học máy. *(7) Đánh giá hiệu suất mô hình (Model Performance Evaluation)*, đánh giá mô hình dựa trên các chỉ số hiệu suất để đảm bảo chất lượng. *(8) Tối ưu hóa siêu tham số (Hyperparameter Tuning)*, điều chỉnh các tham số của mô hình để cải thiện hiệu suất. *(9) Đánh giá cuối cùng (Final Evaluation)* và *(10) Triển khai mô hình (Model Deployment)* vào thực tế.

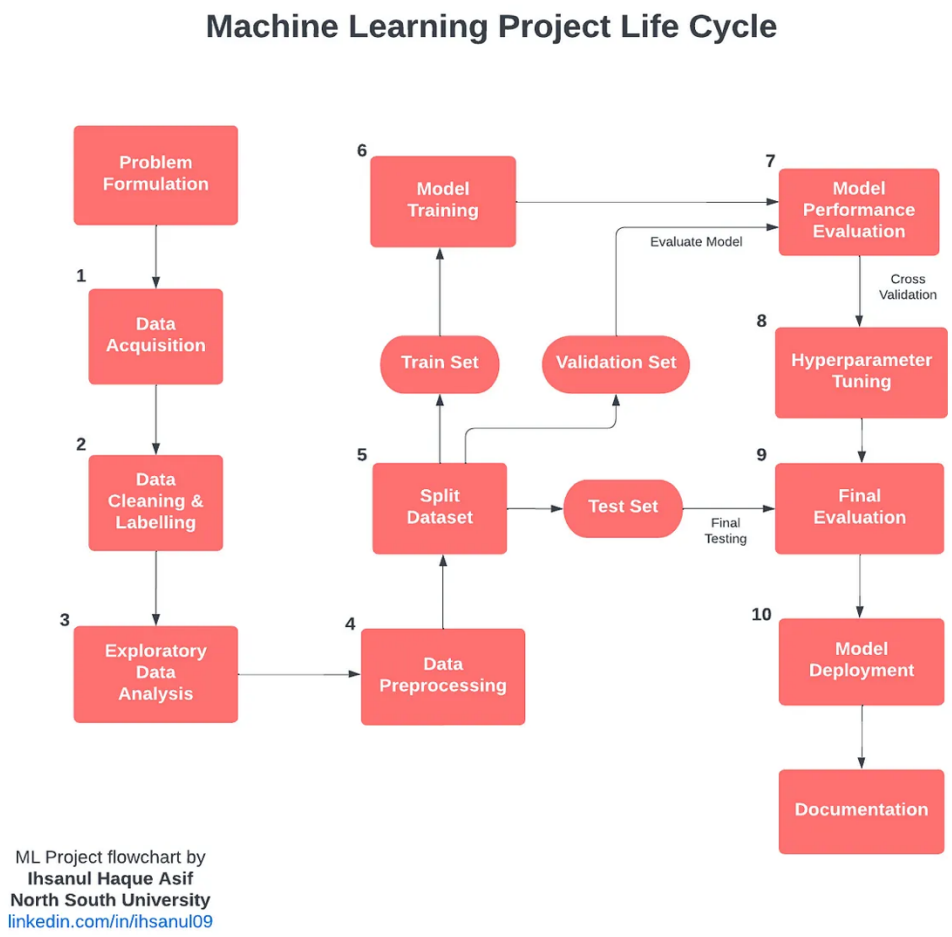

Hình 10. Machine Learning Project Flowchart

Nguồn: Bài nghiên cứu của (Ihsanul Haque Asif, 2023)

2.2.1.2. Các mô hình phân tích đặc trưng người dùng trong Metaverse

Mô hình Chấp nhận Công nghệ TAM (Technology Acceptance Model)

Theo (Neil Charness, Walter R. Boot, 2016) trong Handbook of the Psychology of Aging, mô hình Chấp nhận Công nghệ (TAM; Davis, 1989) là một trong những mô hình có ảnh hưởng lớn nhất trong nghiên cứu về sự chấp nhận công nghệ. Mô hình này chỉ ra rằng ý định sử dụng công nghệ mới của một cá nhân chủ yếu bị chi phối bởi hai yếu tố: nhận thức về sự dễ sử dụng và nhận thức về tính hữu ích. Chẳng hạn, một người cao tuổi có thể không muốn tiếp cận trò chơi điện tử nếu họ cảm thấy chúng quá phức tạp hoặc vô ích. Ngược lại, nếu họ nhận thấy trò chơi điện tử giúp kích thích tư duy và dễ học, họ sẽ có xu hướng sẵn sàng tìm hiểu và sử dụng hơn. Mặc dù TAM đã nhận phải một số chỉ trích, nhưng nó vẫn là một khung lý thuyết hữu ích và phù hợp với nhiều

nghiên cứu về các yếu tố ảnh hưởng đến ý định sử dụng công nghệ của người cao tuổi (Braun, 2013).

Theo bài nghiên cứu của (Davit Marikyan, Savvas Papagiannidis, 2024), Mô hình chấp nhận công nghệ - TAM, một khung lý thuyết được phát triển bởi Fred Davis, 1989, dựa trên Thuyết hành động hợp lí (Theory of Reasoned Action - TRA) và tập trung vào hai yếu tố chính ảnh hưởng đến ý định sử dụng công nghệ của người dùng. Đó là *(1) nhận thức về tính hữu ích*, mức độ mà người dùng tin rằng việc sử dụng sẽ cải thiện hiệu suất công việc của họ và *(2) nhận thức về sự dễ sử dụng*, mức độ mà người dùng tin rằng việc sử dụng hệ thống công nghệ không đòi hỏi nhiều nỗ lực. Sau khi mô hình TAM được phát triển, TAM2 (Davis & Venkatesh, 2000) và TAM3 (Venkatesh & Bala, 2008) mở rộng, bổ sung mô hình về các yếu tố ảnh hưởng đến tính hữu ích và dễ sử dụng.

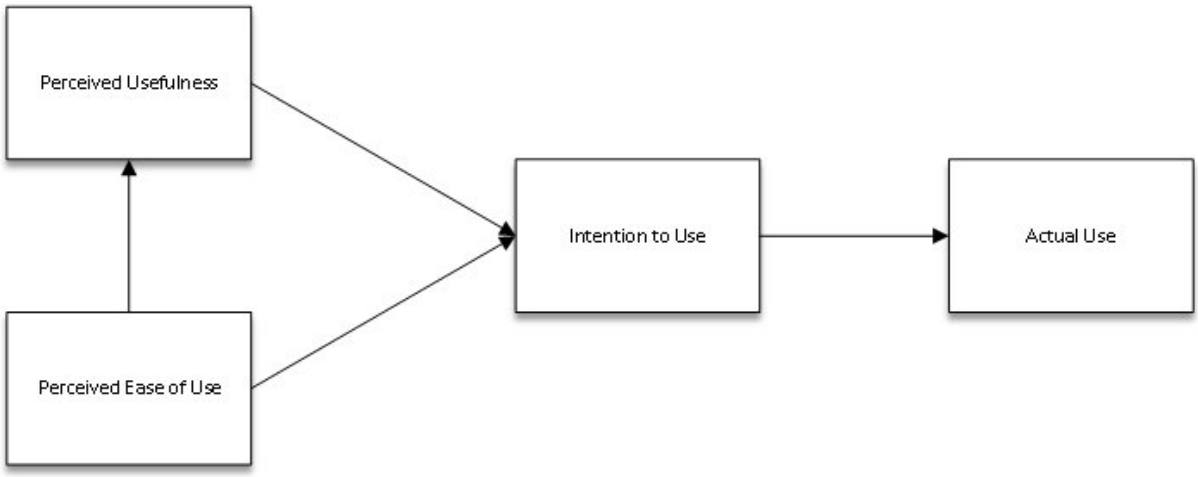

Hình 11. Mô hình TAM (Davis, 1989)

Cũng theo bài nghiên cứu trên, mô hình TAM và các phiên bản mở rộng của nó TAM2, TAM3 được áp dụng rộng rãi trong nhiều lĩnh vực. Trong marketing và thương mại điện tử, TAM giúp phân tích thái độ của người tiêu dùng đối với các công nghệ như chatbot, nền tảng thương mại điện tử, và công cụ mua sắm trực tuyến. Trong tài chính và viễn thông, TAM được áp dụng để nghiên cứu sự chấp nhận ngân hàng di động (mobile banking) và công nghệ thực tế ảo (VR). Kết quả cho thấy tính hữu ích luôn có tác động mạnh mẽ đến ý định sử dụng, nhưng sự dễ sử dụng có thể không phải lúc nào cũng quan trọng, tùy thuộc vào công nghệ cụ thể. Bên cạnh đó, trong giáo dục và y tế, TAM được dùng để phân tích việc chấp nhận hệ thống e-learning và công nghệ y tế.

Ngoài ra, TAM cũng được áp dụng trong nông nghiệp và quản lý tài nguyên, giúp đánh giá mức độ chấp nhận các công nghệ chăn nuôi, canh tác và bảo vệ môi trường.

Mô hình Chấp nhận Công nghệ dựa trên Mindsponge (MTAM)

Theo bài viết của (Dương Thị Minh Phượng, 2023) đăng trên Tạp chí Kinh tế và Dự báo, mặc dù mô hình TAM được áp dụng rộng rãi trong nghiên cứu nhiều lĩnh vực, tuy nhiên vẫn tồn tại một số hạn chế, đặc biệt khi áp dụng cho các công nghệ tiên tiến hơn. Với mục tiêu cải tiến, lý thuyết MTAM ra đời. MTAM tích hợp các yếu tố văn hóa, giá trị và xã hội vào quá trình đánh giá sự chấp nhận công nghệ, giúp hiểu rõ hơn về cách người dùng tiếp nhận các công nghệ mới, đặc biệt là công nghệ trí tuệ nhân tạo cảm xúc. Nghiên cứu cho thấy yếu tố văn hóa và giá trị cá nhân ảnh hưởng đáng kể đến thái độ và niềm tin của người dùng đối với việc thu thập dữ liệu cảm xúc không minh bạch bởi các tổ chức chính phủ và tư nhân. Những người quen thuộc hơn với công nghệ AI hoặc nhận thức rõ hơn về giá trị của nó thường có thái độ tích cực hơn đối với việc thu thập dữ liệu này. Ngoài ra, thời gian sử dụng mạng xã hội cũng ảnh hưởng khác nhau đến thái độ của người dùng đối với việc thu thập dữ liệu không minh bạch bởi chính phủ và tư nhân.

Consumer behaviour model - Mô hình hành vi người tiêu dùng

Theo bài nghiên cứu của (Jisana T. K., 2014), hành vi người tiêu dùng là quá trình cá nhân đưa ra quyết định sử dụng tài nguyên như thời gian, tiền bạc, công sức,.. để mua và sử dụng sản phẩm và dịch vụ. Hành vi bị ảnh hưởng bởi các yếu tố cá nhân, xã hội, văn hóa và tâm lý. Việc hiểu hành vi tiêu dùng giúp doanh nghiệp phát triển chiến lược tiếp thị hiệu quả.

Các yếu tố ảnh hưởng đến hành vi người tiêu dùng đó là: (1) Yếu tố văn hoá, (2) Yếu tố xã hội, (3) Yếu tố cá nhân, (4) Yếu tố tâm lý (theo tháp nhu cầu Maslow). Dựa vào đó, các mô hình được phát triển tiêu biểu là các mô hình truyền thống như Mô hình kinh tế, Mô hình học tập, Mô hình tâm lý phân tích và Mô hình xã hội học. Ngoài ra còn có các mô hình hiện đại như Howard-Sheth model (1969), Engel-Kollat-Blackwell model (1978), Nicosia model (1966) và Stimulus-Response Model.

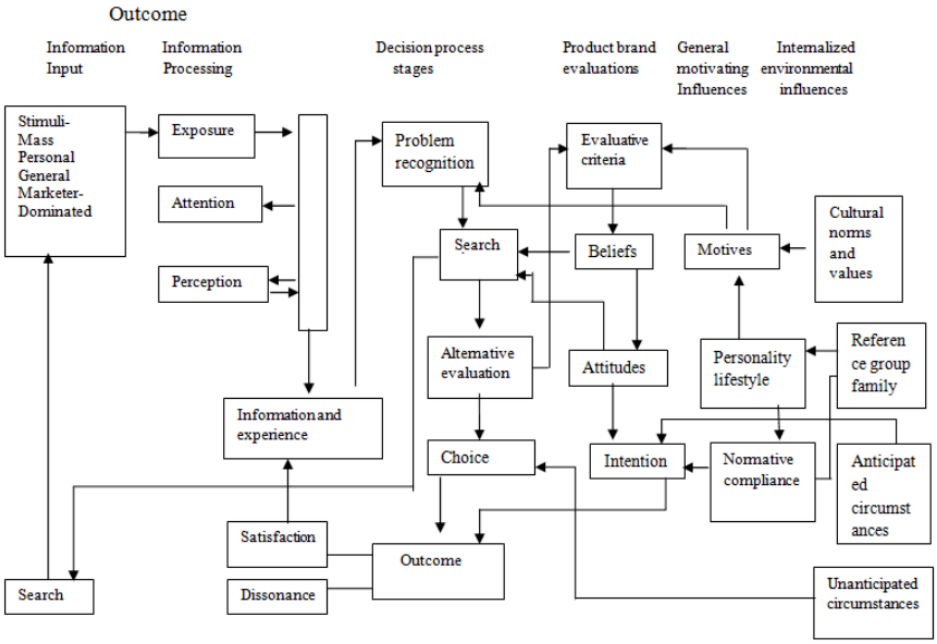

Hình 12. Engel-Kollat-Blackwell model (1978)

Nguồn: Marketing management (S Jayachandran, 2004)

Các mô hình hành vi người tiêu dùng có ứng dụng rộng rãi trong nhiều lĩnh vực, đặc biệt là marketing, thương mại điện tử, trải nghiệm người dùng (UX/UI), quản lý chuỗi cung ứng và công nghệ số. Trong marketing và chiến lược kinh doanh, các mô hình như Howard-Sheth và Engel-Kollat-Blackwell giúp doanh nghiệp phân đoạn thị trường và nhắm đúng đối tượng khách hàng, từ đó xây dựng chiến lược tiếp cận hiệu quả. Trong thương mại điện tử và công nghệ số, các mô hình hành vi giúp tối ưu hóa hành trình khách hàng và cá nhân hóa trải nghiệm mua sắm. Trong lĩnh vực bán lẻ và chuỗi cung ứng, các mô hình hành vi giúp doanh nghiệp dự báo nhu cầu thị trường và tối ưu hóa tồn kho. Việc áp dụng các mô hình hành vi người tiêu dùng vào thực tiễn không chỉ giúp doanh nghiệp tăng doanh thu và nâng cao hiệu quả tiếp thị, mà còn tạo ra trải nghiệm cá nhân hóa cho người dùng, tối ưu hóa quy trình kinh doanh và mở rộng cơ hội phát triển trong nền kinh tế số.

2.2.2. Mô hình đề xuất của nghiên cứu

Khi thu thập được dữ liệu người dùng, hệ thống sẽ tiến hành tiền xử lý dữ liệu; dữ liệu khi đã được làm sạch qua bước tiền xử lý sẽ lấy đi một phần để gán nhãn sau đó chia tập dự liệu đã được xử lý ấy thành các tập dữ liệu là Train (tập huấn luyện), Validation (tập kiểm định) và Test (tập kiểm tra). Hệ thống sẽ sử dụng tập dữ liệu Train để huấn luyện mô hình, sau đó dùng tập kiểm định là Validation để điều chỉnh siêu tham

số và cuối dùng tập kiểm tra Test để đánh giá lại mô hình, nếu kiểm tra đạt mô hình sẽ được đưa vào ứng dụng thực tế.

Thông qua các thuật toán, hệ thống sẽ tạo ra mô hình học bán giám sát tối ưu nhất để gán nhãn người dùng ứng dụng vào cá nhân hóa quảng cáo trong Metaverse. Cụ thể các thuật toán mà hệ thống dùng ở đây là thuật toán Logistic Regression, thuật toán Decision Tree, thuật toán Support Vector Machine (SVM), thuật toán Random Forest, thuật toán K Nearest Neighbor (KNN). Thuật toán Logistic Regression dùng phân loại người dùng qua hình ảnh bài đăng của họ bằng việc tính xác suất một mẫu thuộc về một lớp và sẽ gán nhóm dựa trên một ngưỡng quyết định. Nếu $P(y=1|X) \geq 0.5 \rightarrow$ Gán nhãn 1 tức người dùng có đặc trưng đó và ngược lại.

Thuật toán Decision Tree cũng được dùng để phân loại người dùng dựa trên đặc trưng trích xuất từ hình ảnh. Nó sẽ sử dụng các đặc trưng đầu vào như màu sắc hay hình dạng có trong ảnh để tạo ra một cây quyết định. Với mỗi nút lá của cây (node), Decision Tree sẽ chọn một đặc trưng quan trọng nhất để làm công việc tách dữ liệu. Công đoạn này sẽ được lặp lại nhiều lần cho đến khi dữ liệu không thể tách được nữa. Lúc này khi đưa dữ liệu qua các nhánh của cây, nó sẽ được so sánh thông tin với các nhánh của cây và rơi vào nút lá (leaf node) để nhận nhãn.

Thuật toán Support Vector Machine (SVM) giúp phân loại người dùng với khả năng tìm ra ranh giới tối ưu giữa các nhóm người dùng để giúp mục tiêu quảng cáo cá nhân hóa được chính xác hơn. SVM hoạt động bằng cách tìm một siêu phẳng (hyperplane) để phân tách dữ liệu thành các nhóm khác nhau, sau đó áp dụng kernel để xử lý dữ liệu. Nếu dữ liệu không thể phân tách bằng đường thẳng (phi tuyến tính), SVM sẽ sử dụng kernel trick để biến đổi dữ liệu sang không gian cao hơn, giúp tìm được đường phân chia tốt hơn. Nếu điểm dữ liệu nằm phía trên siêu phẳng thì nó sẽ thuộc nhóm quan tâm đến và ngược lại.

Thuật toán Random Forest dùng trong xác định đặc trưng người dùng để phân loại người dùng vào các chủ đề khác nhau. Nó hoạt động dựa trên cách xây dựng nhiều cây quyết định. Mỗi cây sẽ được huấn luyện trên tập con của dữ liệu và đưa ra dự đoán riêng về đặc trưng của người dùng và khi hi cần phân loại một bài đăng mới, tất cả các cây trong mô hình sẽ bỏ phiếu cho kết quả của nó.

Thuật toán K Nearest Neighbor (KNN) dùng phân loại người dùng vào các chủ đề khác hau theo đặc trưng từng người. Hoạt động dựa trên nguyên tắc tìm điểm dữ liệu gần nhất để đưa dự đoán. Tính khoảng cách giữa hình ảnh đó và tất cả các hình ảnh khác trong tập dữ liệu để tìm ra K ảnh gần nhất với ảnh cần phân loại, sau đó dựa vào ảnh gần nhất để gán nhãn cho ảnh mới. Nhãn phổ biến nhất trong K hàng xóm sẽ được dùng làm kết quả cuối cùng.

Với công dụng và ưu điểm của các thuật toán nêu trên kết hợp với những mô hình lý thuyết mà nhóm đã tham khảo được, nhóm tác giả xin được đề xuất mô hình nghiên cứu của bài dưới đây.

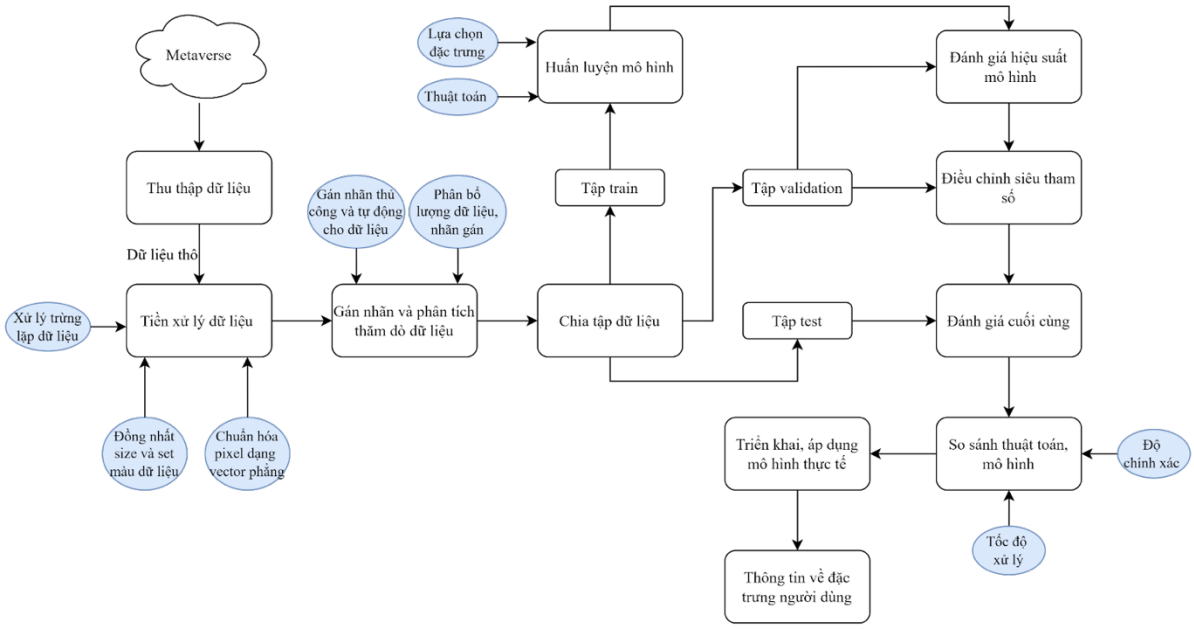

Hình 13. Mô hình đề xuất nghiên cứu

CHƯƠNG 3: PHƯƠNG PHÁP NGHIÊN CỨU

3.1. Phương pháp nghiên cứu

Phương pháp nghiên cứu tài liệu

Phân tích và tổng hợp lý thuyết được sử dụng để xây dựng nền tảng khoa học cho nghiên cứu, đảm bảo tính hệ thống và toàn diện của đề tài. Nhóm nghiên cứu tiến hành khảo sát các công trình khoa học đã được công bố trên các tạp chí quốc tế, hội nghị khoa học, cũng như các tài liệu học thuật liên quan. Những nghiên cứu này cung cấp cái nhìn tổng quan về các phương pháp tiếp cận đã được sử dụng trong việc phân tích đặc trưng người dùng, từ đó giúp nhóm xác định được các khoảng trống nghiên cứu cần được tiếp tục khai thác. Bên cạnh đó, các báo cáo ngành từ các công ty công nghệ lớn như Meta (Facebook), Google, hay các tổ chức nghiên cứu về AI và dữ liệu lớn cũng được xem xét để hiểu rõ hơn về xu hướng phát triển và ứng dụng thực tiễn của công nghệ trong Metaverse. Sau khi thu thập dữ liệu, nhóm tiến hành phân tích, đánh giá điểm mạnh, hạn chế của từng phương pháp, tổng hợp kiến thức từ các nghiên cứu trước từ đó đề xuất một mô hình mới.

Phương pháp thực nghiệm khoa học

Nhóm nghiên cứu tiến hành xây dựng và triển khai mô hình học bán giám sát trên tập dữ liệu thực tế để đánh giá khả năng xác định đặc trưng người dùng trong Metaverse. Bắt đầu bằng việc chuẩn bị dữ liệu huấn luyện, bao gồm thu thập hình ảnh của người dùng trên nền tảng Facebook. Dữ liệu này được làm sạch và xử lý trước khi đưa vào mô hình. Một phần dữ liệu sẽ được gán nhãn thủ công để hỗ trợ quá trình huấn luyện có giám sát, trong khi phần lớn dữ liệu sẽ không có nhãn để mô hình học bán giám sát có thể khai thác thông tin một cách hiệu quả. Triển khai mô hình với 5 thuật toán khác nhau, sau đó tiến hành so sánh, đánh giá hiệu suất của các thuật toán đó.

3.2. Phương pháp đánh giá

3.2.1. Đánh giá độ chính xác và hiệu suất mô hình

Confusion Matrix là một bảng giúp đánh giá hiệu suất của mô hình phân loại bằng cách so sánh kết quả dự đoán với kết quả thực tế. Bảng này chia các dự đoán thành bốn loại: dự đoán đúng cho cả hai lớp (True Positives và True Negatives) và dự đoán sai (False Positives và False Negatives). Nhờ đó, ta có thể xác định các lỗi mà mô hình mắc phải để cải thiện độ chính xác.

Confusion Matrix hiển thị số lượng mẫu mà mô hình tạo ra khi kiểm tra trên tập dữ liệu thử nghiệm. Cụ thể:

- True Positive (TP): Mô hình dự đoán đúng một kết quả dương tính (thực tế cũng là dương tính)
- True Negative (TN): Mô hình dự đoán đúng một kết quả âm tính (thực tế cũng là âm tính)
- False Positive (FP): Mô hình dự đoán sai một kết quả dương tính (thực tế là âm tính), còn gọi là lỗi loại I (Type I error)
- False Negative (FN): Mô hình dự đoán sai một kết quả âm tính (thực tế là dương tính), còn gọi là lỗi loại II (Type II error)

		True Class	
		Positive	Negative
Predicted Class	Positive	True Positive (TP)	False Positive (FP)
	Negative	False Negative (FN)	True Negative (TN)

Hình 14. Confusion Matrix

Nguồn: Sách Business Intelligence and Data Mining

Ngoài đánh giá mức độ chính xác của mô hình, confusion matrix còn hỗ trợ tính toán các chỉ số quan trọng như accuracy, precision, recall, F1-Score.

Accuracy đo lường tần suất mô hình đưa ra dự đoán đúng trên tổng số trường hợp, là chỉ số cung cấp cái nhìn tổng quan về hiệu suất của mô hình. Tuy nhiên, accuracy có thể gây hiểu lầm, đặc biệt với các tập dữ liệu mất cân bằng, nơi một lớp chiếm ưu thế. Ví dụ, một mô hình dự đoán đúng phần lớn các trường hợp thuộc lớp chiếm ưu thế có thể có độ chính xác cao nhưng lại không thể nhận diện tốt các lớp còn lại.

$$Accuracy = \frac{TN + TP}{TN + FP + TP + FN}$$

Precision tập trung vào chất lượng của các dự đoán dương tính, cho biết trong số các trường hợp được mô hình dự đoán là dương tính, có bao nhiêu thực sự đúng. Chỉ số

đặc biệt quan trọng trong các tình huống cần giảm thiểu lỗi dương tính giả (False Positive - FP).

$$Precision = \frac{TP}{TP + FP}$$

Recall đo lường mức độ mô hình có thể nhận diện chính xác tất cả các trường hợp thực sự dương tính. Nó cho thấy tỷ lệ các trường hợp dương tính thực sự được mô hình phát hiện so với tổng số trường hợp dương tính có trong dữ liệu. Chỉ số này rất quan trọng trong những lĩnh vực mà bỏ sót trường hợp dương tính có thể gây hậu quả nghiêm trọng, như chẩn đoán y khoa.

$$Recall = \frac{TP}{TP + FN}$$

Còn F1-Score là chỉ số kết hợp cả precision và recall, giúp cân bằng hai yếu tố này. Đây là thước đo phù hợp với dữ liệu mất cân bằng, nơi mà cả False Positives (FP) và False Negatives (FN) đều quan trọng. Tuy nhiên, F1-score giả định rằng precision và recall có trọng số như nhau, điều này có thể không phù hợp với tất cả các bài toán thực tế.

$$F1\ Score = 2 * \frac{Precision * Recall}{Precision + Recall}$$

3.2.2. Đánh giá thời gian huấn luyện

Thời gian huấn luyện là tiêu chí quan trọng trong việc đánh giá hiệu suất của mô hình. Thời gian huấn luyện phản ánh tốc độ học của mô hình trong quá trình huấn luyện và bị ảnh hưởng bởi nhiều yếu tố, bao gồm các thuộc tính, số lượng mẫu, độ phức tạp của thuật toán và yêu cầu độ chính xác. Số phút hoặc số giờ làm tham chiếu để thiết lập mô hình huấn luyện.

Để đánh giá thời gian huấn luyện, sử dụng phương pháp đo thời gian thực, ghi nhận thời gian bắt đầu và kết thúc huấn luyện mô hình. Bên cạnh đó, chạy các thuật toán khác nhau trên cùng một tập dữ liệu để so sánh thời gian huấn luyện.

Thời gian huấn luyện ngắn được coi là tối ưu, vì giúp giảm thời gian cần thiết để đào tạo mô hình, từ đó tiết kiệm chi phí. Việc đo lường và tối ưu hóa thời gian huấn luyện là cần thiết, ngoài giảm chi phí còn đẩy nhanh quá trình phát triển mô hình và đảm bảo mô hình có thể triển khai thực tế mà không tiêu tốn quá nhiều tài nguyên.

CHƯƠNG 4: KẾT QUẢ NGHIÊN CỨU

4.1. Thu thập và mô tả dữ liệu

4.1.1. Phương pháp và cách thức thu thập dữ liệu

Trước khi tiến hành thu thập dữ liệu, nhóm xác định các tiêu chí cần thiết để đảm bảo dữ liệu phù hợp với mục tiêu nghiên cứu. Đó là chỉ thu thập thông tin từ những tài khoản người dùng hợp lệ, có các hoạt động tương tác rõ ràng trên Facebook, là tài khoản cá nhân không phải fanpage hoặc tài khoản ảo. Các tài khoản Facebook không bị khoá, bị giới hạn nội dung hoặc bị đánh dấu spam. Các tài khoản cần có các bài đăng, hoạt động ít nhất trong 6 tháng trở lại đây. Vì bài nghiên cứu mục tiêu thu thập là mỗi người dùng thu thập 20 ảnh từ trang cá nhân nên người dùng phải có tương tác trên mạng xã hội có đủ ít nhất 20 ảnh. Các ảnh cần có nội dung đa dạng, không nên chỉ có một chủ đề (ví dụ như chỉ có các ảnh tự sướng, ảnh bị trùng lặp,...). Đồng thời, nhóm cũng đề ra tiêu chí không thu thập ảnh vi phạm chính sách cộng đồng của nền tảng Facebook.

Sử dụng nền tảng mạng xã hội để tìm kiếm và thu thập hồ sơ người dùng thủ công. Sau khi có hàng loạt các link người dùng Facebook thì tiến hành sử dụng extension trên Chrome có tên FB AIO để tải ảnh của từng người dùng trên nền tảng Facebook. Kết quả thu thập được 500 tài khoản người dùng Facebook, mỗi người 20 ảnh vậy tổng số ảnh thu được là 10.000 ảnh.

Khi có đủ tất cả các ảnh người dùng, nhóm tiến hành đồng bộ dữ liệu, chỉnh tất cả các ảnh cùng kích thước là 128x128, chuyển đổi toàn bộ ảnh về hệ màu RGB để phù hợp với các thuật toán xử lý hình ảnh. Đồng thời, tất cả các ảnh chuyển về định dạng JPEG (đuôi .jpg). Quá trình tiền xử lý dữ liệu này giúp chuẩn hoá dữ liệu, đảm bảo chất lượng ảnh đồng đều, tạo điều kiện thuận lợi cho việc triển khai chạy mô hình học bán giám sát nhằm xác định đặc trưng người dùng và cá nhân hoá quảng cáo một cách hiệu quả.

4.1.2. Mô tả dữ liệu khảo sát

Dữ liệu thu thập được trong nghiên cứu bao gồm 500 người dùng trên Facebook, mỗi người dùng có 20 ảnh, tạo thành tập dữ liệu tổng cộng 10000 ảnh. Các đặc điểm nhân khẩu học của tập dữ liệu của tập dữ liệu như sau:

Độ tuổi tập trung vào nhóm từ 18 đến 45 tuổi, là nhóm có mức độ sử dụng Facebook cao nhất và có tác động lớn đến hành vi tiêu dùng trên nền tảng,

Giới tính: dữ liệu thu thập của người dùng có giới tính nữ nhiều hơn giới tính nam. Dữ liệu giới tính nữ chiếm khoảng 56% (Tương đương 280 người) tổng dữ liệu trong khi đó dữ liệu của hồ sơ người dùng giới tính nam chỉ chiếm 44% (Tương đương 220 người)

Khu vực địa lí: Hầu hết người dùng trong tập dữ liệu đều là người Việt Nam.

Mức độ hoạt động trên nền tảng Facebook: Các tài khoản có số lượng tương tác nhất định trên nền tảng mạng xã hội Facebook.

4.2. Các kết quả thực nghiệm

4.2.1. Xây dựng bộ dữ liệu thực nghiệm

Dữ liệu thực nghiệm được sử dụng trong nghiên cứu nhằm mục đích xác định đặc trưng người dùng thông qua phân tích hình ảnh bằng phương pháp học bán giám sát. Trong nghiên cứu này, nhóm thu thập được 500 tài khoản người dùng Facebook, mỗi tài khoản cung cấp 20 ảnh, tạo thành tập dữ liệu ban đầu với tổng số 10.000 ảnh. Tuy nhiên, sau quá trình xử lý và loại bỏ các ảnh trùng lặp, số lượng ảnh đạt chuẩn cuối cùng giảm xuống còn 9748 ảnh.

Các ảnh được chuẩn hóa về kích thước 128x128, chuyển sang hệ màu RGB và lưu dưới định dạng JPEG. Sau đó, các ảnh được chuyển đổi thành dạng vector phẳng với các giá trị nằm trong khoảng từ 0 đến 1 để thuận tiện cho việc lưu trữ trong file CSV. Mỗi người dùng được lưu trữ trong một folder riêng biệt, và các folder này được đánh số thứ tự từ 1 đến 500 để phân biệt. Bên trong mỗi folder, các ảnh của người dùng được sắp xếp và đặt tên theo định dạng “a_b”, trong đó “a” đại diện cho số thứ tự của người dùng (từ 1 đến 500) và “b” là số thứ tự của ảnh của người dùng đó (từ 1 đến 20).

Ngoài ra, nhóm nghiên cứu tiến hành gán nhãn cho các ảnh theo 52 loại khác nhau, bao gồm các nhãn: advertise, animal, art, baby, beach, book, camera, charity, children, church, construction, contract, cosmetics, drink, eclectronic_product, event, exhibition, family, fashion, flower, food, game, group_photo, house, lamp, love, nature, news, night, note, party, passport, perfomance, portrait, poster, product, quote, reward, room, school, screen_capture, selfie, sick, sky, sport, store, studying, swimming, tapeworm và transport. Các ảnh được gán nhãn thủ công theo chủ đề và đặc trưng xuất hiện trong từng ảnh, đồng thời, quá trình gán nhãn tự động cũng được thực hiện qua đánh giá chéo K-fold. Khi so sánh kết quả giữa nhãn gán thủ công và nhãn gán tự động, nếu hai nhãn khác nhau thì cột ghi chú sẽ được đánh dấu là 0, ngược lại là 1.

Bảng 1. Bảng mẫu dữ liệu thực nghiệm

STT	Tên ảnh	Pixel_1	Pixel_...	Nhãn gán thủ công	Nhán gán tự động	Ghi chú
1	1_1	0.760784	0.149020	beach	sky	0
2	1_2	0.513725	0.866667	group_photo	group_photo	1
…	…	…	…	…	…	…

4.2.2. Kịch bản thực nghiệm

4.2.2.1. Các bước thực nghiệm

Bước 1. Thu thập dữ liệu

- Tiến hành thu thập thủ công 612 tài khoản người dùng trên nền tảng Facebook.
- Loại bỏ tài khoản ảo, trùng lặp, giữ lại 500 tài khoản đạt chuẩn.
- Thu thập hình ảnh công khai trên trang cá nhân của người dùng bằng công cụ FB AIO.
- Ảnh tải xuống được lưu trong thư mục riêng từng người, sắp xếp theo thứ tự thời gian từ mới đến cũ.

Bước 2. Xử lý dữ liệu

- Đồng nhất kích thước ảnh về 128x128 pixel, chuẩn hóa về hệ màu RGB.
- Lưu trữ ảnh theo thư mục riêng của từng người dùng.
- Chuyển đổi ảnh sang vector phẳng (giá trị từ 0 đến 1) để dễ dàng lưu trữ.
- Lưu trữ dữ liệu dưới dạng CSV với thông tin: số thứ tự, tên ảnh, giá trị pixel.
- Gộp dữ liệu ảnh với nhãn gán thủ công để tạo tập dữ liệu hoàn chỉnh.

Bước 3. Gán nhãn và thăm dò dữ liệu

- Gán nhãn thủ công bằng công cụ hỗ trợ Roboflow với 52 nhãn khác nhau.
- Xuất file CSV chứa thông tin: số thứ tự, tên ảnh, giá trị pixel, nhãn gán thủ công.
- Phân tích sự phân bố nhãn trong tập dữ liệu, điều chỉnh để đảm bảo cân bằng.
- Chia dữ liệu thành tập train (80%) và test (20%).
- Tiến hành đánh giá chéo K-fold với tập train với các thuật toán: Logistic Regression, Decision Tree, Random Forest, SVM, KNN.
- Tính độ chính xác trung bình giữa nhãn thủ công và nhãn gán tự động, tối ưu hóa tham số mô hình.

Bước 4. Chia tập dữ liệu

- Chia tập train (80%) thành 5 folds bằng nhau, 4 fold làm tập train và 1 fold còn lại làm tập validation theo tỷ lệ 80:20, các fold dịch chuyển dần thay phiên nhau. Các tập fold được chia đều dữ liệu theo chủ đề được gán nhãn.
- Tập train: 7798 ảnh.
- Tập validation: 1950 ảnh.
- Tập test (20% ban đầu) có 1950 ảnh, giữ lại để đánh giá mô hình.

Bước 5. Huấn luyện và điều chỉnh tham số mô hình

- Huấn luyện mô hình trên tập train (7798 ảnh) với các thuật toán Logistic Regression, Decision Tree, Random Forest, SVM, KNN.
- Theo dõi các chỉ số: độ chính xác, precision, recall, F1-score.
- Đánh giá trên tập validation để tinh chỉnh siêu tham số, tránh overfitting.

Bước 6. Đánh giá mô hình

- Khi mô hình đạt hiệu suất ổn định, tiến hành kiểm tra trên tập test (1950 ảnh).
- Ghi nhận các chỉ số đánh giá, so sánh giữa các mô hình.
- Triển khai mô hình tối ưu để thu thập thông tin đặc trưng người dùng.
- Ứng dụng kết quả vào hệ thống gợi ý quảng cáo cá nhân hóa trong môi trường Metaverse.

4.2.2.2. Sơ bộ thực nghiệm

Input:

- Tập dữ liệu ảnh của 500 người dùng từ Facebook (9748 ảnh).

Output:

- Kết quả phân loại tương đồng giữa các hình ảnh.
- Xác định đặc điểm trưng người dùng.
- Gợi ý cá nhân hóa quảng cáo trong Metaverse.

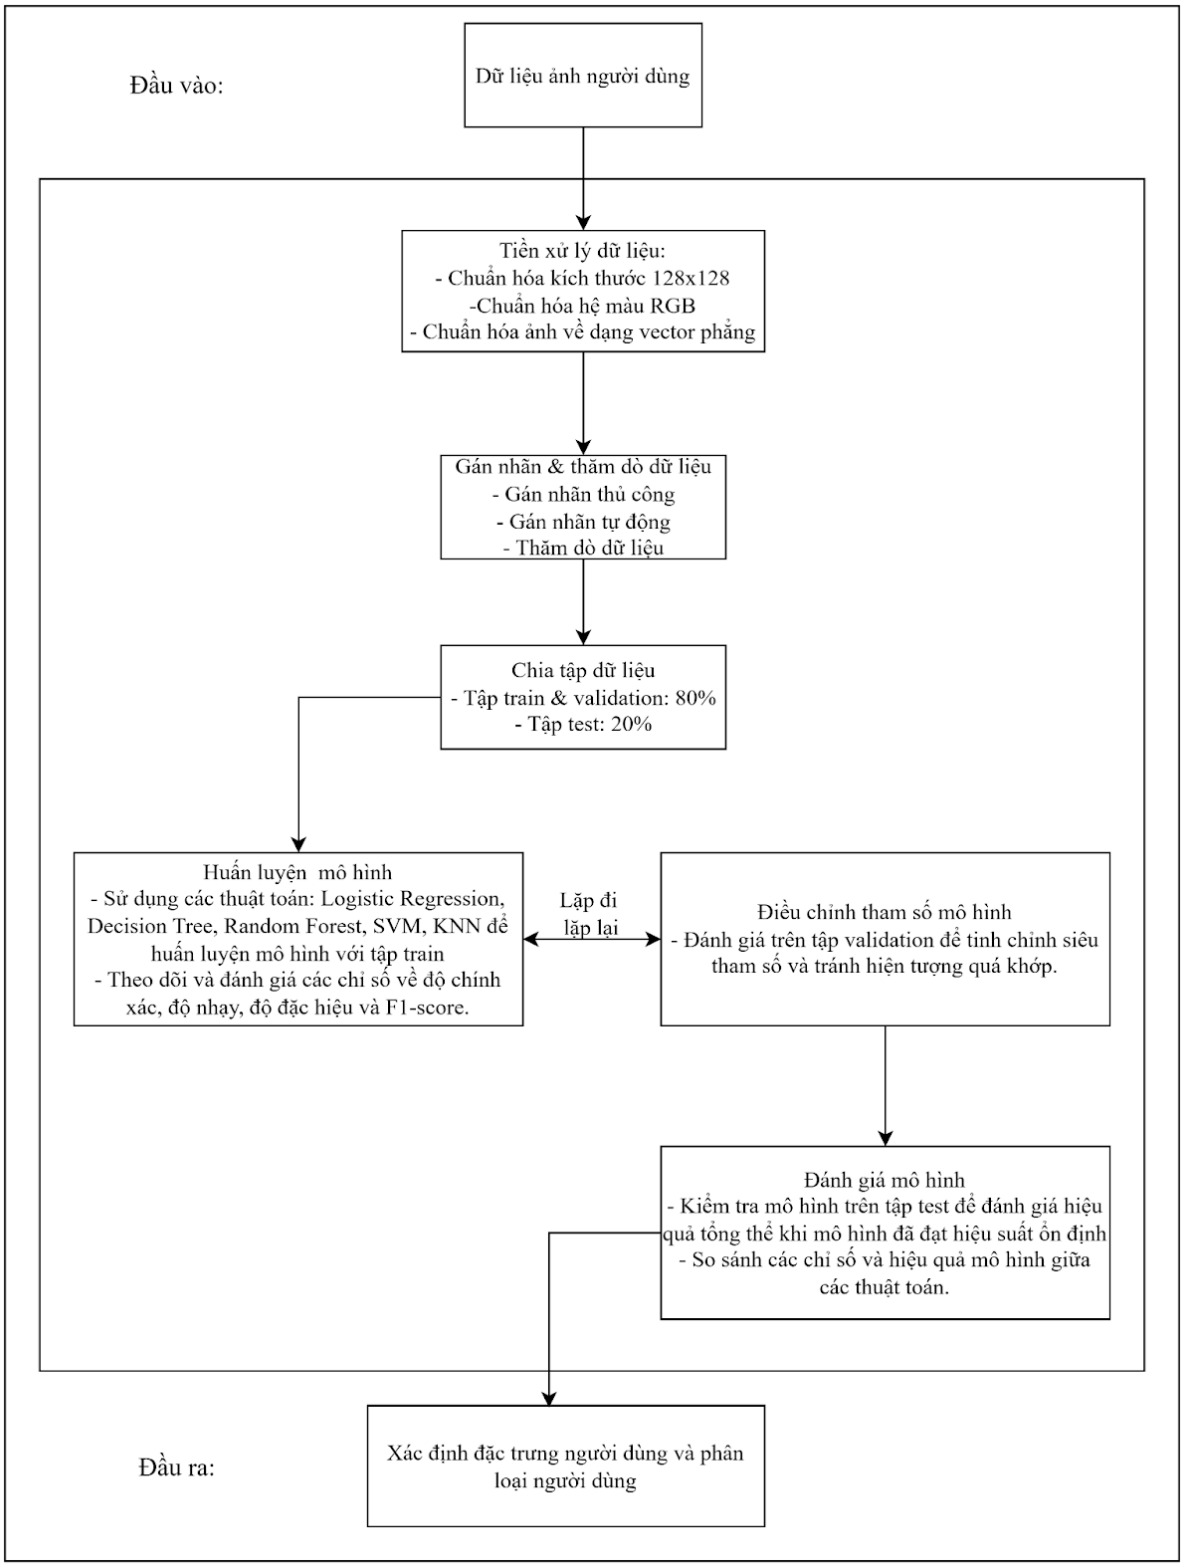

Hình 15. Sơ bộ các bước thực nghiệm

4.2.3. Các kết quả thực nghiệm

4.2.3.1. Các bước thực hiện

Bước 1: Xây dựng bộ dữ liệu về người dùng

Tiến hành thu thập và xử lý dữ liệu người dùng, lọc thủ công những người dùng đạt chuẩn rồi lưu vào trong file excel được chia thành 2 cột gồm cột người dùng và cột ảnh trên trang cá nhân của họ. Sau đó sẽ tải ảnh xuống vào từng folder riêng ứng với mỗi người dùng khác nhau. Tiếp đến chúng tôi sẽ chuyển các ảnh dưới dạng vector, lưu vào trong file csv và gán nhãn chúng.

Bước 2: Tiến hành chạy thực nghiệm

Sau khi thu thập dữ liệu, tiến hành chạy thực nghiệm. Môi trường thực nghiệm được tiến hành làm trên máy tính Intel(R) Core(TM) i5-1235U 1.30 GHz, RAM 16GB, sử dụng ngôn ngữ Python trên hệ điều hành Window 11 và phần mềm Visual Studio Code phiên bản 2020. Folder thực nghiệm là "NCKH_2025" gồm file "Data.csv" là file chứa toàn bộ dữ liệu, "Logistic_Regression.py" là file chứa thuật toán Logistic Regression, "Decision_Tree.py" là file chứa thuật toán Decision Tree, "Random_Forest.py" là file chứa thuật toán Random Forest, "SVM.py" là file chứa thuật toán SVM, "KNN.py" là file chứa thuật toán KNN.

Sau khi chuẩn bị phần cứng, phần mềm cùng dữ liệu đầy đủ, chúng tôi tiến hành chạy thực nghiệm với từng thuật toán/mô hình bằng cách lập một file csv bao gồm các thuộc tính: ID ảnh, vector ảnh, nhãn ảnh, kết quả chạy các thuật toán. Chúng tôi tiến hành chạy lần lượt từng mô hình dựa trên thứ tự file csv bên trên. Sau mỗi lần chạy xong, chúng tôi tiến hành ghi kết quả vào từng cột và ô tương ứng với thuật toán.

4.2.3.2. Kết quả

Tiến hành chạy thực nghiệm và thu được kết quả như sau:

+ Thuật toán Logistic Regression

```
Fold 1: Accuracy = 0.7103
Fold 2: Accuracy = 0.7125
Fold 3: Accuracy = 0.7154
Fold 4: Accuracy = 0.7097
Fold 5: Accuracy = 0.7119

Độ chính xác trung bình của Logistic Regression trên 5 folds: 0.7120
Độ chính xác trên tập test: 0.7059
```

Hình 16. Kết quả đánh giá mô hình Logistic Regression

Nguồn: Kết quả thực nghiệm từ Python

+ Thuật toán Decision Tree

```
Fold 1: Accuracy = 0.6305
Fold 2: Accuracy = 0.6284
Fold 3: Accuracy = 0.6332
Fold 4: Accuracy = 0.6291
Fold 5: Accuracy = 0.6315

Độ chính xác trung bình của Decision Tree trên 5 folds: 0.6305
Độ chính xác trên tập test: 0.6397
```

Hình 17. Kết quả đánh giá mô hình Decision Tree

Nguồn: Kết quả thực nghiệm từ Python

+ Thuật toán Random Forest

```
Fold 1: Accuracy = 0.7931
Fold 2: Accuracy = 0.7860
Fold 3: Accuracy = 0.7942
Fold 4: Accuracy = 0.7795
Fold 5: Accuracy = 0.7873

Độ chính xác trung bình của Random Forest trên 5 folds: 0.7880
Độ chính xác trên tập test: 0.7868
```

Hình 18. Kết quả đánh giá mô hình Random Forest

Nguồn: Kết quả thực nghiệm từ Python

+ Thuật toán SVM

```
Fold 1: Accuracy = 0.7416
Fold 2: Accuracy = 0.7402
Fold 3: Accuracy = 0.7451
Fold 4: Accuracy = 0.7398
Fold 5: Accuracy = 0.7421

Độ chính xác trung bình của SVM trên 5 folds: 0.7418
Độ chính xác trên tập test: 0.7342
```

Hình 19. Kết quả đánh giá mô hình SVM

Nguồn: Kết quả thực nghiệm từ Python

+ Thuật toán KNN

```
Fold 1: Accuracy = 0.6847
Fold 2: Accuracy = 0.6890
Fold 3: Accuracy = 0.6923
Fold 4: Accuracy = 0.6808
Fold 5: Accuracy = 0.6856

Độ chính xác trung bình của KNN trên 5 folds: 0.6865
Độ chính xác trên tập test: 0.6923
```

Hình 20. Kết quả đánh giá mô hình KNN

Nguồn: Kết quả thực nghiệm từ Python

4.2.4. So sánh với các mô hình đã có

Bảng 2. So sánh độ chính xác của các mô hình trên từng tập fold và tập test

Fold	Logistic Regression	Decision Tree	Random Forest	SVM	KNN
Fold 1	0.7103	0.6305	0.7931	0.7416	0.6847
Fold 2	0.7125	0.6284	0.7860	0.7402	0.6890
Fold 3	0.7154	0.6332	0.7942	0.7451	0.6923
Fold 4	0.7097	0.6291	0.7795	0.7398	0.6808
Fold 4	0.7119	0.6315	0.7873	0.7421	0.6856
Test	0.7059	0.6397	0.7868	0.7342	0.6923

Nguồn: Kết quả thực nghiệm tổng hợp từ nghiên cứu

Bảng 3. So sánh hiệu suất các thuật toán

Thuật toán	Accuracy trung bình trên 5 folds	Accuracy trên tập test	Precision	Recall	F1-Score	Thời gian huấn luyện
Logistic Regression	0.7120	0.7059	0.7108	0.6996	0.7047	212.5s
Decision Tree	0.6305	0.6397	0.6412	0.6193	0.6315	123.74s
Random Forest	0.7880	0.7868	0.7898	0.7802	0.7856	7.19s
SVM	0.7418	0.7342	0.7409	0.7305	0.7354	170.56s
KNN	0.6865	0.6923	0.6895	0.6808	0.6856	2.09s

Nguồn: Kết quả thực nghiệm tổng hợp từ nghiên cứu

4.3. Đánh giá và thảo luận kết quả thực nghiệm

4.3. Đánh giá chung

Trong quá trình thực nghiệm, các mô hình học máy khác nhau đã được sử dụng để đánh giá độ chính xác của bài toán. Các thuật toán được so sánh bao gồm K-Nearest Neighbors (KNN), Decision Tree, Logistic Regression, Support Vector Machine (SVM) và Random Forest. Kết quả của các mô hình này được đánh giá dựa trên nhiều tiêu chí khác nhau như độ chính xác trung bình trên tập huấn luyện (5-fold cross-validation), độ chính xác trên tập kiểm tra (test set), Precision, Recall, F1-Score và thời gian huấn luyện.

Kết quả thực nghiệm cho thấy Random Forest là mô hình có độ chính xác cao nhất, với độ chính xác trung bình trên tập huấn luyện đạt 0.7880 và độ chính xác trên tập kiểm tra là 0.7868. Điều này phản ánh khả năng tổng quát hóa tốt của mô hình này, giúp nó hoạt động ổn định trên cả tập huấn luyện và kiểm tra. Đặc biệt, thời gian huấn luyện của Random Forest là 7.19 giây, thấp hơn nhiều so với các thuật toán phức tạp khác, giúp nó trở thành một lựa chọn hiệu quả cả về độ chính xác và hiệu suất tính toán.

Mô hình SVM cũng cho kết quả tốt, với độ chính xác trung bình đạt 0.7418 trên tập huấn luyện và 0.7342 trên tập kiểm tra. Mặc dù thấp hơn so với Random Forest, SVM vẫn cho thấy sự ổn định. Tuy nhiên, thời gian huấn luyện của SVM lên đến 170.56 giây, cao hơn đáng kể so với các thuật toán khác, cho thấy nhược điểm về mặt tính toán của mô hình này.

Mô hình Logistic Regression đạt độ chính xác trung bình 0.7120 và độ chính xác trên tập kiểm tra là 0.7059, cho thấy khả năng tổng quát hóa ổn định. Tuy nhiên, mô hình này có thời gian huấn luyện dài nhất (212.5 giây), làm giảm tính ứng dụng nếu cần triển khai trên tập dữ liệu lớn.

Mô hình KNN có độ chính xác trung bình trên tập huấn luyện là 0.6865 và trên tập kiểm tra là 0.6923. Đây là một mô hình đơn giản, không yêu cầu quá trình huấn luyện nhưng lại có thời gian dự đoán lâu hơn so với các thuật toán khác. Thời gian huấn luyện chỉ 2.09 giây, giúp KNN trở thành một lựa chọn phù hợp cho các bài toán yêu cầu tốc độ triển khai nhanh.

Cuối cùng, mô hình Decision Tree có độ chính xác thấp nhất, với giá trị trung bình trên tập huấn luyện là 0.6305 và trên tập kiểm tra là 0.6397. Điều này có thể là do Decision Tree dễ bị overfitting, dẫn đến độ chính xác trên tập kiểm tra không cao. Thời

gian huấn luyện của mô hình này là 123.74 giây, nhanh hơn Logistic Regression và SVM nhưng vẫn khá cao so với Random Forest.

4.4. Những hạn chế và các vấn đề khác

Mặc dù các thuật toán triển khai đã cho kết quả khá tốt, vẫn tồn tại một số hạn chế nhất định. Một trong những vấn đề quan trọng là khả năng khái quát của mô hình. Chẳng hạn, Decision Tree có độ chính xác thấp nhất và dễ bị ảnh hưởng bởi dữ liệu huấn luyện, dẫn đến hiệu suất kém khi áp dụng vào dữ liệu mới. Trong khi đó, Random Forest tuy có độ chính xác cao nhưng vẫn có nguy cơ overfitting nếu không được điều chỉnh tham số một cách hợp lý.

Chất lượng dữ liệu cũng đóng vai trò quan trọng trong kết quả mô hình. Nếu dữ liệu huấn luyện không đầy đủ hoặc có sự mất cân bằng giữa các nhóm, mô hình có thể học sai lệch và không phản ánh chính xác bản chất của vấn đề. Điều này đặc biệt ảnh hưởng đến các thuật toán nhạy cảm với phân bố dữ liệu, chẳng hạn như Logistic Regression và SVM, dẫn đến hiệu suất không ổn định trên tập kiểm tra.

Bên cạnh đó, hiệu suất tính toán là một yếu tố cần cân nhắc. Các mô hình phức tạp như SVM hay Logistic Regression có thời gian huấn luyện rất dài (lần lượt 170.56 giây và 212.5 giây), trong khi Random Forest cho kết quả tốt hơn nhưng chỉ mất 7.19 giây để huấn luyện. Ngược lại, KNN có thời gian huấn luyện nhanh nhất (2.09 giây), nhưng thường mất nhiều thời gian khi dự đoán. Điều này cho thấy việc lựa chọn mô hình không chỉ dựa vào độ chính xác mà còn cần xem xét đến tài nguyên tính toán và yêu cầu triển khai thực tế, đặc biệt khi xử lý lượng dữ liệu lớn trong thời gian ngắn.

CHƯƠNG 5: KẾT LUẬN VÀ CÁC HÀM Ý

5.1. Kết luận

Trong quá trình thực hiện nghiên cứu, nhóm đã đạt được nhiều kết quả quan trọng trong việc phân tích hành vi người dùng thông qua hình ảnh trên mạng xã hội, nhằm phục vụ cho mục tiêu cá nhân hóa quảng cáo trong môi trường Metaverse. Trước tiên, nhóm đã xây dựng được phương pháp thu thập dữ liệu hình ảnh từ các bài đăng và bình luận trên Facebook, tạo ra bộ dữ liệu bao gồm 500 người dùng với 9748 hình ảnh. Mặc dù quy mô chưa quá lớn, nhưng đây chính là bước đầu quan trọng để tiến hành thực nghiệm và đánh giá tính khả thi của hướng tiếp cận này.

Nhóm nghiên cứu cũng đã áp dụng các thuật toán như: Logistic Regression, Decision Tree, Random Forest, SVN, KNN và mô hình Self - trainning để phân tích và so sánh mức độ tương đồng giữa các hình ảnh. Đặc biệt, nhóm đã đề xuất phương pháp chia khoảng giá trị pixel thành nhiều nhóm, sau đó tiến hành so sánh từng cặp hình ảnh giữa các người dùng, nhằm xác định mức độ tương đồng và phân loại chúng vào các khoảng giá trị cụ thể, từ đó rút ra những đặc điểm chung của các nhóm người dùng có sở thích tương đồng. Phương pháp này giúp đơn giản hóa việc đánh giá sự giống nhau giữa các hình ảnh, đồng thời hỗ trợ quá trình xây dựng mô hình bán giám sát cho việc gán nhãn tự động.

Bên cạnh những kết quả đạt được, nhóm cũng nhận diện một số hạn chế như quy mô dữ liệu còn nhỏ so với nhu cầu thực tế, độ chính xác của mô hình vẫn cần được cải thiện và quy trình gán nhãn dữ liệu có thể tối ưu hơn. Tuy nhiên, những kết quả thu được đã tạo tiền đề quan trọng cho các nghiên cứu tiếp theo. Trong tương lai, nhóm sẽ mở rộng quy mô dữ liệu, tích hợp thêm thông tin văn bản từ bài đăng, đồng thời ứng dụng các phương pháp học sâu như Convolutional Neural Networks (CNN) hoặc Siamese Network để nâng cao độ chính xác trong việc nhận diện sở thích người dùng.

5.2. Các hàm ý về giải pháp

Trong lĩnh vực marketing

Việc ứng dụng phân tích hình ảnh từ các bài đăng trên mạng xã hội mang lại nhiều lợi ích to lớn, đặc biệt là trong việc nhận diện rõ hơn sở thích và hành vi của khách hàng. Mỗi hình ảnh mà người dùng chia sẻ, dù là về sản phẩm yêu thích, không gian sống hay phong cách cá nhân, đều chứa đựng những thông tin quý giá giúp doanh nghiệp thấu hiểu thị hiếu và nhu cầu tiềm ẩn của họ. Thông qua việc phân tích các hình ảnh

này, doanh nghiệp có thể phát hiện ra những xu hướng tiêu dùng mới, nhận diện các nhóm khách hàng có đặc điểm sở thích tương đồng và từ đó xây dựng các hệ thống gợi ý sản phẩm mang tính cá nhân hóa cao. Để đạt được điều này, doanh nghiệp cần đầu tư mạnh mẽ vào việc phát triển các thuật toán phân cụm và học máy nhằm xác định những điểm chung trong hành vi mua sắm và sở thích của từng nhóm khách hàng. Các thuật toán này sẽ đóng vai trò quan trọng trong việc xử lý lượng lớn dữ liệu hình ảnh, trích xuất các đặc trưng quan trọng như màu sắc, kiểu dáng, thương hiệu hay bối cảnh sử dụng sản phẩm, từ đó tạo ra những mô hình gợi ý sản phẩm sát với nhu cầu thực tế của từng khách hàng hơn.

Việc tối ưu hóa quy trình quản lý sản phẩm thông qua phân tích xu hướng từ dữ liệu hình ảnh cũng là một giải pháp quan trọng giúp các cửa hàng trực tuyến nhanh chóng điều chỉnh danh mục sản phẩm. Khi nhận thấy một mẫu sản phẩm nào đó xuất hiện thường xuyên trong các bài đăng, doanh nghiệp có thể kịp thời bổ sung sản phẩm đó vào kho hàng hoặc đẩy mạnh các chương trình khuyến mãi liên quan. Đồng thời, việc theo dõi và phân tích xu hướng này còn giúp doanh nghiệp nhận diện các sản phẩm ít được quan tâm để điều chỉnh chiến lược kinh doanh, tối ưu hóa việc phân bổ nguồn lực và tăng hiệu quả bán hàng.

Trong học máy

Việc áp dụng các phương pháp bán giám sát đóng vai trò quan trọng trong việc giảm thiểu chi phí gán nhãn dữ liệu, đồng thời tận dụng hiệu quả nguồn dữ liệu chưa gán nhãn - vốn chiếm tỷ lệ lớn trong thực tế. Phương pháp này cho phép mô hình học từ một lượng nhỏ dữ liệu đã được gán nhãn ban đầu, sau đó sử dụng những thông tin thu được để gán nhãn cho phần dữ liệu còn lại, tạo ra một quy trình huấn luyện hiệu quả hơn. Đây là giải pháp phù hợp cho các bài toán phân tích hình ảnh trong marketing, nơi việc gán nhãn thủ công không chỉ tốn kém thời gian mà còn đòi hỏi chi phí nhân lực lớn.

Các nhóm nghiên cứu nên ưu tiên phát triển những mô hình học sâu như Convolutional Neural Networks (CNN) hoặc Siamese Neural Network để trích xuất đặc trưng từ hình ảnh một cách tự động và chính xác thay vì so sánh trực tiếp dựa vào giá trị pixel để giúp phát hiện ra những đặc trưng quan trọng như màu sắc chủ đạo, họa tiết, kiểu dáng hay logo thương hiệu. Việc kết hợp nhiều nguồn dữ liệu giữa hình ảnh với văn bản hay mối quan hệ bạn bè, hoạt động tham gia các hội nhóm sẽ tạo ra một hệ

thống học đa phương thức giúp tận dụng đồng thời nhiều loại thông tin khác nhau để nhận diện sở thích khách hàng một cách chính xác hơn.

Để đảm bảo tính ứng dụng và mở rộng quy mô trong tương lai, các doanh nghiệp và nhóm nghiên cứu cần xây dựng cơ sở hạ tầng xử lý dữ liệu lớn, bao gồm việc triển khai các giải pháp điện toán đám mây và kiến trúc microservices để quản lý khối lượng dữ liệu khổng lồ. Việc liên tục cập nhật và cải thiện các mô hình học máy, thông qua việc huấn luyện lại với dữ liệu mới và đánh giá hiệu năng định kỳ, sẽ giúp hệ thống thích ứng tốt hơn với sự thay đổi của thị trường và hành vi người dùng. Đây chính là bước đi quan trọng để tạo ra một nền tảng phân tích dữ liệu mạnh mẽ, phục vụ cho việc cá nhân hóa trải nghiệm khách hàng trong môi trường thương mại điện tử và Metaverse ngày càng phát triển.

5.3. Hạn chế và hướng nghiên cứu tiếp theo

Hạn chế về hướng nghiên cứu

Các thuật toán, mô hình mà nhóm nghiên cứu lựa chọn chưa phải là các thuật toán, mô hình tốt nhất, điều này có thể ảnh hưởng tới kết quả thực nghiệm. Nhóm nghiên cứu hy vọng điều này sẽ được cải thiện trong các nghiên cứu tiếp theo. Việc sử dụng so sánh trực tiếp giữa các cặp hình ảnh dựa trên độ tương đồng pixel có thể không đủ mạnh để phát hiện các đặc trưng ngữ nghĩa sâu hơn, đặc biệt là trong các bối cảnh hình ảnh phức tạp hoặc mang tính trừu tượng. Nhóm nghiên cứu phân nhóm người dùng dựa vào độ tương đồng hình ảnh, thiếu đi sự kết hợp thông tin hình ảnh và các nguồn dữ liệu khác như: văn bản trong ảnh, văn bản/caption đi kèm, mối quan hệ bạn bè, hoạt động tham gia hội nhóm của người dùng khiến cho việc đánh giá sở thích người dùng có thể chưa toàn diện.

Hướng nghiên cứu tiếp theo

Trong những hướng nghiên cứu tiếp theo, việc kết hợp phân tích văn bản và hình ảnh sẽ giúp nâng cao độ chính xác trong việc xác định sở thích người dùng. Cụ thể, có thể áp dụng các kỹ thuật nhận dạng ký tự quang học (OCR) như Tesseract hoặc Google Vision để trích xuất văn bản từ hình ảnh, sau đó sử dụng các mô hình xử lý ngôn ngữ tự nhiên để phân tích nội dung, cảm xúc và chủ đề của các bài viết. Đặc trưng từ văn bản và hình ảnh sẽ được kết hợp lại thông qua việc sử dụng các mạng nơ-ron tích chập (CNN) cho hình ảnh và mạng hồi quy (RNN) hoặc Transformer cho văn bản để phân tích hành vi người dùng một cách toàn diện hơn.

Việc tích hợp dữ liệu đa nguồn là một hướng đi tiềm năng nhằm tăng cường độ chính xác cho mô hình. Khai thác mạng lưới quan hệ xã hội, chẳng hạn như các nhóm chung hoặc danh sách bạn bè, … sẽ giúp xác định các cộng đồng nhỏ, qua đó phân tích sở thích theo nhóm người dùng có mối liên kết chặt chẽ. Bên cạnh đó, việc bổ sung các thông tin từ hồ sơ cá nhân như giới tính, độ tuổi, hay nghề nghiệp cũng sẽ góp phần xây dựng mô hình cá nhân hóa sát với thực tế hơn.

Việc phân nhóm người dùng thông qua phân tích hình ảnh có thể được áp dụng rộng rãi hơn ở nhiều lĩnh vực khác nhau: y tế, giáo dục, … xong cũng cần phải xem xét để sử dụng các thuật toán và mô hình sao cho phù hợp với bài toán đặt ra.

DANH MỤC TÀI LIỆU THAM KHẢO

TÀI LIỆU TIẾNG ANH

1. Rosencrance, L. (2025, February 9). *Is Metaverse Dead? The State of Virtual Worlds in 2025*. Retrieved from Techopedia: https://www.techopedia.com/is-metaverse-dead
2. Tucci, L. (2024, March 22). *What is the metaverse? An explanation and in-depth guide*. Retrieved from https://www.techtarget.com/whatis/feature/The-metaverse-explained-Everything-you-need-to-know
3. Wang, N. (2023, May 9). *Facebook Parent Meta's Metaverse Division Lost $13.7B in 2022*. Retrieved from Coindesk: https://www.coindesk.com/business/2023/02/01/facebook-parent-metas-metaverse-division-lost-137b-in-2022
4. Robbie Whelan, Joe Flint. (2023, March 28). *Disney Eliminates Its Metaverse Division as Part of Company's Layoffs Plan*. Retrieved from The wall street journal: https://www.wsj.com/articles/disney-eliminates-its-metaverse-division-as-part-of-companys-layoffs-plan-94b03650
5. Monteros, M. (2023, April 12). *Major retail players are walking back their metaverse strategies*. Retrieved from ModernRetail: https://www.modernretail.co/technology/major-retail-players-are-walking-back-their-metaverse-strategies/
6. Statista. (n.d.). *Metaverse - Worldwide| Statista market forecast*. Retrieved from Statista: https://www.statista.com/outlook/amo/metaverse/worldwide
7. Courtney Buzzell, Zamir Lalji, Amanda Loyola, Kim Rants, Emily Scofield, Stephan Zimmermann. (2023, June 8). *Unlocking commerce in the metaverse*. Retrieved from McKinsey & Company: https://www.mckinsey.com/capabilities/growth-marketing-and-sales/our-insights/unlocking-commerce-in-the-metaverse
8. *Facebook Users, Stats, Data & Trends for 2025*. (2025). Retrieved from DataReportal: https://datareportal.com/essential-facebook-stats
9. Barnhart, B. (2025, February 20). *31 Facebook statistics marketers should know in 2025* . Retrieved from Sprout Blog / Social Media Marketing: https://sproutsocial.com/insights/facebook-stats-for-marketers/#facebook-advertising-and-marketing-statistics
10. Stephenson, N. (1992). *Snow Crash.*

11. *How Many People Play SL in 2025?* (2025). Retrieved from PlayerAuctions: https://www.playerauctions.com/player-count/sl/
12. Maheshwari, A. K. (2015). *Business intelligence and data mining.*
13. Zhao, Y., Jiang, J., Chen, Y., Liu, R., Yang, Y., Xue, X., & Chen, S. (2022). Metaverse: Perspectives from graphics, interactions and visualization. *Visual Informatics*, *6*(1), 56–67. https://doi.org/10.1016/j.visinf.2022.03.002
14. Berge, Z. L. (2008). Multi-User Virtual Environments for Education and Training? A Critical Review of "Second Life." *Educational Technology*, *48*(3), 27–31. http://www.jstor.org/stable/44429575
15. SL Live Player Count & Population 2025. (n.d.). https://www.playerauctions.com/player-count/sl/
16. Herrman, J., & Browning, K. (2021, July 10). *Are we in the metaverse yet?*. The New York Times. https://www.nytimes.com/2021/07/10/style/metaverse-virtual-worlds.html
17. G. D. Ritterbusch and M. R. Teichmann, "Defining the Metaverse: A Systematic Literature Review," in *IEEE Access*, vol. 11, pp. 12368-12377, 2023, doi: 10.1109/ACCESS.2023.3241809
18. *The metaverse and the implications for the securitie industry.* FINRA. (2024, October). https://www.finra.org/sites/default/files/2024-10/2024-the-metaverse-and-the-implications-for-the-securities-industry.pdf
19. *metaverse*. (2025). https://dictionary.cambridge.org/dictionary/english/
20. Morgan, J. P. (2022). Opportunities in the metaverse | How businesses can explore the metaverse and navigate the hype vs. reality. https://www.jpmorgan.com/content/dam/jpm/treasuryservices/documents/opportunities-in-the-metaverse.pdf
21. Shead, S. (2021, November 17). *The metaverse is investable - and it's going to be big, says tech billionaire*. CNBC. https://www.cnbc.com/2021/11/15/orlando-bravo-metaverse-is-investable-and-its-going-to-be-very-big.html
22. Dwivedi, Y. K., Hughes, L., Baabdullah, A. M., Ribeiro-Navarrete, S., Giannakis, M., Al-Debei, M. M., Dennehy, D., Metri, B., Buhalis, D., Cheung, C. M. K., Conboy, K., Doyle, R., Dubey, R., Dutot, V., Felix, R., Goyal, D. P., Gustafsson, A., Hinsch, C., Jebabli, I., … Wamba, S. F. (2022). Metaverse beyond the hype:

Multidisciplinary perspectives on emerging challenges, opportunities, and agenda for research, practice and policy. *International Journal of Information Management*, *66*, 102542. https://doi.org/10.1016/j.ijinfomgt.2022.102542

23. *Connect 2021: Our vision for the metaverse*. Tech at Meta. (2021, October 28). https://tech.facebook.com/reality-labs/2021/10/connect-2021-our-vision-for-the-metaverse/
24. Zhang, X., Chen, Y., Hu, L., & Wang, Y. (2022). The metaverse in education: Definition, framework, features, potential applications, challenges, and future research topics. *Frontiers in Psychology*, *13*. https://doi.org/10.3389/fpsyg.2022.1016300
25. Almahasees, Z., Mohsen, K., & Amin, M. O. (2021). Faculty's and Students' perceptions of online learning during COVID-19. *Frontiers in Education*, *6*. https://doi.org/10.3389/feduc.2021.638470
26. R. Chengoden *et al*., "Metaverse for Healthcare: A Survey on Potential Applications, Challenges and Future Directions," in *IEEE Access*, vol. 11, pp. 12765-12795, 2023, doi: 10.1109/ACCESS.2023.3241628
27. Büchel, H., & Spinler, S. (2024). The impact of the metaverse on e-commerce business models – a Delphi-based scenario study. *Technology in Society*, *76*, 102465. https://doi.org/10.1016/j.techsoc.2024.102465
28. Ojha, V. (2023, May 17). *The metaverse in media and entertainment: Things to know*. A3Logics. https://www.a3logics.com/blog/the-metaverse-in-media-and-entertainment-things-to-know/
29. M. Uddin, S. Manickam, H. Ullah, M. Obaidat and A. Dandoush, "Unveiling the Metaverse: Exploring Emerging Trends, Multifaceted Perspectives, and Future Challenges," in *IEEE Access*, vol. 11, pp. 87087-87103, 2023, doi: 10.1109/ACCESS.2023.3281303.
30. Allam, Z., Sharifi, A., Bibri, S. E., Jones, D. S., & Krogstie, J. (2022). The metaverse as a virtual form of smart cities: Opportunities and challenges for environmental, economic, and Social Sustainability in Urban Futures. *Smart Cities*, *5*(3), 771–801. https://doi.org/10.3390/smartcities5030040

31. Safari, R. M., Rahmani, A. M., & Alizadeh, S. H. (2019). User behavior mining on social media: A systematic literature review. *Multimedia Tools and Applications*, *78*(23), 33747–33804. https://doi.org/10.1007/s11042-019-08046-6
32. Tran, T. P. (2017). Personalized ads on Facebook: An effective marketing tool for online marketers. *Journal of Retailing and Consumer Services*, *39*, 230–242. https://doi.org/10.1016/j.jretconser.2017.06.010
33. Vesanen, J. (2007). What is personalization? A conceptual framework. *European Journal of Marketing*, *41*(5/6), 409–418. https://doi.org/10.1108/03090560710737534
34. Ostrom, A. L., Parasuraman, A., Bowen, D. E., Patrício, L., & Voss, C. A. (2015). Service research priorities in a rapidly changing context. *Journal of Service Research*, *18*(2), 127–159. https://doi.org/10.1177/1094670515576315
35. van Engelen, J. E., & Hoos, H. H. (2019). A survey on semi-supervised learning. *Machine Learning*, *109*(2), 373–440. https://doi.org/10.1007/s10994-019-05855-6
36. X. Yang, Z. Song, I. King and Z. Xu, "A Survey on Deep Semi-Supervised Learning," in *IEEE Transactions on Knowledge and Data Engineering*, vol. 35, no. 9, pp. 8934-8954, 1 Sept. 2023, doi: 10.1109/TKDE.2022.3220219
37. *Logistic regression in machine learning*. GeeksforGeeks.(2025, February 3). https://www.geeksforgeeks.org/understanding-logistic-regression/
38. Grover, K. (2020, June 23). *Advantages and disadvantages of logistic regression*. OpenGenus IQ: Learn Algorithms, DL, System Design. https://iq.opengenus.org/advantages-and-disadvantages-of-logistic-regression/
39. Justin, L. &. (2020, June 5). *Logistic Regression for Machine Learning: Complete tutorial*. Just into Data. https://www.justintodata.com/logistic-regression-for-machine-learning-tutorial/
40. Ibm. (2025, January 22). *What is a decision tree?*. IBM. https://www.ibm.com/topics/decision-trees#:~:text=A decision tree is a,internal nodes and leaf nodes.
41. *Decision tree*. GeeksforGeeks. (2025, January 16). https://www.geeksforgeeks.org/decision-tree/

42. Ibm. (2024, December 19). *What is Random Forest?*. IBM. https://www.ibm.com/think/topics/random-forest
43. *Random Forest algorithm in machine learning*. GeeksforGeeks. (2025, January 16). https://www.geeksforgeeks.org/random-forest-algorithm-in-machine-learning/
44. *Random forests*. DeepAI. (2020, September 10). https://deepai.org/machine-learning-glossary-and-terms/random-forest
45. Breiman, L. (2001). *Machine Learning*, *45*(1), 5–32. https://doi.org/10.1023/a:1010933404324
46. Cortes, C., & Vapnik, V. (1995). Support-Vector Networks. *Machine Learning*, *20*(3), 273–297. https://doi.org/10.1007/bf00994018
47. Noble, W.S. (2006). A biologist ' s introduction to support vector machines. https://noble.gs.washington.edu/papers/noble2006biologists.pdf
48. Sharma, V., Sharma, D., Tsai, M.-L., Ortizo, R. G., Yadav, A., Nargotra, P., Chen, C.-W., Sun, P.-P., & Dong, C.-D. (2023). Insights into the recent advances of agro-industrial waste valorization for Sustainable Biogas production. *Bioresource Technology*, *390*, 129829. https://doi.org/10.1016/j.biortech.2023.129829
49. Nghị L.V., Ngọc N.M. (2023). Ứng dụng thuật toán SVM dự báo chiều dài nước nhảy trên kênh hình thang cân. *TẠP CHÍ KHOA HỌC VÀ CÔNG NGHỆ THỦY LỢI*
50. Lin, S.-L. (2021). Application of machine learning to a medium gaussian support vector machine in the diagnosis of motor bearing faults. *Electronics*, *10*(18), 2266. https://doi.org/10.3390/electronics10182266
51. Ibm. (2024b, December 19). *What is support vector machine?*. IBM. https://www.ibm.com/think/topics/support-vector-machine
52. Wu, X., Kumar, V., Ross Quinlan, J., Ghosh, J., Yang, Q., Motoda, H., McLachlan, G. J., Ng, A., Liu, B., Yu, P. S., Zhou, Z.-H., Steinbach, M., Hand, D. J., & Steinberg, D. (2007). Top 10 algorithms in Data Mining. *Knowledge and Information Systems*, *14*(1), 1–37. https://doi.org/10.1007/s10115-007-0114-2
53. T. Cover and P. Hart, "Nearest neighbor pattern classification," in IEEE Transactions on Information Theory, vol. 13, no. 1, pp. 21-27, January 1967, doi: 10.1109/TIT.1967.1053964.

54. Beckmann, M., Ebecken, N. F., & Pires de Lima, B. S. (2015). A KNN undersampling approach for data balancing. *Journal of Intelligent Learning Systems and Applications*, *07*(04), 104–116. https://doi.org/10.4236/jilsa.2015.74010

55. Dasarathy, B.V. (1991) Nearest Neighbor (NN) Norms: NN Pattern Classification Techniques. IEEE Computer Society Press, Los Alamitos.

56. Ibm. (2025b, February 12). *What is the K-nearest neighbors algorithm?*. IBM. https://www.ibm.com/think/topics/knn#:~:text=The%20k%2Dnearest%20neighbors%20(KNN)%20algorithm%20is%20a%20non,used%20in%20machine%20learning%20today

57. Allam, Z., Sharifi, A., Bibri, S. E., Jones, D. S., & Krogstie, J. (2022a). The metaverse as a virtual form of smart cities: Opportunities and challenges for environmental, economic, and Social Sustainability in Urban Futures. *Smart Cities*, *5*(3), 771–801. https://doi.org/10.3390/smartcities5030040

58. McKinsey & Company. (2021, November 12). *The value of getting personalization right-or wrong-is multiplying*. McKinsey & Company. https://www.mckinsey.com/capabilities/growth-marketing-and-sales/our-insights/the-value-of-getting-personalization-right-or-wrong-is-multiplying?utm_source=coda&utm_medium=iframely

59. State of Marketing. Salesforce 7th edition (2021). https://www.salesforce.com/content/dam/web/en_us/www/documents/reports/salesforce-research-seventh-state-of-marketing-V2.pdf

60. Segalin, C., Celli, F., Polonio, L., Kosinski, M., Stillwell, D., Sebe, N., Cristani, M., & Lepri, B. (2017). What your facebook profile picture reveals about your personality. *Proceedings of the 25th ACM International Conference on Multimedia*, 460–468. https://doi.org/10.1145/3123266.3123331

61. Agnès Mustar (2023) Modeling User-Machine Interactions During The Information Retrieval Process. Information Retrieval [cs.IR]. Sorbonne Université. https://theses.hal.science/tel-04163288v1

62. Santos Jr., E., & Nguyen, H. (2009). Modeling users for adaptive information retrieval by capturing user intent. *Collaborative and Social Information Retrieval and Access*, 88–118. https://doi.org/10.4018/978-1-60566-306-7.ch005

63. Brusilovsky P., Tasso C. (2004, January). User Modeling for Web Information Retrieval. https://sites.pitt.edu/~peterb/papers/USERPREF15.pdf

64. Sassi Hidri, M. (2024). Learning-based models for building user profiles for Personalized Information Access. *Interdisciplinary Journal of Information, Knowledge, and Management*, *19*, 010. https://doi.org/10.28945/5275

65. *Metaverse - vietnam: Statista market forecast*. Statista. (n.d.). https://www.statista.com/outlook/amo/metaverse/vietnam

66. Amini, M.-R., Feofanov, V., Pauletto, L., Hadjadj, L., Devijver, É., & Maximov, Y. (2025). Self-training: A survey. *Neurocomputing*, *616*, 128904. https://doi.org/10.1016/j.neucom.2024.128904

67. Riloff, E., Wiebe, J., & Wilson, T. (2003) *Learning subjective nouns using extraction pattern bootstrapping*. In *Proceedings of the Seventh Conference on Natural Language Learning at HLT-NAACL,* pages 25–32. https://aclanthology.org/W03-0404.pdf

68. Z. Song, X. Yang, Z. Xu and I. King, "Graph-Based Semi-Supervised Learning: A Comprehensive Review," in *IEEE Transactions on Neural Networks and Learning Systems*, vol. 34, no. 11, pp. 8174-8194, Nov. 2023, doi: 10.1109/TNNLS.2022.3155478.

69. W. Lin, Z. Gao and B. Li, "Shoestring: Graph-Based Semi-Supervised Classification With Severely Limited Labeled Data," *2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, Seattle, WA, USA, 2020, pp. 4173-4181, doi: 10.1109/CVPR42600.2020.00423.

70. Asif, I. H. (2023, November 1). *Complete Machine Learning Project Flowchart explained!*. Medium. https://ihsanulpro.medium.com/complete-machine-learning-project-flowchart-explained-0f55e52b9381

71. Charness, N., & Boot, W. R. (2016). Technology, gaming, and Social Networking. *Handbook of the Psychology of Aging*, 389–407. https://doi.org/10.1016/b978-0-12-411469-2.00020-0

72. Aljarrah, E., Elrehail, H., & Aababneh, B. (2016). E-voting in Jordan: Assessing readiness and developing a system. *Computers in Human Behavior*, *63*, 860–867. https://doi.org/10.1016/j.chb.2016.05.076

73. Marikyan, D.& Papagiannidis, S. (2024) *Technology Acceptance Model: A review*. In S. Papagiannidis (Ed), TheoryHub Book. Available at https://open.ncl.ac.uk / ISBN: 9781739604400

74. Jisana, T.K. (2014). CONSUMER BEHAVIOUR MODELS: AN OVERVIEW. *Sai Om Journal of Commerce & Management: A Peer Reviewed National Journal, 1*, 34-43.

TÀI LIỆU TIẾNG VIỆT

1. Trường Doanh nhân HBR, (2024, July 15). 4 Cách Cá Nhân Hóa Trải Nghiệm Khách Hàng Cho Mọi Doanh Nghiệp. https://hbr.edu.vn/ca-nhan-hoa-trai-nghiem-khach-hang

2. Minh Nguyệt. (2022, February 14). *Chiến Lược Cá Nhân Hóa Thương Hiệu xa xỉ để hút nhóm Tiêu Dùng Mới*. Nhịp sống kinh tế Việt Nam & Thế giới. https://vneconomy.vn/techconnect/chien-luoc-ca-nhan-hoa-thuong-hieu-xa-xi-de-hut-nhom-tieu-dung-moi.htm

3. Trituenhantao.io. (2024, February 11). *Bài 6: Logistic regression (Hồi Quy logistic)*. Trí tuệ nhân tạo. https://trituenhantao.io/machine-learning-co-ban/bai-6-logistic-regression-hoi-quy-logistic/

4. *Top 5 thuật toán phân loại (classification) Trong Machine Learning*. Tomorrow Marketers. (2024, May 27). https://blog.tomorrowmarketers.org/thuat-toan-phan-loai-classification-machine-learning/

5. Van, C. P. (2020, September 18). *Logistic regression - Bài toán cơ bản trong machine learning*. Viblo. https://viblo.asia/p/logistic-regression-bai-toan-co-ban-trong-machine-learning-924lJ4rzKPM#_2-dat-van-de-1

6. *Metaverse - Metaverse - Sự hội tụ khiến thị trường công nghệ tiêu dùng bùng nổ*. Tạp chí Lao động và Xã hội. https://tapchilaodongxahoi.vn/metaverse-su-hoi-tu-khien-thi-truong-cong-nghe-tieu-dung-bung-no-1333740.html

7. Long, D.T. , Minh, C., Chính, P. Q. (May, 2022). *Mô hình mạng nơron tích chập đa nhiệm nhận dạng khuôn mặt và biểu cảm cho ứng dụng hỗ trợ giám sát học trực tuyến*. Tạp chí Khoa học Trường Đại học Mở Hà Nội. https://vjol.info.vn/index.php/jshou/article/view/68665

8. Liên, T., & Phương, N. D. (2017). Một Phương Pháp Học Bán Giám Sát Cho Lọc Kết Hợp. *FAIR - NGHIÊN CỨU CƠ BẢN VÀ ỨNG DỤNG CÔNG NGHỆ THÔNG TIN - 2016*. https://doi.org/10.15625/vap.2016.00052

9. Nên, N.V., Linh, N.T.N., Thuỳ, P.M., Linh, V.T.T., Quyên, H.T.T., Đạt, P.N. (2022, April 11). Đánh giá tác động của quảng cáo cá nhân hoá đến ý định mua sắm của giới trẻ trên địa bàn Thành phố Hồ Chí Minh. Tạp chí Khoa học Thương mại. Số 158. Trường Đại học Thương mại | tckhtm.tmu.edu.vn

10. *Cập nhật số liệu mới nhất 4/2023 về người dùng mạng xã hội tại Việt Nam*. HR1TECH. (2023, May 21). https://hr1tech.com/vi/employer/news/cap-nhat-so-lieu-moi-nhat-4-2023-ve-nguoi-dung-mang-xa-hoi-tai-viet-nam-646.html

11. Phượng D.T.M. (2023, July 28). Mô hình MTAM: Lý thuyết tiềm năng về hành vi của người dùng công nghệ. Tạp chí Kinh tế và Dự báo. https://philpapers.org/versions/DUOMHM